

## Predicción de demanda eléctrica utilizando redes neuronales artificiales para un sistema de distribución de energía eléctrica

Carlos Hugo Lozada Cabrera

[carloslozada@itscv.edu.ec](mailto:carloslozada@itscv.edu.ec)

<https://orcid.org/0000-0002-2087-6806>

Instituto Superior Tecnológico Ciudad de Valencia

Nora Patricia Acosta Apolo

[acostanora@gmail.com](mailto:acostanora@gmail.com)

<https://orcid.org/0000-0002-7587-2896>

Instituto Superior Tecnológico Ciudad de Valencia

Darwin Vinicio Paredes Moran

[maxplack89@gmail.com](mailto:maxplack89@gmail.com)

<https://orcid.org/0000-0003-0872-8680>

Instituto Superior Tecnológico Ciudad de Valencia

Guillermo Ismael Vique Salazar

[guillermovique@itscv.edu.ec](mailto:guillermovique@itscv.edu.ec)

<https://orcid.org/0000-0001-7375-0441>

Instituto Superior Tecnológico Ciudad de Valencia

### RESUMEN

Este trabajo de investigación tiene como finalidad realizar la proyección de la demanda de energía eléctrica mediante un modelo de Redes Neuronales Artificiales (RNA). Para desarrollar esta proyección se utilizan datos de consumos históricos (demanda máxima mensual) entregados por la empresa eléctrica durante en el periodo de tiempo 2019 - 2021. La proyección de la demanda de energía eléctrica es fundamental para poder garantizar principalmente la continuidad del suministro eléctrico generando confiabilidad en los consumidores. En este proyecto se pone a prueba un modelo de RNA, las cuales han venido desarrollándose con mayor frecuencia a lo largo del tiempo. El procesamiento de los datos se realiza a través de 3 capas que forman parte de la RNA, estas capas consisten en: capa de entrada, oculta y salida, las cuales mediante procesos matemáticos entregan valores continuos que representan el resultado. El desarrollo de los resultados se divide en etapas, las cuales consisten en: entrenamiento de la RNA con el 85% de los datos histórico, prueba de la RNA bajo el criterio de evaluación Error Porcentual Absoluto Medio (MAPE) entre el 15% de los valores no utilizados en el entrenamiento frente a la proyección para dicha cantidad de históricos, esta etapa permite demostrar la confiabilidad del modelo en base al porcentaje de error, y así realizar una proyección con mayor horizonte de tiempo.

**Palabras clave:** retropropagación; demanda eléctrica; descenso de gradiente.

Correspondencia: [carloslozada@itscv.edu.ec](mailto:carloslozada@itscv.edu.ec)

Artículo recibido: 02 mayo 2022. Aceptado para publicación: 25 mayo 2022.

Conflictos de Interés: Ninguna que declarar

Todo el contenido de **Ciencia Latina Revista Científica Multidisciplinar**, publicados en este sitio están disponibles bajo

Licencia [Creative Commons](https://creativecommons.org/licenses/by/4.0/) 

Como citar: Lozada Cabrera, C. H., Acosta Apolo, N. P., Paredes Moran, D. V., & Vique Salazar, G. I. (2022) Predicción de demanda eléctrica utilizando redes neuronales artificiales para un sistema de distribución de energía eléctrica. *Ciencia Latina Revista Científica Multidisciplinar*, 6(3), 3871-3894. DOI: [https://doi.org/10.37811/cl\\_rcm.v6i3.2502](https://doi.org/10.37811/cl_rcm.v6i3.2502)

## Electrical demand prediction using artificial neural networks for an electrical energy distribution system

### ABSTRACT

The purpose of this research work is to project the demand for electrical energy through a model of Artificial Neural Networks (ANN). To develop this projection, historical consumption data (monthly maximum demand) delivered by the electricity company during the 2019 - 2021 time period are used. The projection of the demand for electrical energy is essential to be able to guarantee mainly the continuity of the electricity supply by generating consumer reliability. In this project, an ANN model is tested, which have been developed more frequently over time. Data processing is carried out through 3 layers that are part of the ANN, these layers consist of: input, hidden and output layers, which through mathematical processes deliver continuous values that represent the result. The development of the results is divided into stages, which consist of: training of the ANN with 85% of the historical data, testing of the ANN under the evaluation criteria Mean Absolute Percentage Error (MAPE) among 15% of the values not used in the training versus the projection for said number of histories, this stage allows demonstrating the reliability of the model based on the percentage of error, and thus making a projection with a longer time horizon.

**Keywords:** *backpropagation; electricity demand; gradient descent.*

## 1. INTRODUCCIÓN

La demanda eléctrica es la suma de los consumos individuales de los diferentes clientes pertenecientes al sistema de distribución, los cuales, varían según diversos factores que caracterizan dicho consumo (Cabrera, 2014). Los clientes residenciales mantienen un consumo muy variado de acuerdo a las horas del día; los clientes industriales y comerciales varían el consumo de energía según las jornadas de trabajo. Éstos y otros factores como la época del año, festividades, feriados, clima, entre otros, provocan que el consumo de energía eléctrica varíe en el tiempo (Quisimalin, 2017).

El correcto funcionamiento del Sistema Nacional Interconectado (SNI) implica que todos los agentes que participan en él, tales como la generación, transmisión y distribución, estén siempre interconectados y comunicados. Es así que ante la presencia de una falla el sistema pueda responder adecuadamente direccionando recursos para aislarla y corregirla. El constante crecimiento poblacional y desarrollo de la ciudad provoca el incremento de la demanda de energía eléctrica, siendo la empresa de distribución la responsable de abastecer este recurso de forma continua y estable al menor costo (Ariza, 2013).

Por ello, está en la necesidad de desarrollar planes de expansión que reduzcan los costos de inversión, cubriendo el total de la demanda requerida, considerando que una inadecuada proyección genera problemas operativos y mal dimensionamiento de elementos ocasionando pérdidas para la empresa (Hagan, et. al 2014). Dada la importancia de conocer el comportamiento futuro de la demanda de energía eléctrica en la empresa de distribución, la cual tiene entre sus objetivos mantener un adecuado plan de expansión y correcta operación del sistema, en el presente proyecto se realiza la proyección de demanda eléctrica mediante el uso de RNA, ampliamente usado en problemas de proyección de demanda, por los resultados confiables que ofrece (Tablada y Torres, 2019).

El consumo de energía eléctrica a lo largo de los años indica el aumento de la demanda y con esto se debe repotenciar el sistema de distribución para cumplir con los parámetros que deben garantizar la confiabilidad, continuidad, seguridad, niveles de tensión y frecuencia a todos los clientes que están conectados al sistema de distribución (Flores y Fernández, 2018). Realizar la proyección de la demanda eléctrica es sumamente importante para el sistema de distribución, permitiendo cumplir con el objetivo de

entregar la energía eléctrica necesaria a todos los consumidores (Cruz, 2010). La empresa eléctrica mantiene control de las proyecciones de demanda. Se realizan por medio de métodos estadísticos con el objetivo de llevar a cabo una adecuada distribución de energía aplicando planes de operación y expansión con antelación (Rivas y Mazón, 2018). En este trabajo de investigación se utiliza una RNA como un método alternativo para realizar la proyección de demanda, haciendo uso del software MATLAB para llevar a cabo su funcionamiento. El proyecto se desarrolla en cinco capítulos en los que se mencionan los temas más relevantes dirigidos a la proyección con RNA. Estos son: funciones de activación, topología de RNA, procesamiento de datos históricos, entrenamiento, prueba y proyección. La importancia de una correcta proyección de demanda de energía eléctrica radica en que ésta se ajuste a los valores reales (Freeman y Skapura, 2010). La aplicación de cualquier método no garantiza esta finalidad; sin embargo, es importante contar con uno que demuestre ser efectivo. Por ello se plantea el uso de RNA para llevar a cabo la tarea de proyección de demanda. En los sistemas de distribución la correcta proyección de la demanda resulta útil en la toma de decisiones y operación del sistema (Flores, 2018).

El presente trabajo consiste en realizar la proyección de demanda de energía eléctrica considerando el valor del porcentaje de error obtenido en la etapa de prueba, que a su vez depende del proceso de entrenamiento (Morera, 2018). Las etapas de entrenamiento y prueba se realizan con los datos entregados por la empresa. La efectividad del método depende del porcentaje de error resultante en la etapa de prueba. Las RNA se asemejan al funcionamiento de una red neuronal biológica, es decir, se encadenan múltiples neuronas dentro de capas, una a continuación de otra. Cada neurona genera una respuesta de salida que se entrega a las neuronas de la siguiente capa, las que procesan los datos entregándolos a las neuronas de la última capa dando el resultado final (Marín, 2012). El entrenamiento es un proceso en el que una parte del total de datos son ingresados para que la red identifique y aprenda los patrones presentes en la serie de tiempo. Este proceso busca ajustar el valor de pesos y bias que sirven para realizar la proyección después del proceso de entrenamiento (Norgaard y Ravn, 2003). Con el uso de RNA se espera obtener resultados aceptables dado que su algoritmo de aprendizaje supervisado permite modificar los parámetros mediante ensayos de prueba y error hasta

lograr un modelo que dé como resultado el menor porcentaje de error en la etapa de prueba (Caicedo y López, 2009).

## 2. MATERIALES Y MÉTODOS

Para la realización de esta investigación se utilizó una investigación bibliográfica, se realizará una ardua investigación recurriendo a artículos científicos, trabajos de investigación, libros, tesis de grado y posgrado que abordan el tema desde diferentes metodologías y puntos de vista, permitiendo conocer el tema a mayor profundidad, también una investigación explicativa, lo cual permiten complementar las destrezas necesarias para el entendimiento y desarrollo de este proyecto, sentando como bases conocimientos sobre temas relacionados con demanda de energía eléctrica, consumo de energía, probabilidades, entre otros. Se aplicó un método analítico, inductivo y deductivo donde la recopilación de datos de diferentes fuentes de información consultadas permite conocer las características principales que se debe tener en cuenta para el tratamiento de los datos iniciales, el proceso de entrenamiento y prueba de la RNA (Bajaña, 2019). Los datos que se usan para el desarrollo de este proyecto son valores de consumo de potencia eléctrica correspondiente a 6 años, estos datos fueron entregados por la empresa eléctrica. Los datos corresponden al periodo 2003 – 2008, los cuales no son tan actuales debido a que en la empresa eléctrica se manifestó que el seguimiento del consumo energético de CNEL que tiene en el sistema de forma digital.

### RESULTADOS Y DISCUSIÓN

Los datos para realizar el proyecto son valores de consumo de potencia eléctrica tabulados de forma mensual pertenecientes al periodo de tiempo 2019 al 2021. Los datos son entregados por la empresa eléctrica y se presentan en la siguiente tabla:

N°. Muestras	Tiempo (Año)	Tiempo (Mes)	Demanda máxima (MW)	Número de muestras	Tiempo (Año)	Tiempo (Mes)	Demanda máxima (MW)
1	2017	1	62.90	37	2017	1	71.77
2	2017	2	67.48	38	2017	2	76.48
3	2017	3	59.42	39	2017	3	73.58
4	2017	4	67.38	40	2017	4	75.36
5	2017	5	60.42	41	2017	5	65.17
6	2017	6	56.51	42	2017	6	64.45


Lozada Cabrera y otros

7	2017	7	48.45	43	2017	7	61.91
8	2017	8	57.39	44	2017	8	65.18
9	2017	9	56.92	45	2017	9	62.26
10	2017	10	56.35	46	2017	10	62.45
11	2017	11	70.87	47	2017	11	64.72
12	2017	12	58.35	48	2017	12	81.24
13	2018	1	7087	49	2018	1	77.26
14	2018	2	69.25	50	2018	2	83.45
15	2018	3	72.41	51	2018	3	78.48
16	2018	4	67.57	52	2018	4	78.27
17	2018	5	61.20	53	2018	5	73.45
18	2018	6	57.68	54	2018	6	69.45
19	2018	7	65.25	55	2018	7	68.45
20	2018	8	61.45	56	2018	8	68.16
21	2018	9	56.57	57	2018	9	64.88
22	2018	10	62.54	58	2018	10	68.35
23	2018	11	54.90	59	2018	11	64.88
24	2018	12	64.25	60	2018	12	80.75
25	2020	1	68.42	61	2020	1	79.05
26	2020	2	76.21	62	2020	2	86.29
27	2020	3	76.67	63	2020	3	82.56
28	2020	4	71.25	64	2020	4	71.58
29	2020	5	63.24	65	2020	5	77.45
30	2020	6	63.28	66	2020	6	71.28
31	2020	7	61.84	67	2020	7	72.58
32	2020	8	66.35	68	2020	8	71.52
33	2020	9	62.15	69	2020	9	69.53
34	2020	10	61.48	70	2020	10	70.25
35	2020	11	62.25	71	2020	11	71.65
36	2020	12	75.45	72	2020	12	81.54

Fuente: CNEL EP – UNIDAD DE NEGOCIOS AGENCIA QUEVEDO. Elaboración: Autores.

De la base de datos se analiza que los valores de mínimo y máximo consumo fueron en el mes 7 del año 2017 y el mes 2 del año 2020 que corresponden a 48.45 MW y 86.29 MW respectivamente. Estos valores mínimo y máximo de la serie de tiempo permiten realizar la normalización de los datos lo cual es muy importante para el procesamiento en la RNA. Del conjunto de datos históricos se estima que inicialmente en el año 2003 el valor medio de consumo es de 60.25 MW creciendo anualmente de manera progresiva con una media de 3.04 MW, hasta alcanzar en el año 2008 un valor medio de 75.44 MW (López y Fernández, 2008). Los valores de consumo de potencia eléctrica de los 72 meses se presentan en la figura, como una curva que describe una serie en el tiempo, las fluctuaciones que presentan corresponden a las variaciones típicas de consumo.

**Figura 1.** Curva de consumo de potencia eléctrica de 72 meses en escala original.



**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

#### Normalización de datos.

Los datos que se presentan en la serie de tiempo no pueden ser procesados directamente por la RNA, debido a que al tratar de procesar valores muy grandes tardaría mucho tiempo realizando los cálculos, retrasando el proceso y en el peor de los casos colapsando el sistema. Para evitar esto se realiza la normalización de los datos de entrada a valores en el intervalo 0 a 1, la fórmula utilizada para normalizar los valores es la siguiente:

*Donde:*

$P_{norm}$  : valor normalizado.

$P_{desn}$  : valor desnormalizado o en escala inicial.


$P_{min}$  : valor mínimo de la serie.

$P_{max}$  : valor máximo de la serie.

$$P_{norm} = \frac{P_{desn} - P_{min}}{P_{max} - P_{min}}$$

Los datos de consumo de potencia eléctrica para los 72 meses normalizados se presentan en la figura

**Figura 2.** *Curva de consumo de potencia eléctrica de 72 meses normalizados.*



**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

### Conjuntos de entrenamiento y de prueba.

Del total de datos mostrados en la serie de tiempo se dividen en dos grupos, de la siguiente manera: 85% del total de datos para el proceso de entrenamiento, que corresponde a los datos en el intervalo del mes 1 al 60; y, el 15% restante para el proceso de prueba que corresponde a los datos de la serie de tiempo pertenecientes al intervalo de los meses 61 al 72. La división de 50 los datos se realizan de forma arbitraria, pero siempre considerando que el mayor porcentaje de datos es necesario para el entrenamiento y el porcentaje de datos restantes es muy importante para validar el desempeño de la RNA mediante la comparación de la proyección en el proceso de prueba, si se seleccionase el 100% de datos para el entrenamiento, no se podría validar si la proyección de la RNA es correcta, debido a que no se tendría valores nuevos para probar la RNA (Ortiz,2014).

**Figura 3.** *División de datos para entrenamiento y prueba.*

Proceso	# datos	% datos
Entrenamiento	60	85
Prueba	12	15
Total	72	100

**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación



### Proceso de entrenamiento.

Para realizar el proceso de entrenamiento se debe seleccionar de forma adecuada el tamaño del vector de entrada, el cual contiene los datos seleccionados previamente para este proceso. El tamaño del vector de entrada debe contener un patrón que marque una tendencia en el tiempo; asimismo, se debe contar con un vector de salida u objetivo que corresponde a la salida deseada de entrenamiento. Durante el entrenamiento se generan errores al evaluar la salida de la RNA con la salida esperada, esto provoca que el algoritmo de entrenamiento modifique los parámetros relacionados al proceso, es decir, los pesos y bias de las neuronas de la o las capas ocultas y salida (Oscullo y Haro, 2016). La matriz de entrada  $P$  y el vector de salida  $T$  están definidos en la Tabla, el tamaño de la matriz de entrada es de  $12 \times 48$ , y el vector de salida es de  $1 \times 48$ , es importante que las dos variables tengan la misma cantidad de columnas, debido a que cada columna de la matriz de entrada corresponde al patrón que describe cada valor del vector de salida.

**Figura 4.** Matriz de entrada y salida para el entrenamiento.

	70.87	69.25	72.41	67.57	70.50	61.20	57.68	56.25	61.45	56.57	...
	58.35	70.87	69.25	72.41	67.57	70.50	61.20	57.68	56.25	61.45	...
	56.92	58.35	70.87	69.25	72.41	67.57	70.50	61.20	57.68	56.25	...
	56.92	56.92	58.35	70.87	69.25	72.41	67.57	70.50	61.20	57.68	...
	57.39	56.92	56.92	58.35	70.87	69.25	72.41	67.57	70.50	61.20	...
$P$	48.45	57.39	56.92	56.92	58.35	70.87	69.25	72.41	67.57	70.50	...
	56.51	48.45	57.39	56.92	56.92	58.35	70.87	69.25	72.41	67.57	...
	60.42	56.51	48.45	57.39	56.92	56.92	58.35	70.87	69.25	72.41	...
	67.38	60.42	56.51	48.45	57.39	56.92	56.92	58.35	70.87	69.25	...
	59.42	67.38	60.42	56.51	48.45	57.39	56.92	56.92	58.35	70.87	...
	67.48	59.42	67.38	60.42	56.51	48.45	57.39	56.92	56.92	58.35	...
	62.90	67.48	59.42	67.38	60.42	56.51	48.45	57.39	56.92	56.92	...
$T$	69.25	72.41	67.57	70.50	61.20	57.68	56.25	61.45	56.57	62.54	...


**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación

El tamaño de las filas de la matriz de entrada corresponde al número de neuronas de la capa de entrada y es el desplazamiento que tendrá el resultado de entrenamiento con respecto a los datos históricos, es decir, si el número de neuronas de entrada es 12, el resultado de entrenamiento inicia en el mes número 13, como se observa en la figura. En este proyecto se consideran dos inconvenientes durante el desarrollo de ensayos con la RNA, el sobre entrenamiento y la poca cantidad de neuronas de entrada, no permiten lograr el objetivo de una adecuada proyección, a continuación, se presentan los resultados de entrenamiento realizados con este tipo de problemas.

### Sobre entrenamiento.

El sobre entrenamiento es producido cuando la RNA no ha aprendido y no puede generalizar el modelo. Como resultado de este proceso se establece que la RNA memoriza, más no ha aprendido (Barrezueta y Encalada, 2014). En la figura 14 se muestra el resultado de un proceso de entrenamiento en el cual se evidencia que la salida de la RNA (línea entrecortada azul) es la misma que los valores históricos (línea continua roja), estando sobrepuesta una encima de otra. El eje horizontal se extiende hasta el mes 60 debido a que los 12 meses restantes han sido omitidos para luego ser utilizados en el proceso de prueba, mientras que en el eje vertical los valores se presentan en el intervalo de 40 a 100 en su unidad de medición original (MW) y este será el intervalo para todas las demás figuras.

**Figura 5.** Resultado de entrenamiento de una red sobreentrenada.




**Fuente:** Cálculo de resultados. **Elaboración:** Grupo Investigación

### Número de neuronas de entrada inadecuado.

Un número muy bajo de neuronas de entrada no es suficiente para que la RNA aprenda la tendencia de la serie temporal, mientras que un número excesivo de neuronas de entrada provoca la saturación y de igual forma no entrega resultados adecuados. Durante los ensayos se determina que el número adecuado de neuronas de entrada tiene que ser un valor que abarque un patrón que se repita cierto tiempo. En la figura, se presenta el resultado del proceso de entrenamiento para la RNA con 3 neuronas de entrada. La salida estimada por la RNA es muy distinta a la salida deseada, considerando a esta respuesta como un entrenamiento pobre. El resultando de entrenamiento para este caso inicia en

el mes número 4, debido a que se la RNA tiene 3 neuronas de entradas lo que provoca el desplazamiento en el resultado (Mejía y Gonzales, 2019).

**Figura 6.** Resultado de entrenamiento con 3 neuronas de entrada



**Fuente:** Cálculo de resultados. **Elaboración:** Grupo Investigación

En los siguientes procesos se muestra los resultados de la RNA con los dos problemas mencionados.

#### Proceso de prueba.

En el proceso de prueba se obtiene el MAPE entre los valores proyectados y valores históricos que se destinaron para este proceso y no fueron usados durante el entrenamiento. La validación del modelo se realiza utilizando la ecuación (51), el uso de este criterio de evaluación facilita la interpretación del error debido a que entrega el resultado en porcentaje.

En la tabla siguiente se presenta el conjunto de datos históricos de consumo de potencia eléctrica seleccionados para realizar la prueba, los valores corresponden a los 12 meses del año 2020 que han sido omitidos del proceso de entrenamiento.

**Figura 7.** Datos históricos usados en el proceso de

Año	Mes	MW
2008	1	79.05
	2	86.29
	3	82.56
	4	71.58
	5	77.45
	6	71.28
	7	72.58
	8	71.52
	9	69.53
	10	70.25
	11	71.65
	12	81.54


**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

Una vez finalizado el proceso de entrenamiento la RNA está en capacidad de realizar la proyección de los valores para el proceso de prueba, sin embargo, la proyección se encuentra en la escala normalizada por lo que se procede a desnormalizar y obtener los valores en la unidad inicial, es decir, en MW, para ello se utiliza la ecuación.

$$P_{desn} = (P_{norm} \times (P_{max} - P_{min})) + P_{min}$$


En la figura se muestra el resultado de la proyección (línea entrecortada verde) para el proceso de prueba de la RNA sobreentrenada y en la figura el resultado de proyección de la RNA con 3 neuronas de entrada. El eje horizontal se presenta en el intervalo del mes 61 al 72 que corresponde a los 12 meses históricos seleccionados para este proceso, mientras que en el eje vertical se mantiene el mismo intervalo anterior en MW

**Figura 8.** *Proyección para la prueba de la RNA sobreentrenada*



Fuente: Datos extraído de la investigación. Elaboración: Grupo Investigación.

**Figura 9.** *Proyección para la prueba de la RNA con 3 neuronas de entrada.*




Fuente: Datos extraído de la investigación. Elaboración: Grupo Investigación.

## Proyección

El proceso de proyección consiste en realizar una extensión de los valores proyectados en la prueba de la RNA, se realiza considerando el método de proyección en múltiples pasos de tiempo, en donde los nuevos datos proyectados serán ingresados a la matriz de entrada formando el patrón de tendencia a la largo del tiempo. La variable  $N$  indica el horizonte de tiempo hasta el cual se va a realizar la proyección, para el proceso de prueba el valor de esta variable está definido en 12, mientras que, para la proyección fuera de la prueba se puede definir en cualquier valor (Mejía y Gonzales, 2019).

En la figura se muestra el resultado de la prueba y proyección de la RNA sobreentrenada, se evidencia que, al obtener el entrenamiento demasiado ajustado entre la salida estimada y la salida esperada, se generan proyecciones inadecuadas sin ningún patrón de comportamiento.


**Figura 10.** Prueba y proyección de la RNA sobreentrenada



**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

En la figura 10 se muestra el resultado de la prueba y proyección de la RNA con 3 neuronas de entrada, de igual manera se evidencia que en el entrenamiento no se ajusta adecuadamente la salida estimada y la salida esperada, generando proyecciones que resultan en una línea recta.

**Figura 11.** Prueba y proyección de la RNA con 3 neuronas de entrada.



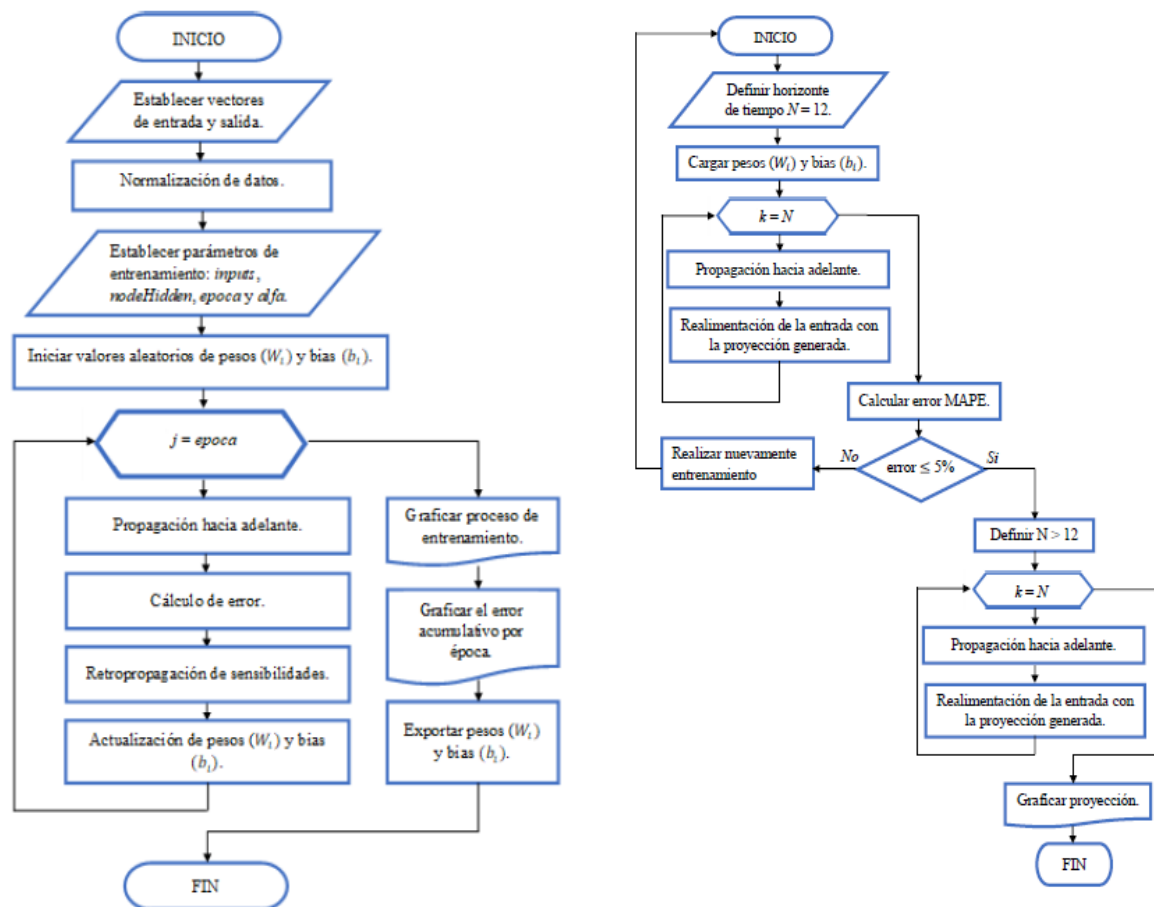
**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

En la figura se presentan los procesos de prueba (líneas entrecortadas verdes), los valores históricos (línea continua roja) y la proyección (líneas entrecortadas magenta) con horizonte de tiempo = 36, que corresponden a la proyección de 12 meses para la prueba y extensión de la proyección para 24 meses más.

### Implementación de la Red Neuronal Artificial.

La matriz de pesos  $W_i$  y vector bias  $b_i$  inicialmente se genera de manera aleatoria y con ello se realiza la propagación hacia adelante, a continuación, se realiza la comparación de la salida estimada con la salida deseada y se calcula el error permitiendo obtener un valor de sensibilidad para ser propagado hacia atrás, esto permite ajustar el valor de pesos y bias con cada iteración, este proceso se repite hasta que la variable  $j$  es del mismo valor que la variable época, posteriormente se generan las gráficas de entrenamiento y del error por cada iteración, finalmente se exportan la matriz de pesos  $W_i$  y el vector bias  $b_i$  a un archivo denominado Pesos.m para ser usados en el siguiente diagrama de flujo (Mejía y Gonzales, 2019).

Figura 12. Diagrama de flujo 1-2 del proceso de entrenamiento.



Fuente: Datos extraído de la investigación. Elaboración: Grupo Investigación.

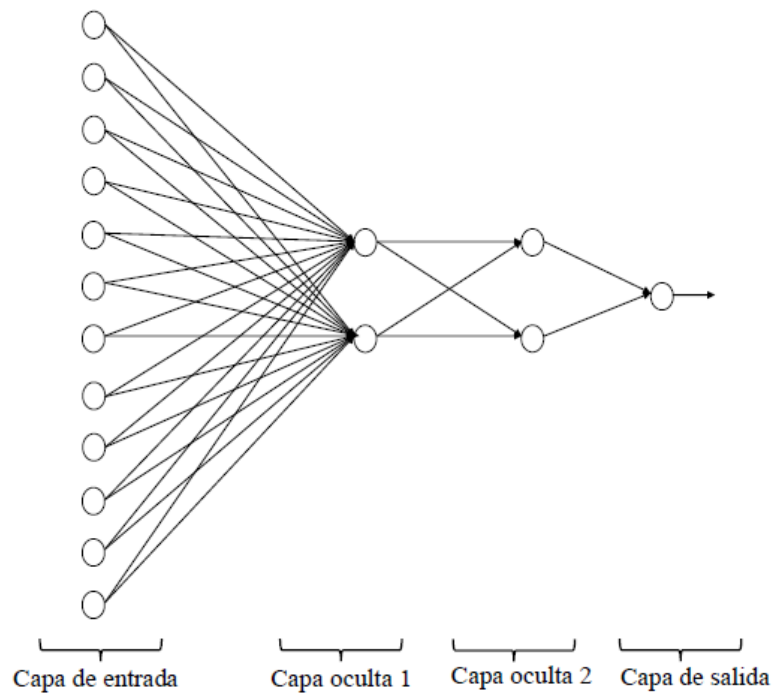
### Diseño de la Red Neuronal Artificial

Se presentan dos modelos de RNA con arquitecturas diferente, la figura 22 presenta el primer modelo de dos capas ocultas con dos neuronas en cada capa y una neurona en la capa de salida, mientras que, la figura presenta el segundo modelo de una sola capa oculta con nueve neuronas y una neurona en la capa de salida, los dos modelos se plantean con doce neuronas de entrada.

**Figura 13.** Características de los modelos 1 y 2.

Parámetro	Modelo 1	Modelo 2
Número de neuronas de entrada	12	12
Número de neuronas de salida	1	1
Número de capas ocultas	2	1
Número de neuronas en primera capa oculta	2	9
Número de neuronas en segunda capa oculta	2	-
Función de activación capa oculta	Tangente hiperbólica	Tangente hiperbólica
Función de activación capa de salida	Lineal	Lineal
Algoritmo de aprendizaje	Backpropagation	Backpropagation
Aprendizaje	Supervisado	Supervisado


**Figura 14.** Arquitectura del modelo 1.



**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.



Figura 15. Arquitectura del modelo 2.



Fuente: Datos extraído de la investigación. Elaboración: Grupo Investigación.

Figura 16. Parámetros de proyección de los modelos 1 y 2.


	Modelo 1	Modelo 2
<i>inputs</i>	12	12
<i>train</i>	1:60	1:60
<i>nodeHidden</i>	2;2	9
<i>epoca</i>	1000	1000
<i>alfa</i>	0.032	0.018
<i>prueba</i>	61:72	61:72
<i>N</i>	36	36

Fuente: Datos extraído de la investigación. Elaboración: Grupo Investigación.

En la figura se presentan los resultados de entrenamiento del modelo 1 (línea entrecortada azul) y modelo 2 (línea entrecortada verde) que inician en el mes número 13 a causa del desplazamiento que surge al presentar 12 neuronas de entrada, el resultado finaliza en el mes número 60 cubriendo el total de valores seleccionados para el entrenamiento, además se incluye el total de valores históricos (línea continua roja).

Inicialmente las curvas de los modelos 1 y 2 no se asemejan a los valores históricos, pero a medida que más valores de entrenamiento recibe la RNA, se ajusta de mejor manera. El eje horizontal presenta la cantidad de meses del total de valores históricos, es decir, 72 meses, mientras que, en el eje vertical se mantiene el intervalo de 40 a 100 en unidad de MW, se presenta en esta unidad debido a que es de mejor comprensión que al tratar con valores normalizados.

**Figura 17.** *Proceso de entrenamiento de los modelos 1 y 2.*



**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

La figura siguiente presenta el descenso del error durante el proceso de entrenamiento para los modelos 1 y 2. El error se calcula como la diferencia entre el valor esperado y el valor estimado, en base a este error se calculan las sensibilidades y se actualización los pesos y bias después de cada iteración, cabe indicar que cuando se han ingresado el total de valores de entrada se completa una iteración. El eje horizontal de la figura señala la cantidad de iteraciones que se han realizado, mientras que el eje vertical muestra la diferencia existente entre cada punto de la serie temporal de datos históricos y la proyección de los modelos 1 y 2 al finalizar cada iteración.

Proyección normalizada				Proyección desnormalizada	
Año	Mes	Modelo 1	Modelo 2	Modelo 1	Modelo 2
2019	61	0.96	0.96	81.09	81.00
	62	1.05	1.08	83.83	85.11
	63	0.97	0.99	81.14	82.02
	64	0.93	0.95	80.04	80.62
	65	0.85	0.88	77.14	78.27
	66	0.80	0.80	75.52	75.57
	67	0.61	0.65	69.08	70.55
	68	0.64	0.69	70.02	71.68
	69	0.47	0.51	64.50	65.57
	70	0.62	0.66	69.35	70.66
	71	0.65	0.63	70.32	69.70
	72	0.93	0.93	80.01	80.04
	73	1.00	1.02	82.25	82.95
	74	1.06	1.10	84.16	85.80
	75	1.00	1.07	82.44	84.50
	76	1.02	1.06	82.92	84.21
2020	77	0.92	0.97	79.70	81.15
	78	0.90	0.95	78.96	80.54
	79	0.68	0.74	71.56	73.58
	80	0.66	0.75	70.77	73.97
	81	0.53	0.59	66.42	68.31
	82	0.66	0.70	70.75	72.15
	83	0.75	0.73	73.67	73.19
	84	0.95	0.94	80.65	80.42
	85	1.01	1.04	82.51	83.71
	86	1.06	1.13	84.46	86.69
	87	1.03	1.11	83.43	85.86
	88	1.06	1.14	84.40	86.99
2021	89	0.98	1.04	81.75	83.72
	90	0.95	1.04	80.65	83.66
	91	0.76	0.84	74.18	77.02
	92	0.70	0.82	72.19	76.04
	93	0.61	0.68	68.98	71.47
	94	0.72	0.75	72.83	73.92
	95	0.82	0.80	76.16	75.62
	96	0.97	0.97	81.41	81.30

**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

**Error de proyección.**

En la tabla se presenta el resultado del proceso de prueba de los modelos 1 y 2, consiste en aplicar el criterio de evaluación MAPE, para lo cual se dispone de los valores esperados que corresponde a los 12 meses del año 2008 en unidades originales (MW), las proyecciones de los modelos 1 y 2 se presenta en la misma unidad de medida y el resultado de aplicar el criterio MAPE se expresa en porcentaje.

	Histórico		Proyección		MAPE	
Año	Mes	MW	Modelo 1	Modelo 2	MAPE 1	MAPE 2
2018	1	79.05	81.09	81.00	2.58	2.47
	2	86.29	83.83	85.11	2.86	1.36
	3	82.56	81.14	82.02	1.72	0.65
	4	71.58	80.04	80.62	11.82	12.63
	5	77.45	77.14	78.27	0.40	1.05
	6	71.28	75.52	75.57	5.95	6.02
	7	72.58	69.08	70.55	4.82	2.79
	8	71.52	70.02	71.68	2.10	0.23
	9	69.53	64.50	65.57	7.23	5.70
	10	70.25	69.35	70.66	1.29	0.59
	11	71.65	70.32	69.70	1.85	2.73
	12	81.54	80.01	80.04	1.88	1.84
Error: 3.71%					3.17%	

**Fuente:** Datos extraído de la investigación. **Elaboración:** Grupo Investigación.

Se evidencia que el modelo 2 entrega menor porcentaje de error, siendo considerado como el modelo más adecuado en base al criterio MAPE. El porcentaje de error aceptable en proyecciones de demanda eléctrica a mediano y corto plazo se encuentra establecido en 5%, reflejando un 95% de confianza en las proyecciones del modelo a evaluar. La importancia de evaluar los modelos recae en la correlación que presente el modelo y sus datos reales, y así realizar proyecciones ajustándose a estos datos. Se considera que las proyecciones que se encuentren dentro del margen de 95% de confiabilidad se pueden considerar como “buenas”, la selección de un modelo de proyección y otro, depende del criterio de evaluación que se aplique, pudiendo ser el criterio de evaluación MAPE, MSE, RMSE, MAE, etc.

Entre las consideraciones a tomar en cuenta para el desarrollo de la RNA es la forma en la que los datos van a ser ingresados, para ello, en el diagrama de flujo se indica la forma en que se consideran los datos, los datos de entrada forman un conjunto de patrones para la comparación de un valor futuro que se encuentra dentro de los datos históricos, así se va construyendo los vectores con los conjuntos de patrones que sirven para entrenar la red. La normalización de los datos de entrada es de mucha importancia para evitar saturar el proceso de entrenamiento debido a que al trabajar con datos muy grandes requiere mucho tiempo procesar estos datos. Después de realizar los procesos de entrenamiento, prueba y proyección se realiza el proceso de desnormalización para devolverlos a las unidades de origen (Oscullo y Haro, 2016).

En este caso la división de los datos usados para el entrenamiento corresponde al 85% del total y el 15% restantes, para el proceso de prueba. Siendo este proceso fundamental para el desempeño y evaluación del modelo de red neuronal. El procesamiento de la RNA se basa en ensayos de prueba y error hasta encontrar la mejor solución con la cual se obtenga el menor porcentaje de error en el proceso de prueba de la red. Los parámetros que predominan en el proceso de entrenamiento son los que se van modificando hasta encontrar el mejor modelo, para ello se puede cambiar el número de neuronas de entradas, número de capas ocultas, número de neuronas por cada capa oculta, funciones de activación, número de épocas para entrenamiento y valor de la tasa de aprendizaje. Durante los ensayos de prueba y error se pueden observar que existen diferentes comportamientos que entregan como resultado la RNA (Oscullo y Haro, 2016). Los comportamientos que destacan son el sobre entrenamiento que entregan resultados de predicción totalmente erróneos, también se destaca que para un horizonte de proyección muy lejano la RNA pierde la tendencia de los datos y se convierte en una recta, también se conoce que, con muy pocas neuronas de entrada, la red no tiene los suficientes patrones de entrenamiento, por lo cual la misma resulta ineficiente para realizar las predicciones. La prueba se realiza comparando los datos no usados para el proceso de entrenamiento que consisten en el intervalo de meses del 61 al 72 para los modelos 1 y 2, de los cuales se obtiene un porcentaje de error de 3.71% y 3.17% respectivamente a partir del criterio de evaluación MAPE.

#### 4. CONSIDERACIONES FINALES

El modelo del perceptrón multicapa con función de activación logística en la capa oculta y función de activación lineal en la capa de salida sirve como un aproximador universal de funciones. Para este caso de estudio, el cual presenta una sola variable de entrada, el número de neuronas de la capa de entrada es seleccionado mediante el análisis de la serie temporal identificando patrones de comportamiento que se repiten cada cierto tiempo.

El modelo 1 es más sensible a cambios en la respuesta de la RNA por cambios en los parámetros de pesos y bias en comparación al modelo 2. El resultado del criterio de evaluación MAPE aplicado durante la etapa de prueba, no asegura que la proyección para los meses siguientes tendrá el mismo margen de error, debido a que la proyección resulta adecuada para los primeros meses de evaluación, pero pierde tendencia muy pronto. Aplicando el criterio de evaluación MAPE al modelo 1 y modelo 2, se concluye que el modelo 2 resulta ser el más adecuado debido a que entrega un porcentaje de error igual a 3.17%, siendo menor al obtenido del modelo 1, que es de 3.71%. La cantidad de neuronas en la capa oculta intervienen de forma significativa en los resultados de la RNA, debido a que esta cantidad de neuronas depende del problema a resolver, por lo que se debe realizar ensayos de prueba y error hasta encontrar el número adecuado de neuronas ocultas que lo resuelvan.

#### 5. LISTA DE REFERENCIAS

- Cabrera, D. "Diseño de una red neuronal artificial para la predicción de demanda eléctrica", trabajo de fin de grado, Universidad Nacional de Loja, Loja, 2014.
- Quisimalin, L. "Predicción de demanda eléctrica en una barra de 69 kV del sistema eléctrico de subtransmisión de la Empresa Eléctrica Riobamba S.A", trabajo de fin de grado, Escuela Politécnica Nacional, Quito, 2017.
- Ariza, A. "Métodos utilizados para el pronóstico de energía eléctrica en sistemas de distribución", trabajo de fin de grado, Universidad Tecnológica de Pereira, Pereira, 2013.
- Hagan, M. Demuth, H. Beale, M. "Neural Network Desing", 2nd Edition, Madrid, 2014.
- Tablada C. y Torres, G. "Redes Neuronales Artificiales", Revista de Educación Matemática, vol. 24, octubre. 2019.

- Flores, R. y Fernández, J. "Las redes neuronales artificiales fundamentos teóricos y aplicaciones prácticas", Netbiblo, Madrid, 2018.
- Cruz, P. "Inteligencia artificial con aplicaciones a la ingeniería", Primera edición, Alfaomega Grupo Editor, S.A., México, 2010.
- W. Rivas y B. Mazón, "Redes neuronales artificiales aplicadas al reconocimiento de patrones", Machala, UTMACH, 2018.
- Freeman, J. y Skapura, D. "Redes Neuronales algoritmos, aplicaciones y técnicas de programación", Addison – Wesley / Diaz de Santos, 2010.
- Flores, I. "Modelo predictivo de la demanda de energía eléctrica en el campus central de la Universidad de El Salvador", tesis de grado, Universidad de El Salvador, San Salvador, 2018.
- Llanos, L. Hoyos, A. Arias, F. y Velázquez, J. "Comparación del desempeño de funciones de activación en redes feedforward para aproximar funciones", Revista Avances en Sistemas e Informática, vol. 4, septiembre 2007.
- Morera, A. "Introducción a los modelos de redes neuronales artificiales El perceptrón simple y multicapa", tesis de grado, Universidad zaragoza, Zaragoza, 2018.
- Palmer, A. Montañó, J. y Jiménez, R. "Tutorial sobre redes neuronales artificiales: El perceptrón multicapa", Universidad de las Islas Baleares, 2001.
- Marín, J. "Introducción a las redes neuronales aplicadas", Universidad Carlos III de Madrid, 2012.
- Norgaard, M. Ravn, O. Poulsen, N. y Hansen, L. Neural Networks for Modelling and Control of Dynamic Systems, 1st Edition, 2003.
- Caicedo, B. y López, J. "Perceptrón multicapa y algoritmo backpropagation" en Una Aproximación Práctica a Las Redes Neuronales Artificiales, 2009.
- Bajaña, A. "Pronóstico de producción hidroeléctrica del Ecuador usando redes neuronales", tesis de grado, Universidad de Guayaquil, 2019.
- López, R. y Fernández, J. "Las Redes Neuronales Artificiales Fundamentos Teóricos y Aplicaciones Prácticas", Netbiblo, 2008.
- Ortiz, D. "Aplicación de redes neuronales artificiales en el pronóstico de la demanda eléctrica a corto plazo en el SNI", tesis de grado, Universidad Politécnica Salesiana, 2014.

- Oscullo, J. y Haro, L. "Pronóstico de la demanda diaria del sistema nacional interconectado utilizando redes neuronales artificiales", Revista Politécnica, vol. 38, pp. 77 septiembre 2016.
- Barrezueta, J. y Encalada, A." Análisis de factores que afectan a la demanda eléctrica y su estimación. Sector residencial del área de concesión de la empresa CENTRO SUR. C. A.", tesis de grado, Cuenca, 2014.
- Mejía, E. y Gonzales, S. "Predicción del consumo de energía eléctrica residencial de la Región Cajamarca mediante modelos Holt -Winters", Cajamarca, 2019.