

**MÉTODOS UTILIZADOS PARA EL PRONÓSTICO DE DEMANDA DE
ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN**

ADRIANA MARCELA ARIZA RAMÍREZ

UNIVERSIDAD TECNOLÓGICA DE PEREIRA

**FACULTAD DE INGENIERÍAS: ELÉCTRICA, ELECTRÓNICA, FÍSICA Y
CIENCIAS DE LA COMPUTACIÓN**

PROGRAMA DE INGENIERÍA ELÉCTRICA

PEREIRA

2013

**MÉTODOS UTILIZADOS PARA EL PRONÓSTICO DE DEMANDA DE
ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN**

ADRIANA MARCELA ARIZA RAMÍREZ

**Trabajo presentado como proyecto de grado para optar al título de ingeniera
electricista**

Director

Dr. Carlos Julio Zapata Grisales

UNIVERSIDAD TECNOLÓGICA DE PEREIRA

**FACULTAD DE INGENIERÍAS: ELÉCTRICA, ELECTRÓNICA, FÍSICA Y
CIENCIAS DE LA COMPUTACIÓN**

PROGRAMA DE INGENIERÍA ELÉCTRICA

PEREIRA

2013

Nota de aceptación:

Presidente del jurado

Jurado

Jurado

Pereira, 02 de Agosto de 2013

DEDICATORIA

A mi familia, mi gran amor y motivación.
ADRIANA

AGRADECIMIENTOS

Al Todopoderoso, por darme vida, salud y sabiduría para culminar este proyecto.

Al Doctor Carlos Julio Zapata Grisales por su invaluable colaboración a través de sus aportes, comentarios y sugerencias en el desarrollo de este proyecto.

Muy sinceramente le agradezco a quienes fueron mis profesores, por ser el pilar fundamental en el proceso de mi formación como Ingeniera Electricista.

A la Universidad Tecnológica de Pereira, por ser el ente encargado de mi formación académica.

A Darwin Miranda, por su amor y apoyo constante, siendo mi mejor amigo y compañero inseparable.

Agradezco profundamente a mi familia, por ser mi mayor inspiración y razón de ser, por la confianza depositada y su apoyo incondicional.

A todos y cada uno, solo me resta decirles mil gracias, sin ustedes alcanzar esta meta, no hubiese sido posible.

CONTENIDO

	pág.
I. RESUMEN.....	15
II. INTRODUCCIÓN.....	17
III. JUSTIFICACIÓN.....	18
VI. OBJETIVOS	19
V. ABREVIATURAS.....	20
 CAPÍTULO I: PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN: GENERALIDADES.....	 21
1.1 DEMANDA DE ENERGÍA ELÉCTRICA.....	21
1.1.1 Demanda.	21
1.1.2 Demanda o carga máxima.	21
1.1.3 Carga instalada.	21
1.1.4 Capacidad instalada.	21
1.1.5 Demanda diversificada o coincidente.	21
1.1.6 Demanda máxima no coincidente.	22
1.1.7 Curvas de carga diaria.	22
1.1.8 Curvas de carga anual.	22
1.1.9 Factor de demanda.	22
1.1.10 Factor de carga.	22
1.1.11 Factor de potencia.	23
1.1.12 Factor diversidad.	23
1.1.13 Factor de coincidencia.	23
1.2 PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA	24
1.3 IMPORTANCIA DEL PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA	25
1.4 FACTORES QUE INFLUYEN EN EL PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA	26

1.4.1	Factores geográficos.	27
1.4.2	Clima.....	27
1.4.3	Hábitos de consumo.	28
1.4.3.1	Caso colombiano	28
1.4.4	Utilización de terrenos.	29
1.4.5	Planes municipales.	29
1.4.6	Planes Industriales.	30
1.4.7	Planes de Desarrollo Comunitario.	30
1.4.8	Densidad de carga.	30
1.4.9	Crecimiento demográfico.	30
1.4.10	Datos históricos.	30
1.4.11	PIB / Nivel Socioeconómico.	30
1.4.12	Tarifas.	31
1.5	CLASIFICACIÓN DE LOS MÉTODOS DE PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA	31
1.5.1	Según su horizonte de tiempo.	33
1.5.1.1	Pronóstico a corto plazo	33
1.5.1.2	Pronóstico a mediano plazo	33
1.5.1.3	Pronóstico largo plazo	33
1.6	CRITERIOS DE VALIDACIÓN DEL MÉTODO Y ANÁLISIS	34
1.6.1	Error estándar múltiple de la estimación.....	34
1.6.2	Error residual.....	34
1.6.3	MAD (<i>Mean Absolute Deviation</i> – Desviación Media Absoluta.....	34
1.6.4	MSE (<i>Mean Square Error</i> - Error Medio Cuadrático).....	35
1.6.5	MAPE (<i>Mean Absolute Percentage Error</i> - Porcentaje de Error Medio Absoluto).....	35

CAPITULO II: PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO MODELOS DE TENDENCIA	36
---	----

2.1	MÉTODOS DE REGRESIÓN SIMPLE	36
2.1.1	Método de estimación de mínimos cuadrados ordinarios (MCO).	36
2.1.2	Regresión lineal.	37
2.1.3	Regresión Exponencial.	38
2.1.4	Regresión Polinomial.	39
2.1.5	Regresión Potencial.	41
2.1.6	Regresión Logarítmica.	42
2.1.7	Regresión Logística.	43
2.1.8	Regresión Gompertz.	44
2.2	MÉTODO DE REGRESIÓN LINEAL MÚLTIPLE	45
2.2.1	Los supuestos del modelo de regresión lineal.	45
2.2.2	Determinación de los parámetros del modelo.	46
2.2.3	Intervalos de confianza.	48
2.2.4	Principales pruebas.	48
2.2.4.1	Coeficiente de correlación o determinación R^2	48
2.2.4.2	Coeficiente de correlación de Pearson R.	49
2.2.4.3	F: Test Fisher (Prueba de significancia de la regresión).....	50
2.2.4.4	T: t-student (Prueba de significancia de la variable).....	51
2.3	REGRESIÓN MÚLTIPLE UTILIZANDO VARIABLES ECONÓMICAS: MÉTODO ECONOMETRICO.....	52

CAPITULO III: PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO SERIES DE TIEMPO.....55

3.1	MÉTODO DE SERIES TEMPORALES.....	55
3.1.1	Componentes de una serie de tiempo.....	55
3.1.1.1	Tendencia.....	55
3.1.1.2	Fluctuaciones cíclicas.....	56
3.1.1.3	Fluctuaciones estacionarias.....	57
3.1.1.4	Fluctuaciones aleatorias.....	57

3.1.2	Método de descomposición.....	58
3.2	ANÁLISIS DE SERIES TEMPORALES BASADOS EN PROMEDIOS	58
3.2.1	Promedio Simple.....	58
3.2.2	Promedios Móviles.....	59
3.2.3	Promedio móvil doble.....	59
3.2.4	Promedios Móviles Ponderados.....	60
3.3	ANÁLISIS DE SERIES TEMPORALES BASADOS SUAVIZACIÓN EXPONENCIAL.....	61
3.3.1	Suavización Exponencial.....	61
3.3.2	Atenuación exponencial ajustada a la tendencia: Método de Holt.....	62
3.3.3	Atenuación exponencial ajustada a la tendencia y a la variación estacional: Modelo Winter.....	65
3.4	ELABORACIÓN DE LOS MODELOS AR, MA Y ARMA PARA SERIES DE TIEMPO.....	66
3.4.1	Proceso autorregresivo (AR).....	66
3.4.2	Proceso de media móvil (MA).....	66
3.4.3	Proceso autorregresivo y de media móvil (ARMA).....	67
3.4.4	Proceso autorregresivo integrado de media móvil (ARIMA).....	68
3.4.5	Propiedades de las series integradas.....	69
3.4.6	Caracterización Series de tiempo.....	70
3.4.7	Modelos estacionales ARIMA.....	71
3.4.8	Pruebas de estacionariedad.	72
3.4.9	Criterios de validez modelos ARIMA.....	73
3.4.10	Descripción de la metodología Box-Jenkins.....	73
CAPITULO IV: PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO DISTRIBUCIÓN DE PROBABILIDAD.....		74
4.1	DISTRIBUCIÓN DE PROBABILIDAD	74
4.1.1	Método de momentos (MOM).	74
4.1.2	Método estimación de máxima verosimilitud (MLE).	75

4.1.3	Criterios de validación o ajuste.	76
4.1.3.1	Test de Chi cuadrado χ^2	76
4.1.3.2	<i>Test de Kolmogorov–Smirnov</i>	78

CAPITULO V: PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO MICROÁREAS.....81

5.1	MÉTODO DE MICRO ÁREAS	82
5.1.1	Uso de tierra.	82
5.1.1.1	Submodelo de demanda de tierra.	82
5.1.1.2	Submodelo de oferta de tierra.	83
5.1.1.3	Definición de micro áreas.	84
5.1.1.4	Determinación del factor de saturación por microárea.....	84
5.1.1.5	Demanda máxima por microárea.....	87
5.1.2	Tendencia (Demanda de energía eléctrica).	88
5.1.2.1	Modelo de carga.	88
5.1.2.2	Ajuste de tendencia con curva polinómica.....	89
5.1.2.3	Regresión multivariable.....	89
5.1.2.4	Técnica de inferencia de áreas vacías.....	90
5.1.2.5	Transferencia de carga.....	90
5.2	METODOLOGÍA PARA EL PRONÓSTICO DE ENERGÍA ELÉCTRICA UTILIZANDO MICROÁREAS.....	91

CAPITULO VI: PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO REDES NEURONALES ARTIFICIALES.....94

6.1	MÉTODO REDES NEURONALES ARTIFICIALES	94
6.1.1	Elementos de una red neuronal.	94
6.1.1.1	Neurona artificial.	94
6.1.1.3	Estado de activación.	96
6.1.1.2	Unidad de proceso.....	94

6.1.1.4	Conexiones y pesos sinápticos.	96
6.1.1.5	Función de activación.	97
6.1.1.6	Función de salida o transferencia.	100
6.1.1.7	Regla de aprendizaje.	100
6.1.2	Topología de redes neuronales.	100
6.1.2.1	Según la estructura en capas	100
6.1.2.2	Según el flujo de datos en la red	101
6.1.2.3	Según el tipo de respuesta de la red o asociación entrada y salida.....	102
6.1.3	Mecanismo de aprendizaje.	103
6.1.3.1	Supervisado.....	103
6.1.3.2	No supervisado.....	104
6.1.4	Representación de la información.	106
6.1.5	Evolución de redes neuronales artificiales.	106
6.2	PERCEPTRÓN MULTICAPA	106
6.3	PASOS PARA LA IMPLEMENTACIÓN DE REDES NEURONALES EN EL PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA.....	108

CAPITULO VII: IMPLEMENTACIÓN DE LOS MÉTODOS Y ANÁLISIS DE RESULTADOS.....111

7.1	BASE DE DATOS.....	111
7.1.1	Métodos de Tendencia simple.	113
7.1.2	Método de Suavizamiento exponencial y promedios móviles.	118
7.1.3	Método ARIMA.	124
7.1.4	Método distribución de probabilidad. S.....	128
7.1.5	Método Redes Neuronales Artificiales.	131

CAPITULO VIII : VENTAJAS Y DESVENTAJAS DE CADA MÉTODO.....137

ANEXO.....141

BIBLIOGRAFÍA143

LISTA DE TABLAS

	pág.
Tabla 1. Factores de conversión entre unidades de energía	24
Tabla 2. Días Festivos en Colombia	29
Tabla 3. Patrones teóricos de FAC y FACP	68
Tabla 4. Caracterización series de tiempo	68
Tabla 5. Distribución de probabilidad	79
Tabla 6. (Continuación)	80
Tabla 7. Tipos de aprendizaje supervisado	104
Tabla 8. Tipos de aprendizaje no supervisados	106
Tabla 10. Metodología Kaastra-Boyd para pronóstico utilizando Redes Neuronales Artificiales	108
Tabla 9. Evolución de Redes Neuronales Artificiales (RNA)	109
Tabla 11. Demanda de energía eléctrica periodo 200801 a 201104 en una zona de Colombia	111
Tabla 12. Análisis estadístico de los datos de demanda periodo 200801 a 201104	112
Tabla 13. Coeficiente de correlación según el tipo de regresión para la serie de demanda	113
Tabla 14. Error estimado según método utilizado para la serie temporal	120
Tabla 15. Análisis de los Modelos Winter, Holt y Brown	123
Tabla 16. Estimación de Modelos ARIMA para la serie de datos	126
Tabla 17. (Continuación)	127
Tabla 18. Validación de Modelos ARIMA utilizando criterio MSE	127
Tabla 19. Modelos de Distribución de probabilidad para la serie temporal (MATLAB)	128
Tabla 20. Modelos de Distribución de probabilidad para la serie temporal (XLSTAT)	130
Tabla 21. Información de la red neuronal implementada para el pronóstico de energía eléctrica	134
Tabla 22. Simulación de entrenamiento	134
Tabla 23. Resultados de prueba de la red neuronal	135
Tabla 24. Resultados finales	136
Tabla 25. Métodos de pronóstico de demanda ventajas y desventajas	137

LISTA DE FIGURAS

	pág.
Figura 1. Factor de Potencia.....	23
Figura 2. Escenario de demanda de energía final URE según energéticos	25
Figura 3. Factores que influyen en el pronóstico de demanda de energía eléctrica	27
Figura 4. Regresión Lineal	38
Figura 5. Regresión Exponencial.....	39
Figura 6. Regresión Polinomial	40
Figura 7. Regresión Potencial.....	42
Figura 8. Regresión Logarítmica	43
Figura 9. Regresión Logística.....	44
Figura 10. Regresión Gompertz.....	44
Figura 11. Metodología para pronóstico utilizando regresión	54
Figura 12. Característica de componente de tendencia de una serie temporal.....	56
Figura 13. Característica de componente de ciclicidad de una serie temporal	56
Figura 14. Característica de componente de estacionalidad de una serie temporal	57
Figura 15. Característica de componente de aleatoriedad de una serie temporal.....	57
Figura 16. Metodología para Modelos de Suavizamiento Exponencial	65
Figura 17. Diagrama de flujo Metodología Box-Jenkins	73
Figura 18. Distribución Chi cuadrado.....	76
Figura 19. Región de aceptación test Chi Cuadrado.....	77
Figura 20. Procedimiento para ajustar una distribución a un modelo probabilístico a partir de una muestra de datos	81
Figura 21. Submodelo de demanda de suelo- Polos urbanos	83
Figura 22. Curva característica de crecimiento de carga (MWh/año)	84
Figura 24. Esquema de pronóstico global (Espacial y Eléctrico).....	91
Figura 25. Procedimiento para pronósticos utilizando microáreas.....	93
Figura 26. Relación entre una neurona biológica y artificial	95
Figura 27. Función de activación Escalón	97
Figura 28. Función de activación Identidad o Lineal	98
Figura 29. Función de activación Mixta	98
Figura 30. Función de activación Sigmoidal.....	99
Figura 31. Función de activación Tangente hiperbólica	99
Figura 32. Función de activación Gaussiana.....	100
Figura 33. Red Monocapa	101
Figura 34. Red multicapa de propagación hacia adelante.....	102
Figura 35. Red multicapa de propagación hacia atrás (Feedback)	102

Figura 36. Esquema general de un Perceptrón Multicapa.....	107
Figura 37. Metodología para pronóstico utilizando Rede Neuronales Artificiales	110
Figura 38. Curva anual de demanda de energía eléctrica 200801 a 201104.....	112
Figura 39. Demanda de energía eléctrica periodo 200801 al 201104	113
Figura 40. Modelos de tendencia utilizando Excel (Criterio R^2)	115
Figura 41. Modelos de tendencia utilizando Minitab 15 (Criterio MAD, MAPE)	116
Figura 42. Análisis de componentes de la serie	117
Figura 43. Modelo de descomposición para la serie de demanda de energía	117
Figura 44. Modelo de Media Móvil a dos períodos para la serie de demanda.....	118
Figura 45. Modelos de Suavizamiento Exponencial (Simple, Doble, Winter)	119
Figura 46. Modelos Suavizamiento Exponencial (Simple estacional, Brown, Holt)	121
Figura 47. Modelo Winter (Aditivo y Multiplicativo) para la serie temporal.....	122
Figura 48. Función de Autocorrelación de la serie temporal	124
Figura 49. Función de Autocorrelación Parcial de la serie temporal.....	124
Figura 50. FAC y FACP teóricas para ARMA (1,1)	125
Figura 51. Distribución Normal datos teóricos y reales	128
Figura 52. Curva de Distribución Normal vs Serie de demanda	129
Figura 53. Esquema de red neuronal implementada.....	133
Figura 54. Resultado de entrenamiento de la red	135
Figura 55. Resultados de entrenamiento (Modo grafico).....	135
Figura 56. Performance de entrenamiento	136
Figura 57. Correlación del Modelo RNA.....	136

I. RESUMEN

Este trabajo de grado tiene como objeto la presentación de los métodos utilizados para el pronóstico de demanda de energía eléctrica en sistemas de distribución.

En primera instancia se realiza la descripción de cada uno de los métodos, luego se presenta la metodología o procedimiento para su aplicación y posteriormente se hace la implementación de los mismos; para ello se hace uso de los siguientes programas:

- Excel
- Minitab 15
- SPSS 20
- XLSTAT
- MATLAB V2012b

Se hace el modelamiento de la demanda utilizando datos históricos según los métodos expuestos en el texto y los disponibles en cada software. En el caso de MATLAB V2012b se realiza un código que aplica el método de distribución de probabilidad y redes neuronales artificiales.

A partir de los resultados obtenidos se procede a determinar el modelo que mejor se ajusta al comportamiento de la demanda y con el cual es conveniente realizar el pronóstico, para la muestra de datos el modelo que presento mejor ajuste fue el generado por Redes Neuronales Artificiales con un coeficiente de correlación de **0,9985**. Cabe mencionar que los resultados obtenidos son para fines académicos puesto que la base de datos disponible cuenta con 40 registros que corresponde a 3 años y 4 meses, y en la práctica se debe contar, por lo menos, con registros de 10 años para el pronóstico de demanda de energía eléctrica.

ABSTRACT

The main objective of this graduation project is to show the methods used for load forecasting in electrical power distribution systems.

Firstly, it makes a description about each method, and then it presents the methodology or procedure for its application and implementation. For the implementation of these methods were applied the following softwares:

- Excel
- Minitab 15
- SPSS 20
- XLSTAT
- MATLAB V2012b

The load is modeled using historical data according to the methods exposed in this paper and available ones in each software. In case of MATLAB V2012b, it makes a code that applies the probability distribution method and neural networks.

From the results was gotten, it is going to decide about the best load model and which is appropriate to make the forecast, in this case the best model was gotten by neural networks with a correlation coefficient of **0,9985** according database. Since way, these results are for academic purposes because the database has 40 records corresponding to 3 years and 4 months, and in practice the database have too many records around 10 years for the load forecasting.

II. INTRODUCCIÓN

La demanda de electricidad ha aumentado continuamente a lo largo de las últimas décadas tanto en los hogares como en la industria. Dicho incremento obedece al creciente nivel de vida de las sociedades por medio de los avances tecnológicos. Por lo que cada vez es mayor la utilización de electrodomésticos y dispositivos electrónicos entre los que se destacan los de computo y comunicación; como consecuencia se tiene una mayor demanda de energía eléctrica y por consiguiente mayor producción de la misma.

Frente a este panorama es inherente la necesidad de pronóstico de la demanda de energía eléctrica de la manera más acertada, pues dicha predicción puede determinar de forma previa la carencia del sistema de distribución de dicha energía, o si pudiera ser conveniente, la consideración de construcción de nuevas subestaciones o si por el contrario, en el futuro existirá un exceso de capacidad frente a la demanda traduciéndose en pérdidas económicas para la empresa.

El constante desarrollo de los mercados de energía eléctrica genera escenarios cada vez más competitivos, por lo que resulta de crucial importancia poseer sistemas de distribución con planes de manejo bien estructurados, para disponer de sistemas que suministren energía eléctrica de acuerdo a la demanda con el menor número de interrupciones y al menor costo posible, mejorando así la calidad del servicio.

Este trabajo pretende acercar al lector a las técnicas utilizadas en la actualidad en la proyección de demanda de energía eléctrica en nuestro país, teniendo en cuenta que estas son la base para una adecuada planeación de redes de distribución de energía eléctrica. Uno de los propósitos de este trabajo es mostrar que hay diversas formas de establecer un pronóstico de demanda de electricidad, ventajas y desventajas que presentan además de estimar el grado de precisión del pronóstico y que es fundamental conocerlos para poder seleccionar el método más apropiado que contribuya a una acertada toma de decisiones, teniendo en cuenta que errores en los pronósticos representan altos costos económicos para las empresas de energía.

III. JUSTIFICACIÓN

El pronóstico de la demanda de electricidad es una herramienta fundamental para la toma de decisiones operativas y estratégicas en las empresas de energía, cuya falta de precisión puede traer altos costos económicos.

La importancia del pronóstico de demanda de energía eléctrica se incrementa en la medida que el cumplimiento de los objetivos trazados dependan lo menos posible del azar, disminuyendo así la incertidumbre sobre los resultados de las decisiones tomadas. Por esto, es de vital importancia conocer a priori el crecimiento de la demanda de energía eléctrica, de una manera segura y confiable lo cual se aproxime lo más cercano a la realidad. Para esto se requiere de técnicas apropiadas que permitan realizar un buen pronóstico a corto, mediano y largo plazo de la demanda; ya que de esto depende garantizar el suministro de la energía eléctrica.

Con la información proporcionada por el estudio de pronóstico de demanda de energía eléctrica a corto, mediano y largo plazo, los operadores pueden tomar decisiones en despacho óptimo de flujos de carga óptima, programas de mantenimiento, compra de combustible, análisis de la confiabilidad y seguridad de operación. Para el caso de pronóstico a largo plazo es indispensable para construcción y ampliación de nuevas unidades de generación, así como la determinación de los precios y sus políticas de regulación. Por lo tanto un buen estudio de pronóstico de demanda de energía eléctrica, es necesario para la operación económica y segura del sistema.

En las últimas décadas se han dedicado esfuerzos por desarrollar y mejorar los métodos para el pronóstico de la demanda de electricidad. El análisis de dicha información es uno de los objetivos de este trabajo. Existen varias razones que pueden explicar la dificultad de realizar pronósticos acertados de la demanda; entre ellas se cuentan: las complejidades de sus factores determinantes, las características estructurales de los datos, el horizonte de pronóstico y las limitantes propias de las metodologías empleadas. Uno de los objetivos de este trabajo es discutir estas limitantes.

IV. OBJETIVOS

OBJETIVO GENERAL

Describir los métodos utilizados para el pronóstico de demanda de energía eléctrica en sistemas de distribución.

OBJETIVOS ESPECÍFICOS

- Determinar los factores que inciden en el pronóstico de demanda de energía eléctrica.
- Clasificar los métodos de pronóstico de demanda de electricidad según su categoría.
- Enunciar los métodos de pronóstico de demanda de energía eléctrica y su aplicación en corto, mediano o largo plazo en sistemas de distribución.
- Identificar ventajas y desventajas de cada método en mención según su horizonte de tiempo.

V. ABREVIACIONES

UPME	Unidad de Planeamiento Minero Energético
UCP's	Unidades de Control de Pronóstico
CND	Centro Nacional de Despacho
CREG	Comisión de Regulación de Energía y Gas
SEP	Sistema Eléctrico de Potencia
SIN	Sistema Interconectado Nacional
STN	Sistema de Transmisión Nacional
STR	Sistema de Transmisión Regional
SDL	Sistema de Distribución Local
SDR	Sistema de Distribución Regional
OR	Operadores de Red
ENS	Energía No Suministrada
URE	Uso Racional y Eficiente de la energía
kVA	kilo Voltio Amperios, unidad de medida potencia aparente
kWh	kilo Watt hora , valor de carga activa consumida por hora
MWh	Mega Watt hora , valor de carga activa consumida por hora
MEM	Mercado de Energía Mayorista colombiano
MCO	Mínimos Cuadrados Ordinarios
PIB	Producto Interno Bruto
RNA	Red Neuronal Artificial

CAPÍTULO I

PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN: GENERALIDADES

1.1 DEMANDA DE ENERGÍA ELÉCTRICA

1.1.1 Demanda. Es la cantidad de potencia que un consumidor utiliza en un periodo de tiempo. La demanda de una instalación eléctrica en los terminales receptores, es tomada como un valor medio en un intervalo determinado. El período durante el cual se toma el valor medio se denomina intervalo de demanda. La duración que se fije en este intervalo dependerá del valor de demanda que se desee conocer. Para establecer una demanda es indispensable indicar el intervalo de demanda ya que sin él no tendría sentido práctico. La demanda se puede expresar en kVA, kW, kVAR, A, etc.

La variación de la demanda en el tiempo para una carga dada origina el ciclo de carga que es una curva de carga (Demanda vs tiempo). [10], [25]

1.1.2 Demanda o carga máxima. Corresponde a la carga mayor que se presenta en un sistema o instalación en un período de trabajo previamente establecido. Para establecer la demanda máxima se debe especificar el intervalo de demanda para medirla. La carga puede expresarse en p.u de la carga pico del sistema. [10], [25]

1.1.3 Carga instalada. Es la suma de potencias nominales de aparatos y equipos de consumo que se encuentran conectados a un sistema o a parte de él, se expresa generalmente en kVA, MVA, kW o MW. [10]

1.1.4 Capacidad instalada. Corresponde a la suma de las potencias nominales de los equipos (transformadores, generadores), instalados a líneas que suministran la potencia eléctrica a las cargas o servicios conectados. Es llamada también capacidad nominal del sistema. [25]

1.1.5 Demanda diversificada o coincidente. Es la suma de varias cargas en un momento determinado. Se considera el mismo intervalo de tiempo. [10], [25]

$$D_{Div} = \sum_{i=1}^n D_i * t_i \quad (1.1)$$

Donde:

D_i = Demanda de energía eléctrica del usuario

t_i = Periodo en que se registra la demanda

i = Número de usuarios

1.1.6 Demanda máxima no coincidente. Es la suma de la demanda máxima de cada usuario sin importar que ocurran o no al mismo tiempo. [10], [25].

1.1.7 Curvas de carga diaria. Las curvas de carga diaria están formadas por los picos obtenidos en intervalos de una hora para cada hora del día. Las curvas de carga diaria dan una indicación de las características de la carga en el sistema, para el sector residencial, comercial o industrial y de la forma en que se combinan para producir el pico. [25]

1.1.8 Curvas de carga anual. Las curvas de carga anual están formadas por los valores de la demanda a la hora pico en cada mes, permiten una visualización de los crecimientos y variaciones de los picos mensuales y anuales. El análisis de las causas de estas variaciones debe conducir a conclusiones prácticas sobre el comportamiento del sistema y los factores que lo afectan. [25]

1.1.9 Factor de demanda. El factor de demanda en un intervalo de tiempo t , de una carga, es la razón entre la $D_{m\acute{a}x}$ y la carga total instalada. El factor de demanda por lo general es menor que 1. En el caso de máquinas eléctricas recibe el nombre de factor de uso o de utilización. [10], [25]

$$F_{Dem} = \frac{D_{m\acute{a}x}}{\text{Carga instalada}} \leq 1 \quad (1.2)$$


1.1.10 Factor de carga. Es la razón entre la D_{prom} en un intervalo de tiempo dado y la $D_{m\acute{a}x}$ observada en el mismo intervalo de tiempo. [10], [25]

$$F_C = \frac{D_{prom}}{D_{m\acute{a}x}} \quad 0 < F_C \leq 1 \quad (1.3)$$

1.1.11 Factor de potencia. Es la relación entre la potencia activa (W, kW o MW) y la potencia aparente (VA, kVA, MVA), determinada en el sistema o en uno de sus componentes. [25]

$$\cos \theta = \frac{P}{Q} = \frac{\text{Potencia activa}}{\text{Potencia reactiva}} \quad (1.4)$$

Figura 1. Factor de Potencia



La incidencia más importante del factor de potencia es en el porcentaje de pérdidas y en la regulación de voltaje y por lo tanto, en la calidad y economía del servicio eléctrico.

El factor de potencia se corrige mediante la instalación de bancos de condensadores en las acometidas de los usuarios cuyas cargas así lo requieran, o en los circuitos primarios. Es muy importante el correcto cálculo de los kVAR a compensar y la ubicación de los bancos de condensadores dentro del sistema.

1.1.12 Factor diversidad. Es la razón entre la sumatoria de las demandas máximas individuales y la demanda máxima del conjunto o grupo de usuarios (llamada también demanda máxima coincidente). [25]

$$F_{Div} = \frac{\sum D_{M\acute{a}x \text{ individuales}}}{D_{M\acute{a}x \text{ individuales}}} = \frac{D_{M\acute{a}x \text{ no coincidente}}}{D_{M\acute{a}x \text{ coincidente}}} \quad (1.5)$$

1.1.13 Factor de coincidencia. Es la relación entre la demanda máxima coincidente de un grupo de consumidores y la suma de las demandas de potencia máxima de consumidores individuales que conforman el grupo, ambos tomados en el mismo punto de alimentación para el mismo tiempo. [25]

$$F_{co} = \frac{D_{M\acute{a}x \text{ coincidente}}}{\sum D_{M\acute{a}x \text{ individuales}}} = \frac{D_{M\acute{a}x \text{ coincidente}}}{D_{M\acute{a}x \text{ no coincidente}}} \quad (1.6)$$

1.2 PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA

El pronóstico de la demanda de energía eléctrica es un procedimiento sistemático que permite definir cuantitativamente la demanda futura y por ser de vital importancia debe procurarse que dicha información sea lo más exacta posible, sin olvidar la presencia de incertidumbres. Dependiendo del período de tiempo que se adopte en el análisis se podría considerar dentro del pronóstico tres técnicas de predicción: de corto, mediano y largo plazo, todo depende del tipo de análisis a ejecutarse y de la complejidad en la modelación, lo cual será detallado más adelante. Además para satisfacer la carga futura se debe considerar los proyectos de nuevas centrales de generación y redes de transmisión asociadas. Así mismo el pronóstico de demanda puede referirse a la potencia pico, a la energía total demandada o al comportamiento de la curva de carga.

El pronóstico de la demanda de energía eléctrica puede ser de dos formas, energía (utiliza demanda de electricidad en unidades de Wh) y potencia (Demanda eléctrica en unidades de W), usualmente los OR realizan proyecciones de potencia horaria (energía) en el orden de los MWh.

La UPME realiza pronósticos de demanda de energéticos primarios y secundarios, como se describe en la referencia [28], incluyendo en este grupo a los derivados del petróleo, gas natural, carbón, biomasa y electricidad, mostrando curvas de consumo históricas y proyectadas a cierto periodo. Se sabe que cada combustible o derivado del mismo utiliza unidades de medidas específicas por lo que la UPME se vale de factores de conversión entre unidades de energía fijando solo una unidad para los energéticos y así comparar su comportamiento, como se muestra en la **tabla 1**.

Tabla 1. Factores de conversión entre unidades de energía

	btu	toe	boe	kWh	kcal	Gcal	Mtoe	Mbtu	GWh
btu	1	2.51982E-08	1.84703E-07	2.93056E-04	0.2519824	2.51982E-07	2.51982E-14	1.00000E-06	2.93056E-10
toe	3.96853E+07	1	7.330	11.630.0	1.00000E+07	10.000	1.00000E-06	39.685	1.16300E-02
boe	5.41409E+06	1.36426E-01	1	1,586.6	1.36426E+06	1.364	1.36426E-07	5.414	1.58663E-03
kWh	3,412.3	8.59845E-05	6.30267E-04	1	859.8452	8.59845E-04	8.59845E-11	3.41232E-03	1.00000E-06
kcal	3.9685	1.00000E-07	7.33000E-07	1.16300E-03	1	1.00000E-06	1.00000E-13	3.96853E-06	1.16300E-09
Gcal	3.96853E+06	1.00000E-01	7.33000E-01	1,163.0	1,000,000	1	1.00000E-07	3.969	1.16300E-03
Mtoe	3.96853E+13	1.00000E+06	7.33000E+06	1.16300E+10	1.00000E+13	1.00000E+07	1	3.96853E+07	11.630.0
Mbtu	1.00000E+06	2.51982E-02	1.84703E-01	293.0556	251,982	2.51982E-01	2.51982E-08	1	2.93056E-04
GWh	3.41232E+09	85.9845	630.2666	1.00000E+06	8.59845E+08	859.8452	8.59845E-05	3,412.322	1

Fuente: UPME. Proyección de demanda de energía en Colombia. Revisión Octubre de 2010.

Donde:


Btu= Unidad Térmica Británica

Toe= Toneladas equivalente de petróleo

Boe= Barriles equivalentes de petróleo

Cal= Calorías

Figura 2. Escenario de demanda de energía final URE según energéticos



Fuente: UPME. Proyección de demanda de energía en Colombia. Revisión Octubre de 2010.p.68

En la **figura 2** se muestra la proyección de demanda de energéticos en Colombia hasta el año 2030.

1.3 IMPORTANCIA DEL PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA

El objetivo principal del sistema eléctrico de potencia es suministrar el servicio de energía de manera continua, segura y confiable, por esta razón debe adaptarse continuamente a la demanda. Sin embargo, los sistemas eléctricos no son sistemas adaptativos, y para suplir dicha demanda requiere contar con un estimado del valor demandado por dicho sistema para poder realizar las modificaciones y cumplir con las exigencias del servicio.

La determinación de un buen estudio de pronóstico de demanda de energía eléctrica es importante puesto que contribuye a la correcta programación de unidades de generación por parte del CND, el marco regulatorio dispuesto por la CREG le exige a todos los OR del país un pronóstico de energía y potencia horaria, el cual debe ser enviado cada semana al CND para que éste pueda realizar la operación y programación de las unidades de generación que diariamente salen seleccionadas en el despacho económico, con el fin que no se tengan que realizar nuevas programaciones con unidades de generación más costosas

para atender la demanda o, en el caso contrario, prescindir de generaciones programadas, todo ello implicando mayores costos por generación.

Un pronóstico más acertado reduce el riesgo de realizar redespachos donde se deban usar unidades de generación más costosas o, por el contrario, se deba prescindir de generaciones programadas anteriormente. Es por ello que en este documento se analizan los métodos para el pronóstico de demanda a corto, mediano y largo plazo, evaluando sus ventajas y desventajas que permitan a los OR tomar decisiones que puedan prevenir sobrecargas, evitar fallas de los equipos o apagones que implican grandes pérdidas y de esta manera proporcionar un mejor servicio.

La resolución CREG 097 de 2008 [6], establece un esquema de compensaciones cuando ocurren eventos en el STR por ENS (Energía No Suministrada), teniendo en cuenta el porcentaje que esta energía representa frente al pronóstico, colocando topes de 2%. Esto implicaría que el error de pronóstico será definitivo para determinar si a nivel horario se supera el límite de 2%. Por lo tanto, los operadores de red se ven en la necesidad de buscar alternativas de herramientas o modelos que disminuyan las desviaciones del pronóstico y mejoren la calidad del mismo.

Los indicadores están suministrados en promedio mes por cada UCP's y están dados por:

- Pronóstico de buena calidad entre el $\pm 2\%$.
- Pronóstico de mala calidad superior de $\pm 4\%$.

Como consecuencia se tiene la preocupación por parte de los OR al mejoramiento de los pronósticos disminuyendo la desviación entre lo proyectado y la demanda real.

1.4 FACTORES QUE INFLUYEN EN EL PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA

La demanda de energía eléctrica está sujeta a alteraciones debido a un gran número de factores los cuales inciden directamente en su proyección.

En la **figura 3** se hace una breve explicación de los factores que se deben tener en cuenta en la proyección de demanda de energía eléctrica.

Figura 3. Factores que influyen en el pronóstico de demanda de energía eléctrica



Fuente: Basado en GÖNEN, Turan. Electric Power Distribution System Engineering. McGraw-Hill, 1986.

1.4.1 Factores geográficos. Las características de consumo de energía eléctrica de una zona de consumo varían con la temperatura, humedad y velocidad de viento, las cuales son distintas para cada estación del año y zona geográfica donde se encuentre. Todos los factores climáticos afectan la demanda de electricidad pero entre todos la temperatura es el más relevante debido a que los consumidores tienen comportamientos diferentes dependiendo de esta variable, es decir, en ciudades calurosas se incrementa el uso de aire acondicionado, ventiladores y refrigeradores mientras que en ciudades frías existe una mayor utilización de calentadores de agua y calefacción, incrementándose el consumo de electricidad en verano o invierno respectivamente.

1.4.2 Clima. Como antes se ha mencionado los factores climáticos inciden el comportamiento de la demanda de electricidad. Colombia es un país que se encuentra en el trópico por lo que no desarrolla estaciones climáticas, pero su relieve le permite diversas temperaturas.

La causa de mayor variabilidad climática en el país se debe al fenómeno conocido como "el Niño" y su fase opuesta "la Niña".

“El Niño” es un evento de naturaleza marina y atmosférica que consiste en un calentamiento anormal de las aguas superficiales en el pacífico tropical central y oriental frente a las costas del norte de Perú, Ecuador y sur de Colombia, que dependiendo de la intensidad alcanzada puede afectar el clima mundial; este fenómeno se presenta entre cada dos y siete años. [3]

En el caso Colombiano, en general, los períodos lluviosos tienden a atenuarse y el seco a intensificarse. Su duración, en promedio, es de doce meses, aunque han sido registrados fenómenos más cortos (siete meses) y más largos (28 meses) [3]. En consecuencia este fenómeno disminuye los aportes hídricos afectando así la disponibilidad de caudal en las centrales y por consiguiente en la generación de energía eléctrica en el país que principalmente está compuesta por centrales hidroeléctricas. Por ende el Sector eléctrico colombiano debe establecer medidas que permitan mantener el abastecimiento de energía eléctrica en el país, sin incurrir en el riesgo de racionamiento.

“La Niña” se produce como resultado del “enfriamiento de las aguas del Océano Pacífico Tropical. Dicho enfriamiento genera un aumento considerable en las lluvias, especialmente en las regiones Andina y Caribe. Este aumento de capacidad hídrica también repercute el precio spot de energía eléctrica.

1.4.3 Hábitos de consumo. Este factor abarca el comportamiento de la población en cuanto al consumo de electricidad debido a la carencia de cultura de ahorro o consumo eficiente del servicio, frecuencia de utilización de electrodomésticos, dispositivos de cómputo y comunicación principalmente, también incluye las conductas adoptadas por los consumidores en días festivos, laborales, fines de semana, fines de semana con festivos, semana santa o vacaciones.

1.4.3.1 Caso Colombiano. En nuestro país en un año se presentan 18 festivos establecidos por ley en la que se estipula días de descanso remunerados (días de fiesta de carácter civil o religioso) comúnmente es conocida bajo el nombre de Ley Emiliani (Ley 51 de 1983). [5]

Los festivos fijos (**6**) se celebran el día determinado sin importar que día de la semana suceda, los festivo trasladables (**12**) son aquellos que cuando no caen en un día lunes se trasladan al lunes siguiente. En la **tabla 2** Se muestra la descripción de los festivos en Colombia.

Los periodos vacacionales son una variable en consideración, semana santa, semanas de junio y julio, semanas de diciembre y enero, y una semana especial en el mes de octubre.

Tabla 2. Días Festivos en Colombia

FESTIVO	FECHA	TIPO	CLASE	CELEBRACIÓN
1	01 Enero	Religioso	Fijo	Año nuevo/Circuncisión de Jesús
2	01 Mayo	Cívico	Fijo	Día del trabajo
3	20 Julio	Cívico	Fijo	Día de la independencia
4	07 Agosto	Cívico	Fijo	Batalla de Boyacá
5	08 Diciembre	Religioso	Fijo	Inmaculada concepción
6	25 Diciembre	Religioso	Fijo	Navidad
7	06 Enero	Religioso	Trasladable	Reyes Magos
8	19 Marzo	Religioso	Trasladable	San José
9	29 Junio	Religioso	Trasladable	San Pedro y San Pablo
10	15 Agosto	Religioso	Trasladable	Asunción de la Virgen
11	12 Octubre	Cívico	Trasladable	Día de la Raza
12	01 Noviembre	Religioso	Trasladable	Todos los Santos
13	11 Noviembre	Cívico	Trasladable	Independencia de Cartagena
14	Triduo Pascual	Religioso	Trasladable	Jueves Santo
15	Triduo Pascual	Religioso	Trasladable	Viernes Santo
16	39 días después de la Pascua	Religioso	Trasladable	Ascensión de Cristo
17	60 días después de la Pascua	Religioso	Trasladable	Corpus Cristi
18	68 días después de la Pascua	Cívico	Trasladable	Sagrado corazón

Fuente: COLOMBIA. CONGRESO DE LA REPUBLICA. Ley 51. (6, Diciembre, 1983). Por la cual se traslada el descanso remunerado de algunos días festivos. Diario Oficial. Bogotá, D.C., 1983. No. 36.428.

1.4.4 Utilización de terrenos. Este aspecto es importante pues se parte del hecho que al construirse o utilizarse más terrenos entonces habrá un incremento de la demanda de electricidad, en este factor se relacionan los datos de oferta y demanda del suelo para urbanizaciones, parques, avenidas, centros comerciales entre otros y posteriormente se transforma en información de demanda eléctrica, a través de curvas de carga características. Entre los métodos de pronóstico de demanda de energía eléctrica se encuentra, un método que utiliza el uso de la Tierra para determinar la demanda futura de electricidad.

1.4.5 Planes municipales. El consumo de electricidad de una zona está influenciado por estos planes pues en ellos se dispone el plan de ordenamiento territorial de los asentamientos humanos en el municipio, y en este sentido se nota la influencia que estos tienen en el incremento del consumo de la energía eléctrica, esta relación fue antes descrita en el uso de terrenos, también influye la intervención gubernamental en la ampliación del sistema eléctrico existente o creación de nuevas centrales generadoras.

1.4.6 Planes Industriales. La electricidad es el recurso energético más utilizado por la industria en comparación con las demás fuentes de energía como el carbón, el petróleo y sus derivados, etc. Para muchos sectores industriales, la electricidad representa cerca o más del 50% del consumo energético, por ende, el pronóstico de demanda de electricidad debe incluir el comportamiento del sector industrial de una zona o región teniendo en cuenta la puesta en marcha de nuevas plantas industriales y/o la expansión de las ya existentes.

1.4.7 Planes de Desarrollo Comunitario. Los planes de desarrollo comunitario son proyectos originados en la comunidad en pro de la transformación y evolución socioeconómica de la misma, desde esta plataforma se impulsan programas turísticos, creación de empresas, fortalecimiento de infraestructura entre otros y de allí nace la relación intrínseca con el consumo de electricidad que dichos programas propiciarían.

1.4.8 Densidad de carga. Este parámetro nos indica cuánta es la carga por unidad de área. Es frecuentemente útil para medir las necesidades eléctricas de un área determinada. Se puede medir en kVA por metro cuadrado y se define como la carga instalada por unidad de área; el término voltio-amperio por pie cuadrado es usado también al referirse a la densidad de la carga, sin embargo, es limitado a edificios comerciales o plantas industriales. Conociendo la densidad de carga y el área de la sección en estudio, se puede conocer el valor de la carga instalada. [10], [14]

1.4.9 Crecimiento demográfico. En la medida en que aumenta la población, se incrementa el número de consumidores de electricidad quienes requieren del uso de la misma para sus electrodomésticos y dispositivos electrónicos. Además, este crecimiento demográfico incide en el aumento de fabricación de productos en general, para satisfacer la demanda de los mismos y en esta misma relación se incrementa el consumo de energía eléctrica dado que estos precisan mayoritariamente de este recurso en su proceso de elaboración.

1.4.10 Datos históricos. La información histórica es de vital importancia en la proyección de demanda de electricidad pues con estos podemos generar patrones de consumo, analizar su comportamiento año tras año y proyectarlo al futuro.

1.4.11 PIB / Nivel Socioeconómico. Existe una relación positiva entre PIB y el consumo de electricidad, esta relación se debe no solamente a que el crecimiento del PIB induce a un aumento en la demanda de electricidad, al incrementarse el equipamiento de los hogares, aumentando la cantidad de electrodomésticos, dispositivos electrónicos y la frecuencia de utilización de los mismos.[9]

El crecimiento económico implica un mayor nivel de producción industrial con el fin de satisfacer la demanda de los consumidores de bienes o servicios. En este caso el “efecto multiplicador” se refiere al hecho que la demanda de bienes o servicios por el sector eléctrico a otros sectores impulsa a su vez la demanda de bienes y servicios por las empresas de estos otros sectores.

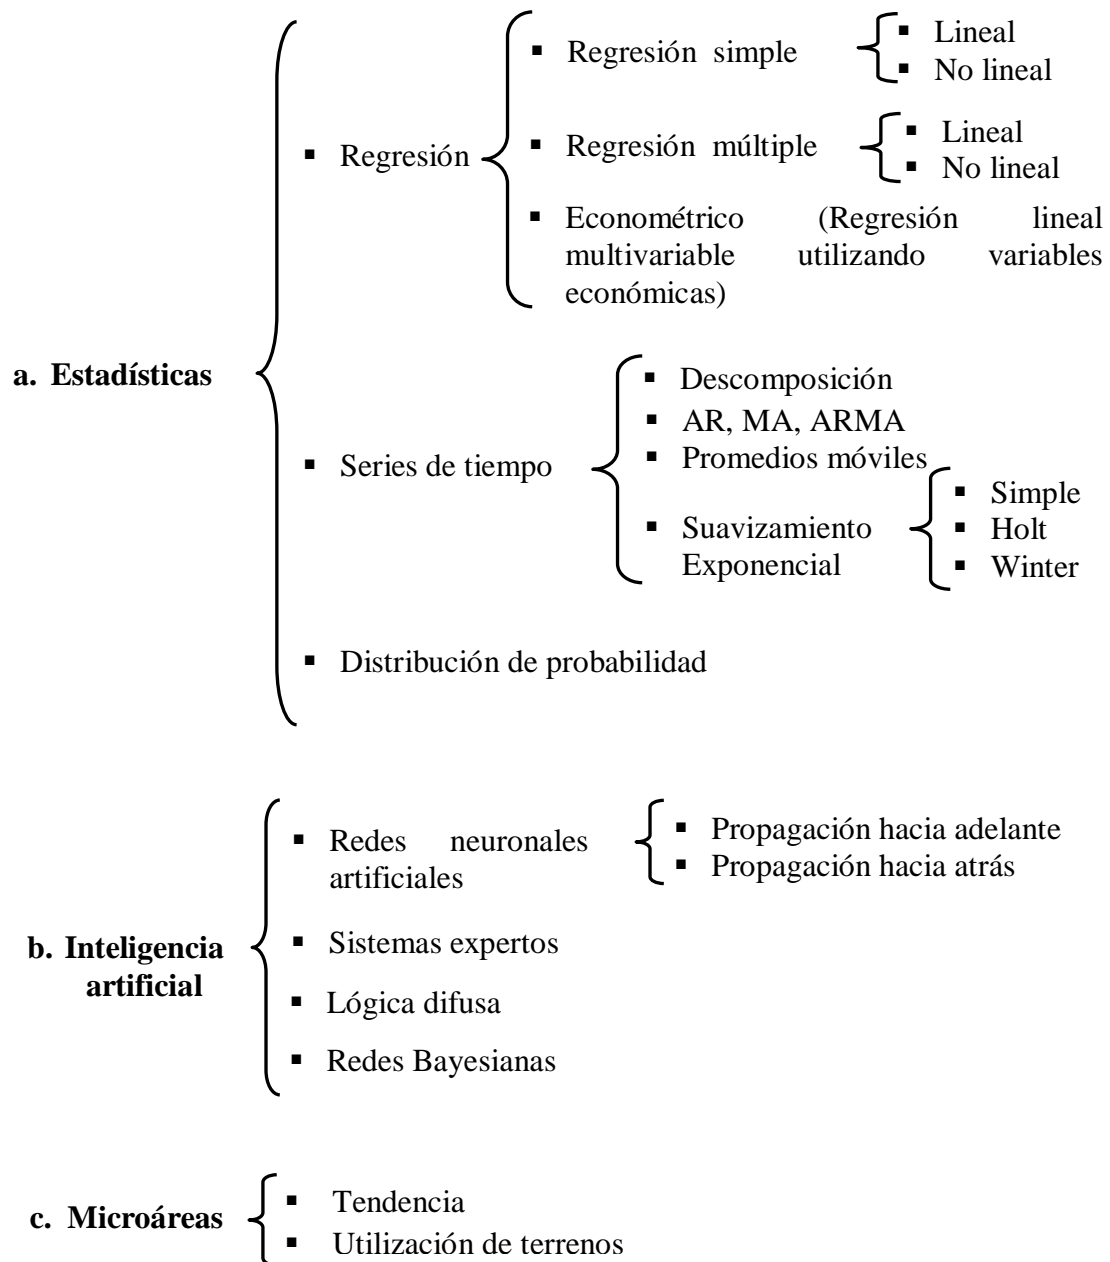
1.4.12 Tarifas. Para los usuarios regulados o residenciales este factor es indiferente puesto que el consumo es del orden de los cientos de kWh y están obligados a pagar la energía según la tarifa dispuesta por la empresa de energía y regulada por la CREG, caso contrario sucede con los usuarios no regulados que por el hecho de tener una demanda promedio mensual de potencia mayor a 0.1 MW, o en energía de 55 MWh-mes en promedio durante los últimos 6 meses puede negociar libremente la tarifa de suministro de electricidad con el comercializador que desee dichas tarifas no están reguladas por la CREG sino que son acordadas mediante un proceso de negociación entre el consumidor y el comercializador. [7], [9], [14].

1.5 CLASIFICACIÓN DE LOS MÉTODOS DE PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA

1. Horizonte de tiempo
 - Corto plazo
 - Mediano plazo
 - Largo plazo

2. Tipo de demanda eléctrica
 - Energía (Wh)
 - Potencia (W)

3. Técnicas matemáticas
 - a. Estadísticas
 - b. Inteligencia artificial
 - c. Microáreas



Cabe mencionar que el pronóstico de demanda de energía eléctrica puede realizarse a partir de:

- Usuarios (Residencial, Comercial e Industrial)
- Transformador
- Circuito primario
- Subestación
- Zonas
- Sistema

1.5.1 Según su horizonte de tiempo. El pronóstico de demanda de energía eléctrica según su horizonte de tiempo se clasifica en corto, mediano y largo plazo, se dispone de esta manera de acuerdo a su aplicación en la operación de las unidades de generación y el despacho económico, planeación del uso de energéticos y programación del mantenimiento de redes entre otras.[4], [14], [18].

1.5.1.1 Pronóstico a corto plazo. Previsión de carga futura en tiempo real para la hora siguiente y con un horizonte de hasta una semana; el pronóstico se basa en los datos históricos de demanda diaria y factores climáticos.

Este tipo de pronóstico es requerido por los encargados de planificar la operación diaria de unidades de generación tal como lo dispone la CREG. Estos pronósticos consisten en proporcionar la demanda de energía eléctrica del sistema sobre un intervalo de horas, días y la semana.

Como antes se ha mencionado el comportamiento del consumo de la electricidad se ve afectado por diversos factores en este tipo de pronóstico las variaciones de las condiciones meteorológicas, tarifas y hábitos de consumo son las más influyentes, cabe decir que la relación entre la demanda y la temperatura es más estrecha que las demás; Por lo que la carga máxima diaria ocurre normalmente alrededor de la temperatura máxima o mínima dependiendo si la energía se requiere para refrescar o calentar. Con lo que se puede decir que la curva diaria de la demanda sigue normalmente el perfil de temperatura diaria. [14]

1.5.1.2 Pronóstico a mediano plazo. Corresponde al pronóstico mensual con un horizonte de hasta un año, se establece a partir de la demanda histórica de electricidad y la predicción de algunas variables explicativas como el crecimiento de la economía, variaciones en el clima, períodos vacacionales adición de nuevas cargas y los patrones de demanda de clientes no regulados.

Con el pronóstico de la demanda de energía eléctrica a mediano plazo, también se pronostican los energéticos que son necesarios para mantener la demanda futura, además de proporcionar elementos para llevar a cabo programas de mantenimiento de redes y equipos, planear el consumo de combustible requerido por las diversas unidades y coordinación adecuada de los recursos hidráulicos de las centrales generadoras. [14]

1.5.1.3 Pronóstico largo plazo. Abarca un horizonte de uno hasta diez años; la predicción de la demanda en el largo plazo es usada para la planeación y expansión de la generación y de la transmisión.

El pronóstico de la demanda a largo plazo es de gran importancia para la planeación de la creación de nuevas plantas de generación, líneas de transmisión subestaciones, redes de distribución, además del consumo de combustibles que se tendrá a largo plazo y de la valoración de los costos de producción de la energía eléctrica. Este estudio es clave para llevar a cabo la interconexión con otros sistemas de potencia. [14]

Este pronóstico está influenciado por muchos más factores aparte de las condiciones meteorológicas. En este horizonte es importante la inclusión del comportamiento del PIB, crecimiento demográfico, planes municipales, industriales y desarrollo comunitario así como la utilización de terrenos.

1.6 CRITERIOS DE VALIDACIÓN DEL MÉTODO Y ANÁLISIS

1.6.1 Error estándar múltiple de la estimación. Es una medida de dispersión de la estimación se hace más precisa conforme el grado de dispersión alrededor del plano de regresión se hace más pequeño como se detalla en [8]. Para medirla se utiliza la formula:

$$S_e = \sqrt{\frac{\sum_{t=1}^n (Y_t - \hat{Y}_t)^2}{(n - k - 1)}} \quad (1.7)$$

Donde:

Y_t = Es el valor observado de Y en los datos

\hat{Y}_t = Es el valor estimado de Y de la ecuación de regresión

n = Número de datos

k = Número de variables independientes X

1.6.2 Error residual. Se define error residual como la diferencia entre el valor del pronosticado y lo que realmente ocurrió en dicho período. A partir del concepto que la demanda tiene un componente aleatorio, todos los pronósticos contienen con certeza algún error.[1],[4], [8]

$$e_i = Y_t - \hat{Y}_t \quad (1.8)$$

Donde:

Y_t = La demanda real u observada en el período t

\hat{Y}_t = Demanda pronosticada para el período t

1.6.3 MAD (Mean Absolute Deviation – Desviación Media Absoluta). Es una medida del error global del pronóstico para un modelo, esta se calcula al sumar los valores absolutos de los errores individuales del pronóstico, y dividiéndolos entre el número de

periodos, esta información resulta de gran utilidad cuando se desea medir el error de pronóstico en las mismas unidades de la serie original. [1],[4], [8]

$$\mathbf{MAD} = \frac{\sum_{t=1}^n |\mathbf{Y}_t - \hat{\mathbf{Y}}_t|}{\mathbf{n}} \quad (1.9)$$

Donde:

\mathbf{Y}_t = La demanda real u observada en el período t

$\hat{\mathbf{Y}}_t$ = Demanda pronosticada para el período t

\mathbf{n} = Número de periodos

1.6.4 MSE (*Mean Square Error - Error Medio Cuadrático*). Cada error o residual se eleva al cuadrado; luego, estos valores se suman y se divide entre el mismo número de observaciones. Este enfoque penaliza los errores mayores de pronóstico ya que eleva cada uno al cuadrado. Esto es importante pues en ocasiones pudiera ser preferible una técnica que produzca errores moderados a otra que por lo regular tenga errores pequeños, pero que ocasionalmente arroje algunos en extremo grandes. Idealmente, se desea que el resultado del EMC sea 0, lo que indicaría un pronóstico perfecto. En general, mientras más pequeño sea el valor de EMC, mejor es el modelo de pronóstico. [1],[4], [8]

$$\mathbf{MSE} = \frac{\sum_{t=1}^n (\mathbf{Y}_t - \hat{\mathbf{Y}}_t)^2}{\mathbf{n}} \quad (1.10)$$

1.6.5 MAPE (*Mean Absolute Percentage Error- Porcentaje de Error Medio Absoluto*). En ocasiones, resulta más útil calcular los errores de pronóstico en términos de porcentaje y no en cantidades. El Porcentaje de Error Medio Absoluto (PEMA) se calcula encontrando el error absoluto en cada período, dividiendo éste entre el valor real observado para ese período y después promediando estos errores absolutos de porcentaje. Este enfoque es útil cuando el tamaño o magnitud de la variable de pronóstico es importante en la evaluación de la precisión del pronóstico. El PEMA proporciona una indicación de qué tan grandes son los errores de pronóstico comparados con los valores reales de la serie. También se puede utilizar el PEMA para comparar la precisión de la misma u otra técnica sobre dos series completamente diferentes. [1],[4], [8]

$$\mathbf{MAPE} = \frac{\sum_{t=1}^n \frac{|\mathbf{Y}_t - \hat{\mathbf{Y}}_t|}{\mathbf{Y}_t}}{\mathbf{n}} \quad (1.11)$$

CAPITULO II

PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO REGRESIÓN

2.1 MÉTODOS DE REGRESIÓN SIMPLE

Los modelos o métodos de regresión son una función matemática que intenta modelar probabilísticamente a una variable de estudio en relación a uno o más predictores de interés.

En el método de regresión simple hay solo una variable independiente y dependiente, donde se puede emplear el conocimiento de la variable independiente para pronosticar la variable dependiente.

2.1.1 Método de estimación de mínimos cuadrados ordinarios (MCO). El criterio de este método consiste en proporcionar estimadores de los parámetros que minimicen la suma de los cuadrados de los errores. Operativamente el proceso es construir una función objetivo en términos de la suma de los cuadrados de los errores y mediante optimización (condiciones de primer orden (C.P.O)) y condiciones de segundo orden (C.S.O)) obtener las fórmulas de cálculo de los estimadores.

Debido a que la función de regresión poblacional no se puede observar directamente, los estimadores de mínimos cuadrados ordinarios se obtienen a partir de la función de regresión muestral (FRM). [8], [26]

Propiedades de los estimadores MCO.

1. Linealidad

La forma funcional que liga al verdadero valor del parámetro y al estimador es lineal.

$$\hat{\beta} = \beta + ke \quad (2.1)$$

El error cometido en la estimación es exclusivamente una porción fija “k” del error cometido en la especificación del modelo. Las propiedades del estimador serán una función lineal de las propiedades de la perturbación aleatoria.

2. Insensatez

El valor más probable del estimador coincide con el verdadero valor del parámetro.

$$E|\hat{\beta}| = \beta \quad (2.2)$$

3. Eficiencia

La desviación entre el verdadero valor del parámetro estimado y el valor del estimador será la menor posible.

4. Consistencia

La diferencia entre el valor estimado del parámetro y el real se anula para una muestra infinita.

$$\lim_{n \rightarrow \infty} \hat{\beta} = \beta \quad (2.3)$$

2.1.2 Regresión lineal. Una línea recta es el modelo gráfico más sencillo para relacionar una variable dependiente con una sola variable independiente. Este método consiste en encontrar la ecuación de la recta que mejor se ajuste al conjunto de puntos de datos XY, es decir, calcula la suma de las distancias al cuadrado entre los puntos reales y los puntos definidos por la recta estimada a partir de las variables introducidas en el modelo, de forma que la mejor estimación será la que minimice estas distancias. A esta línea se le conoce como la línea de regresión, como se describe en [1], [4], [26]. La ecuación que describe esta línea recta es la siguiente forma:

$$Y = b_0 + bX + \varepsilon \quad (2.4)$$

Donde:

b_0 , Intersección en eje Y cuando **$X = 0$**

b , Pendiente de la recta, representa la cantidad de cambio en Y al incrementar X en una unidad

ε , Diferencia entre el valor real y el valor estimado o pronosticado

El método empleado para determinar los valores de **b_0** y **b** se conoce como **Método de Mínimos cuadrados**, este encuentra la mejor relación lineal entre variable independiente y dependiente.

El cálculo de estos coeficientes se realiza así:

$$Y_i = \hat{b}_0 + \hat{b}X_i + \varepsilon_i \quad (2.5)$$

$$Y_i = \hat{Y}_i + \varepsilon_i \quad (2.6)$$

La suma del cuadrado de los errores puede expresarse como sigue:

$$\sum \varepsilon_i^2 = \sum (Y_i - \hat{Y}_i)^2 = \sum (Y_i - \hat{b}_0 - \hat{b}X_i)^2 \quad (2.7)$$

$$\min \sum \epsilon_i^2 = \min \sum (Y_i - \hat{b}_0 - \hat{b}X_i)^2 \quad (2.8)$$

$$E = \sum (Y_i - \hat{b}_0 - \hat{b}X_i)^2 \quad (2.9)$$

$$\frac{\partial E}{\partial \hat{b}_0} = 0 \quad \frac{\partial E}{\partial \hat{b}} = 0 \quad (2.10)$$


Se deriva la anterior expresión con respecto a \hat{b}_0 y \hat{b} y se iguala a cero respectivamente, se resuelven las ecuaciones y se encuentran los estimadores de los parámetros de la regresión:

$$\hat{b} = \frac{n(\sum_{i=1}^n X_i Y_i) - (\sum_{i=1}^n X_i)(\sum_{i=1}^n Y_i)}{n(\sum_{i=1}^n X_i^2) - (\sum_{i=1}^n X_i)^2} \quad (2.11)$$

$$\hat{b}_0 = \frac{(\sum_{i=1}^n Y_i) - \hat{b}(\sum_{i=1}^n X_i)}{n} \quad (2.12)$$

Error residual = Valor observado - Valor pronosticado


Figura 4. Regresión Lineal



2.1.3 Regresión Exponencial. Este tipo de regresión tiene como ecuación característica descrita en las referencias [1], [4], [26]:

$$y = a \cdot e^{bx} \quad (2.13)$$

Figura 5. Regresión Exponencial



Esta expresión no es lineal pero es linealizable tomando logaritmos y aplicando sus propiedades como se plantea a continuación:

$$\ln y = \ln(a \cdot e^{bx}) \quad (2.14)$$

$$\ln y = \ln a + \ln e^{bx} \quad (2.15)$$

$$\ln y = \ln a + bx \ln e \quad (2.16)$$

$$\ln y = \ln a + bx \quad (2.17)$$

Como resultado se tiene $\ln y$ como una función lineal de x .

Donde:

b , Pendiente

$\ln a$, Intersección

$$\ln y = y' \quad (2.18)$$


$$\ln a = a' \quad (2.19)$$

$$y' = a' + bx, \quad \text{Ecuación linealizada} \quad (2.20)$$

2.1.4 Regresión Polinomial. Este tipo de regresión se representa así detallado en [1], [4], [26]:

$$\hat{Y} = b_0 + b_1X + b_2X^2 + \dots + b_mX^m = \sum_{i=0}^n b_iX_i \quad (2.21)$$

Figura 6. Regresión Polinomial



Describe la relación que existe entre la variable independiente **X** y dependiente **y**, dicha relación no es lineal, es de grado **m**.

El problema estriba en la determinación de los coeficientes **b₀, b₁, b₂, ..., b_m** por lo que se procede de la siguiente forma:

$$E = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \quad (2.22)$$

$$E = \sum_{i=1}^n (Y_i - b_0 - b_1 X - b_2 X^2 - \dots - b_m X^m)^2 \quad (2.23)$$

$$\frac{\partial E}{\partial b_i} = 0 \quad (2.24)$$

Las **(m + 1)** ecuaciones con **(m + 1)** incógnitas resultantes son:

$$\sum_{i=1}^n Y_i = nb_0 + b_1 \sum_{i=1}^n X_i + b_2 \sum_{i=1}^n X_i^2 + \dots + b_m \sum_{i=1}^n X_i^m \quad (2.25)$$

$$\sum_{i=1}^n Y_i X_i = b_0 \sum_{i=1}^n X_i + b_1 \sum_{i=1}^n X_i^2 + b_2 \sum_{i=1}^n X_i^3 + \dots + b_m \sum_{i=1}^n X_i^{m+1} \quad (2.26)$$

⋮

$$\begin{aligned} \sum_{i=1}^n Y_i X_i^{k-1} &= b_0 \sum_{i=1}^n X_i^{k-1} + b_1 \sum_{i=1}^n X_i^k + b_2 \sum_{i=1}^n X_i^{k+1} + \dots \\ &+ b_m \sum_{i=1}^n X_i^{k+m+1} \end{aligned} \quad (2.27)$$

$$\sum_{i=1}^n Y_i X_i^m = b_0 \sum_{i=1}^n X_i^m + b_1 \sum_{i=1}^n X_i^{m+1} + b_2 \sum_{i=1}^n X_i^{m+2} + \dots + b_m \sum_{i=1}^n X_i^{2m} \quad (2.28)$$

Las cuales deberán ser resueltas por cualquier método para ecuaciones algebraicas lineales para obtener los coeficientes $b_0, b_1, b_2, \dots, b_m$.

$$\begin{bmatrix} \sum_{i=1}^n X_i^0 & \sum_{i=1}^n X_i^1 & \sum_{i=1}^n X_i^2 & \dots & \sum_{i=1}^n X_i^m \\ \sum_{i=1}^n X_i^1 & \sum_{i=1}^n X_i^2 & \sum_{i=1}^n X_i^3 & \dots & \sum_{i=1}^n X_i^{m+1} \\ \sum_{i=1}^n X_i^2 & \sum_{i=1}^n X_i^3 & \sum_{i=1}^n X_i^4 & \dots & \sum_{i=1}^n X_i^{m+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n X_i^m & \sum_{i=1}^n X_i^{m+1} & \sum_{i=1}^n X_i^{m+2} & \dots & \sum_{i=1}^n X_i^{2m} \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n Y_i X_i^0 \\ \sum_{i=1}^n Y_i X_i^1 \\ \sum_{i=1}^n Y_i X_i^2 \\ \vdots \\ \sum_{i=1}^n Y_i X_i^m \end{bmatrix}$$

$$\sum_{i=1}^n X_i^0 = n \quad (2.29)$$


Por otra parte el error de regresión esta dado por la expresión:

$$E_{Y/X} = \sqrt{\frac{E}{n - (m + 1)}} \quad (2.30)$$

2.1.5 Regresión Potencial. El modelo potencial utilizado para el pronóstico de demanda está dado por la siguiente expresión matemática y puede ser consultado en [1], [4], [26]:

$$y = a \cdot X^b \quad (2.31)$$

Figura 7. Regresión Potencial



Tomando logaritmos a ambos lados y aplicando propiedades se tiene que:

$$\log y = \log(a \cdot X^b) \quad (2.32)$$

$$\log y = b \cdot \log x + \log a \quad (2.33)$$

Si **D = log y** (eje vertical)

Y **D = log x** (eje horizontal) se tiene que,

$$D = b \cdot X + \log a \quad (2.34)$$

Donde:

b= Pendiente de la recta

log a = Coeficiente de posición de la recta

D= Pronóstico de demanda de energía


X= Curva de demanda tipificada

El modelo potencial es ideal para el tipo de gráficas que tienen un pequeño comportamiento curvo, aproximando a través de rectas. Este modelo hay que llevarlo a la forma de una ecuación lineal (**y = a · X + b**) con el fin de usar el método de mínimos cuadrados para encontrar su respectiva ecuación.

2.1.6 Regresión Logarítmica. Muchas relaciones entre variables no siguen un modelo exponencial, en su lugar la variable independiente se relaciona con la variable dependiente mediante un modelo logarítmico, desarrollado en las referencias [1], [4], [26]; dicho modelo esta descrito por esta expresión:

$$y = b + a \ln x \quad (2.35)$$

Figura 8. Regresión Logarítmica



Esta curva es muy útil cuando el índice de cambios de los datos aumenta o disminuye rápidamente y después se estabiliza. Esta línea de tendencia puede tomar valores positivos o negativos.

2.1.7 Regresión Logística. El modelo de crecimiento logístico es una función exponencial donde el crecimiento de la variable dependiente está limitado como lo es el crecimiento demográfico, recursos no renovables, ventas de un bien o servicio entre otras. Detallado en las referencias [1], [4], [26]. El modelo de crecimiento logístico de la variable y con respecto al tiempo obedece la siguiente ecuación:

$$Y(t) = \frac{c}{1 + ae^{-bt}} \quad (2.36)$$


Donde:

a, b, c , Constantes con $c > 0$ y $b > 0$

c , Capacidad de mantenimiento

$$\lim_{t \rightarrow \infty} Y(t) = c \quad (2.37)$$

Figura 9. Regresión Logística




2.1.8 Regresión Gompertz. Se utiliza para estudiar el comportamiento de crecimiento de poblaciones, entre las distintas formulaciones que tiene la curva de Gompertz la más sencilla es:

$$y(t) = e^{a-be^{ct}} \quad \text{Donde } a, b > 0 \quad ; \quad 0 < c < 1 \quad (2.38)$$

$$\text{Para } x = 0 \quad \text{entonces} \quad y = e^{a-b} (\text{Umbral}) \quad (2.39)$$

Figura 10. Regresión Gompertz



Las curvas logística y Gompertz son conocidas por su forma de S y presentan un punto de inflexión donde la curva cambia su forma cóncava por la convexa. Estas dos curvas tienen un patrón de crecimiento similar, la principal diferencia entre ellas reside en la localización del punto de inflexión; las curvas Gompertz alcanzan este punto en la primera parte del ciclo de crecimiento (35% o 40% del crecimiento total) mientras que la curva logística alcanza ese punto en la mitad del ciclo. [1], [4], [26]

El ajuste de las curvas es determinado por el coeficiente de correlación que se describe en el numeral [2.2.4.1.](#)

2.2 MÉTODO DE REGRESIÓN LINEAL MÚLTIPLE

Como antes se ha mencionado el pronóstico de la demanda de electricidad considera no solo valores observados de demanda de energía eléctrica durante un periodo de tiempo, sino también considera los factores que influyen en la variación de dicha demanda, es decir, temperatura, crecimiento demográfico, humedad entre otras, el método de regresión múltiple permite agregar con mucha facilidad la consideración de los factores ambientales. [1], [4], [8]

Este método presenta como variable independiente al tiempo, pero determina la demanda futura extrapolando la tendencia de la información pasada. El modelo de regresión lineal empleado es de la siguiente forma:

$$Y_t = B_0 + B_1 X_{t1} + B_2 X_{t2} + \dots + B_n X_{tn} + \varepsilon_t \quad (2.40)$$

$$Y_t = B_0 + \sum_{i=1}^n B_i X_{ti} + \varepsilon_t \quad (2.41)$$

Donde,

Y_t = Demanda pronosticada en el período t

X_{ti} = Factores que influyen en la demanda

ε_t = Todos los factores que no consideran las variables independientes

B_0 y B_i = Parámetros desconocidos de las variables dependientes

2.2.1 Los supuestos del modelo de regresión lineal.

- $E(u_i|X_i) = 0$, la medida de los errores es igual a cero para cada valor de X_i .
- $Cov(u_i, u_j) = 0$, los errores no están correlacionados, son independientes.
- $Var(u_i|X_i) = \sigma^2$, la varianza o dispersión de los errores es constante.
- $Cov(u_i, X_j) = 0$, errores no correlacionados con la variable explicatoria X.
- $u_i \sim N(0, \sigma^2)$, los errores presentan una distribución normal.

2.2.2 Determinación de los parámetros del modelo. Los parámetros B_0, B_1, \dots, B_p son desconocidos y serán estimados, usando la muestra de datos disponible. Se aplica el método de mínimos cuadrados (MCO) para la estimación. [1], [4], [8]

Los estimadores de mínimos cuadrados ordinarios se obtienen a partir de la función de regresión muestral (FRM), expresada así:

$$Y_t = \hat{\beta}_0 + \sum_{i=1}^p \hat{\beta}_i X_{ti} + e_t \quad (2.42)$$

Donde:

Y_t = Variable dependiente a pronosticar en periodo t

$\hat{\beta}_0$ y $\hat{\beta}_i$ = Estimadores muestrales

X_{ti} = Variables independientes

e_t = Perturbación o error de estimación

$$Y_t = \hat{Y}_t + e_t \quad (2.43)$$

Donde:

Y_t = Variable dependiente observada en el período t o real

\hat{Y}_t = Estimación de la variable dependiente o valor calculado

La suma del cuadrado de los errores puede expresarse como sigue:

$$\sum_{t=1}^n e_t^2 = \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 = \sum_{t=1}^n (Y_t - \hat{\beta}_0 - \hat{\beta}_i X_{ti})^2 \quad (2.44)$$

De acuerdo con el principio de mínimos cuadrados ordinarios:

$$\min \sum_{t=1}^n e_t^2 = \min \sum_{t=1}^n (Y_t - \hat{\beta}_0 - \hat{\beta}_i X_{ti})^2 \quad (2.45)$$

Derivando la anterior expresión con respecto a $\hat{\beta}_0$ y $\hat{\beta}_i$ e igualando a cero, respectivamente:

$$\begin{bmatrix} n & \sum_{t=1}^n X_{t1} & \sum_{t=1}^n X_{t2} & \cdots & \sum_{t=1}^n X_{tn} \\ \sum_{t=1}^n X_{t1} & \sum_{t=1}^n X_{t1}^2 & \sum_{t=1}^n X_{t1}X_{t2} & \cdots & \sum_{t=1}^n X_{t1}X_{tn} \\ \sum_{t=1}^n X_{t2} & \sum_{t=1}^n X_{t2}X_{t1} & \sum_{t=1}^n X_{t2}^2 & \cdots & \sum_{t=1}^n X_{t2}X_{tn} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{t=1}^n X_{tn} & \sum_{t=1}^n X_{tn}X_{t1} & \sum_{t=1}^n X_{tn}X_{t2} & \cdots & \sum_{t=1}^n X_{tn}^2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_n \end{bmatrix} = \begin{bmatrix} \sum_{t=1}^n Y_t \\ \sum_{t=1}^n Y_t X_{t1} \\ \sum_{t=1}^n Y_t X_{t2} \\ \vdots \\ \sum_{t=1}^n Y_t X_{tn} \end{bmatrix}$$

Resolviendo las ecuaciones normales, se encuentran los estimadores de los parámetros de la regresión:

$$\hat{\beta}_i = \frac{n \sum_{i=1}^n X_i Y_i - (\sum_{i=1}^n X_i)(\sum_{i=1}^n Y_i)}{n \sum_{i=1}^n X_i^2 - (\sum_{i=1}^n X_i)^2} = \frac{\widehat{\text{Cov}}(X, Y)}{\widehat{\text{Var}}(X)} \quad (2.46)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_i \bar{X} \quad (2.47)$$

La varianza en los estimadores indica la confiabilidad de las estimaciones (si son pequeñas dejan ver que los parámetros muestrales van a ser muy parecidos a los poblacionales) y es la medida del error estándar.

$$\text{Var}(\hat{\beta}_0) = \frac{\sum_{i=1}^n X_i^2}{n \sum_{i=1}^n (X_i - \bar{X})^2} \sigma^2 \quad (2.48)$$

$$\text{Var}(\hat{\beta}_i) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \quad (2.49)$$

$$\text{se}(\hat{\beta}_0) = \sqrt{\left[\frac{\sum_{i=1}^n X_i^2}{n \sum_{i=1}^n (X_i - \bar{X})^2} \right]} \sigma \quad (2.50)$$

$$\text{se}(\hat{\beta}_i) = \frac{\sigma}{\sqrt{n \sum_{i=1}^n (X_i - \bar{X})^2}} \quad (2.51)$$

2.2.3 Intervalos de confianza. Un intervalo de confianza para el parámetro $\beta_k, \forall k = 1, 2, \dots, K$, tiene la forma:

$$\Pr[\hat{\beta}_k - t_{\alpha/2} \text{se}(\hat{\beta}_k) \leq \beta_k \leq \hat{\beta}_k + t_{\alpha/2} \text{se}(\hat{\beta}_k)] = 1 - \alpha \quad (2.52)$$

$$\hat{\beta}_k \pm t_{\alpha/2} \text{se}(\hat{\beta}_k) \quad (2.53)$$

Donde α es el nivel de significancia estadística y $\text{se}(\hat{\beta}_k)$ es el error estándar de $\hat{\beta}_k$.

2.2.4 Principales pruebas. Son útiles para evaluar la ecuación de regresión integralmente y su confiabilidad. [1], [4], [8]

2.2.4.1 Coeficiente de correlación o determinación R^2 . Mide el porcentaje del cambio de una variable dependiente explicado por el cambio de las variables independientes, a través de un modelo de regresión lineal múltiple. Entre más cercano a uno mejor es el ajuste. Descrito en mejor detalle en las referencias [1], [4], [8]. El coeficiente de determinación se calcula así:

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} \quad (2.54)$$

Donde:

Y_i = Valor observado

\bar{Y} = Media

\hat{Y}_i = Valor estimado en la regresión

Toma el mismo valor cuando usamos a X para predecir a Y o cuando usamos a Y para predecir X.

Criterios de aceptación.

1. El grado de ajuste de una función es aceptable cuando $R^2 \geq 0,8$
2. Sí varias funciones cumplen con esta condición se elige la que se acerca más a 1.

2.2.4.2 Coeficiente de correlación de Pearson R. El coeficiente de correlación da una señal de la fuerza de la relación entre dos variables y su valor es reportado con los resultados de regresión [1], [4], [8]. El puede ser interpretado como la proporción de la

variación en la variable dependiente, Y, que es explicado por la variación en la variable independiente, X. El valor será de -1 a +1, con el mismo signo que la pendiente. Mientras los valores se acerquen a 1 (positivo o negativo) se podrá decir que la correlación es más fuerte, positivamente relacionado hacia 1 o inversamente proporcional en dirección a -1. El coeficiente se obtiene sacando la raíz cuadrada al coeficiente de determinación (R^2) y se simboliza con letra "R" así:

$$R = \sqrt{R^2} \quad (2.55)$$

Para $R=0$, implica que no hay relación lineal entre X e Y.

El coeficiente de correlación trata a X e Y simétricamente. Si ajustamos $Y = \alpha + \beta X$ o $X = \alpha^* + \beta^* Y$, en ambos casos obtendremos el mismo coeficiente de correlación, pero no la misma pendiente.

2.2.4.3 F: Test Fisher (Prueba de significancia de la regresión). En el modelo de regresión múltiple prueba la significancia conjunta de todas las variables independientes. En este modelo el test F tiene p grados de libertad en el numerador y $(n-p-1)$ grados de libertad en el denominador. En el caso de dos variables el test tiene 1 grado de libertad en el numerador y $(n-2)$ en el denominador. [1], [4], [8]

La prueba de hipótesis del test F es:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_j = 0 \quad (2.56)$$

$$H_a: \text{al menos una } \beta_j \neq 0 \quad (2.57)$$

El test F no prueba la significancia de β_0 .

$$F = \frac{CMR}{CME} \quad (2.58)$$

$$CMR = \frac{SCR}{p} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{p} \quad (2.59)$$

$$CME = \frac{SCE}{n - p - 1} = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n - p - 1} \quad (2.60)$$

Donde:

CMR= Cuadrado medio debido a la regresión

SCR= Suma de cuadrados debida a la regresión

CME= Cuadrado medio debido al error

SCE= Suma de cuadrados debido al error

n= Número de variables impeditivas

p= Grados de libertad.

Regla de rechazo

Valor aproximado p : Rechazar H_0 si valor $p \leq \alpha$

Valor crítico aproximado: Rechazar H_0 si $F \geq F_\alpha$

Donde F_α pertenece a la *distribución F* con p grados de libertad en el numerador y $(n-p-1)$ grados de libertad en el denominador.

2.2.4.4 T: t-student (Prueba de significancia de la variable). Sí la **prueba F** indica que la relación de la regresión múltiple es significativa, se puede realizar una prueba t para determinar la significancia de cada uno de los parámetros. Los valores de t son calculados efectuando el cociente entre el coeficiente estimado y el error estándar respectivo. [1], [4], [8]

Para cualquier parámetro β_i

$$H_0: \beta_i = 0 \quad (2.61)$$

$$H_a: \beta_i \neq 0 \quad (2.62)$$

$$t = \frac{b_i}{s_{b_i}} \quad (2.63)$$

s_{b_i} = Es la estimación de la desviación estándar de b_i .

Regla del rechazo

Método del valor p : Rechazar H_0 si valor $p \leq \alpha$

Método del valor crítico: Rechazar H_0 si $t \geq -t_{\alpha/2}$ o si $t \geq t_{\alpha/2}$

Donde $t_{\alpha/2}$ es un valor de la **distribución t** con $(n-p-1)$ grados de libertad.

2.3 REGRESIÓN MÚLTIPLE UTILIZANDO VARIABLES ECONÓMICAS : MÉTODO ECONOMETRICO

Este modelo combina la teoría económica y el modelo de regresión lineal múltiple para el pronóstico de la demanda de electricidad. Se basan en ecuaciones que relacionan la demanda de electricidad con factores externos, como el número de clientes, la renta de los mismos, el precio de la electricidad y de los productos sustitutivos, el nivel de actividad económica, las variables climáticas, el nivel de equipamiento de los hogares, etc. El modelo evalúa las relaciones entre el consumo de energía (dependiendo de variables) y factores que influyen en el consumo. Las relaciones se calculan por el método de mínimos cuadrados o los métodos de series de tiempo. Una de las opciones en este marco es agregar el enfoque de análisis econométrico cuando el consumo en los diferentes sectores (residencial, comercial e industrial) se calcula como una función de tiempo meteorológico, económico y otras variables, a continuación, las estimaciones se montan utilizando datos histórico recientes. La integración del enfoque econométrico en el uso final introduce componentes de comportamiento en las ecuaciones de uso final. [22], [26].

En Colombia las empresas de energía se basan en información histórica de ventas de energía eléctrica en los principales sectores de consumo del sistema eléctrico, y en otras variables socioeconómicas.

La teoría económica define una serie de restricciones al signo y al valor de los parámetros de la curva de demanda de energía eléctrica, que corresponden a conceptos microeconómicos de elasticidad de ingreso, para el caso de la variable producto o ingreso y elasticidad de precio para el caso de la variable de tarifa eléctrica.

El concepto de **elasticidad** es un valor que relaciona el crecimiento porcentual de dos variables, por lo que es independiente de las unidades de medidas involucradas (metros, kilos, pesos etc.) permitiendo conocer el grado de sensibilidad de la demanda ante el aumento (o reducción) del ingreso o del precio. Con este indicador se puede saber cuánto descendería la cantidad demandada del bien, si el precio del mismo se eleva en un determinado porcentaje.

Si **I** es la variable de ingreso y **P**, el precio, los parámetros asociados a ellas responderían a los conceptos de elasticidades de ingreso y precio constante, respectivamente, en el caso en que todas las variables **Q**, **I** y **P** estén expresadas en logaritmos. Estos parámetros de elasticidad se definen como el cambio porcentual de la cantidad demanda del bien o servicio **Q** frente al cambio porcentual de la variable de ingreso **I** o precio **P** respectivamente.

En el caso de la demanda de electricidad se espera estimar una elasticidad ingreso positiva por no mayor a 1 ($0 < \epsilon_{Q,I} < 1$), según el tipo de usuario, por lo que un incremento del nivel de ingreso elevaría la cantidad demandada del bien pero de una forma proporcionalmente menor, es decir, se ajustaría más a la categoría de bien necesario.

En lo que se refiere al precio esta teoría señala que este parámetro debe ser negativo, es decir, la cantidad demandada del bien debe reducirse al elevarse su precio. Cuando la elasticidad precio es mayor que -1 ($-1 < \epsilon_{Q,P} < 0$), se dice que la demanda es **inelástica**, y cuando es menor a -1 ($\epsilon_{Q,P} < -1$) se dice que la demanda es **elástica**. La importancia de esta diferenciación estriba en el impacto que genera sobre el gasto total (precio por cantidad), es decir, sobre la restricción presupuestalmente de las familias o empresas. [22]

Se espera que la elasticidad precio de la demanda de energía eléctrica tenga un valor entre -1 y 0 ($-1 < \epsilon_{Q,P} < 0$) por lo que un incremento del precio de la energía reduciría la cantidad demandada pero de una forma proporcionalmente menor, es decir, se consideraría un bien que tiene pocos sustitutos cercanos.

Adicionalmente a las elasticidades ingreso y precio debe tenerse en cuenta el concepto de elasticidad cruzada de la demanda, el cual mide la sensibilidad de la demanda de un determinado bien, cuando varía el precio de un bien sustituto. Esta elasticidad debe ser positiva, es decir, si el precio del bien sustituto se eleva, la cantidad demandada del otro bien debe elevarse, con lo cual, la ecuación aplicada al consumo de energía eléctrica se formularía de la siguiente manera [22]:

$$Q = A + \epsilon_{Q,I} * I + \epsilon_{Q,P} * P + \epsilon_{Q,PS} * PS \quad (2. 64)$$

Donde:

Q= Consumo de energía eléctrica

A = Constante

I= Nivel de ingreso

P= Precio de la energía eléctrica

PS= Precio de una fuente alternativa de energía eléctrica

$$\text{Elasticidad de ingreso} = \epsilon_{Q,I} = \left(1 + \frac{\Delta Q}{Q}\right) / \left(1 + \frac{\Delta I}{I}\right) \quad (2. 65)$$

$$\text{Elasticidad de Precio} = \epsilon_{Q,P} = \left(1 + \frac{\Delta Q}{Q}\right) / \left(1 + \frac{\Delta P}{P}\right) \quad (2. 66)$$

$$\text{Elasticidad cruzada} = \epsilon_{Q,PS} = \left(1 + \frac{\Delta Q}{Q}\right) / \left(1 + \frac{\Delta PS}{PS}\right) \quad (2. 67)$$

Cabe anotar que todo este análisis supone que la demanda de energía eléctrica lo realizaría un consumidor final, también es aplicable a la demanda intermedia, es decir, la demanda industrial y comercial, relacionando precio y nivel de ingresos a estos.

También se presenta otro modelo de pronóstico de energía eléctrica a largo plazo en logaritmos bajo el concepto de cointegración, mediante la siguiente expresión [22]:

$$\log(V_t) = \beta_0 + \beta_1 \log(y_t) + \beta_2 \log(p_t) + \beta_3 \log(a_t) + \varepsilon_t \quad (2. 68)$$

Donde:

V_t = Ventas de energía eléctrica

y_t = PIB (Producto interno bruto)

p_t = Tarifa de electricidad

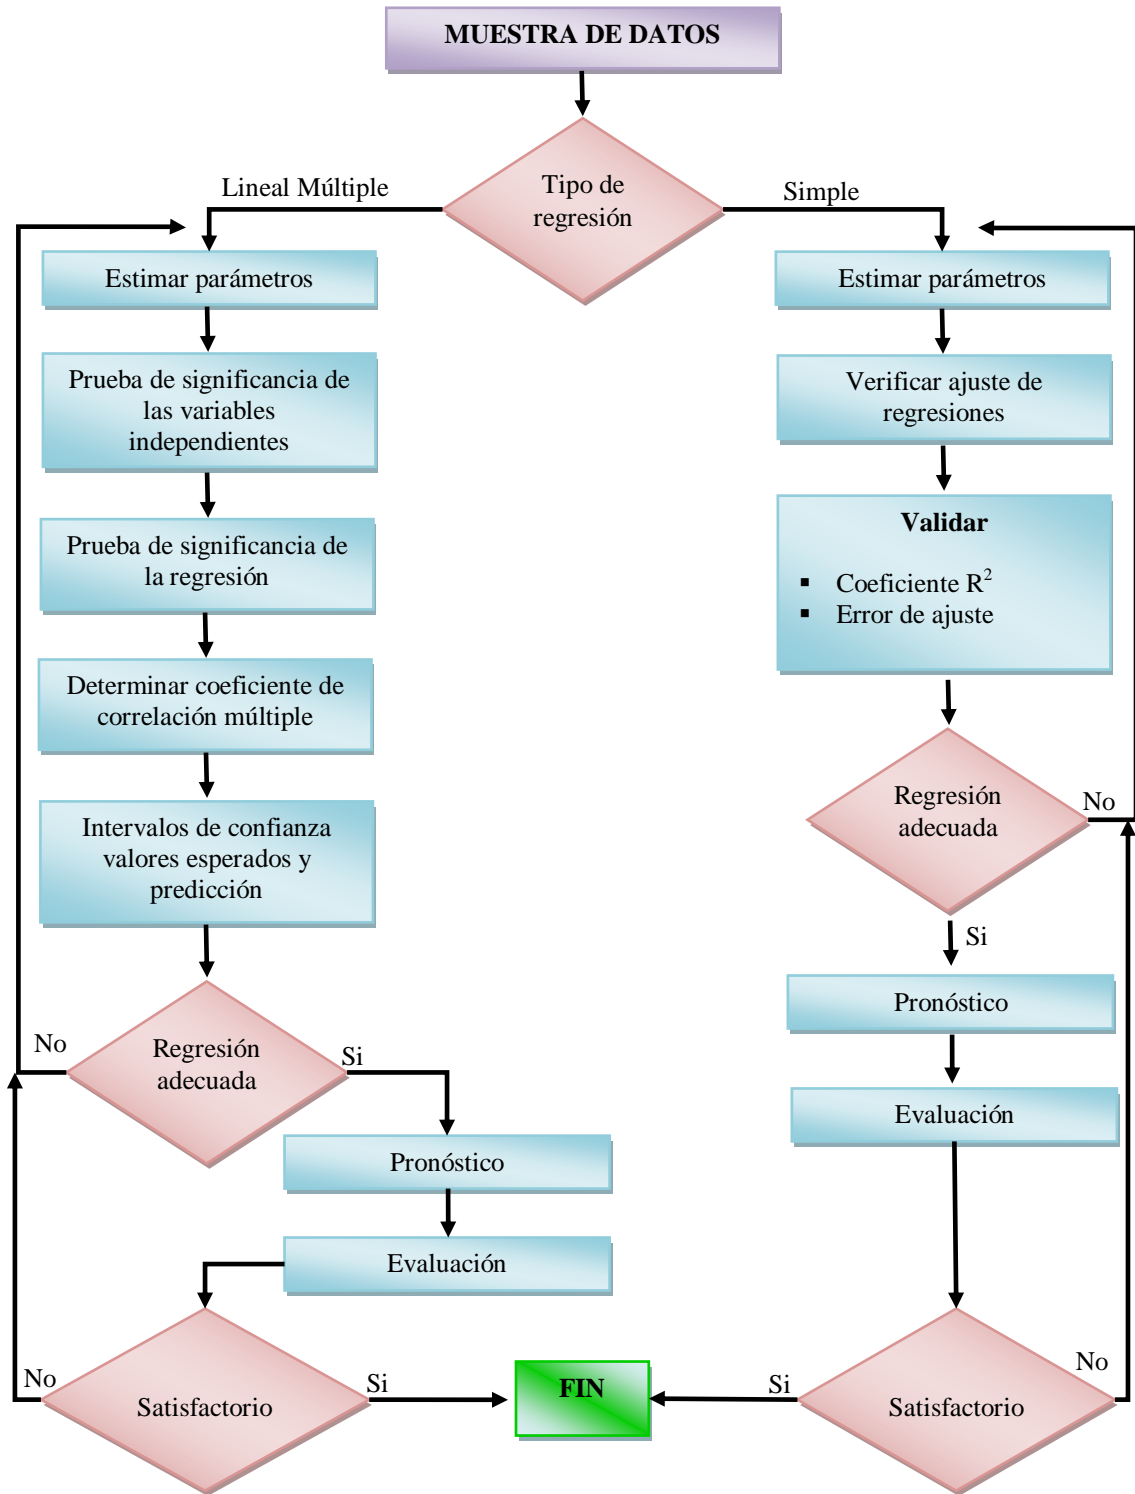
a_t = Número de clientes

$\varepsilon_t \sim N(0, \sigma^2)$, los errores presentan una distribución normal.

Se debe verificar que el residuo de la expresión anterior sea estacionario para verificar la presencia de cointegración. Si este es el caso el vector conformado por $(\beta_0, \beta_1, \beta_2, \beta_3)$ será el vector de cointegración [22]. Una vez determinada la estacionariedad de los residuos se procede a estimar un modelo de corrección de errores, determinado por un modelo de rezagos distribuidos de la siguiente forma:

$$\Delta \log(V_t) = \left\{ \begin{aligned} & -\lambda [\log(v_{t-1}) - \beta_1 \log(y_{t-1}) - \beta_2 \log(p_{t-1}) \\ & \quad - \beta_3 \log(a_{t-1})] \\ & - \sum_{j=1}^{p-1} b_j \Delta \log(v_{t-j}) - \sum_{j=0}^{q-1} \gamma_{1j} \Delta \log(y_{t-j}) \\ & - \sum_{j=0}^{r-1} \gamma_{2j} \Delta \log(p_{t-j}) - \sum_{j=0}^{s-1} \gamma_{3j} \Delta \log(a_{t-j}) + \mu_t \end{aligned} \right\} \quad (2. 69)$$

Figura 11. Metodología para pronóstico utilizando regresión



CAPITULO III

PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO SERIES DE TIEMPO

3.1 MÉTODO DE SERIES TEMPORALES

Dado que la demanda eléctrica varía de manera continua en el tiempo, se considera que es una serie de tiempo. Esto permite la aplicación de diferentes técnicas de series temporales y metodologías para la predicción de la demanda futura basadas en los datos históricos disponibles de demandas.


Este método requiere la menor información posible, dado que la única variable independiente es el tiempo, básicamente se pretende medir el consumo de energía eléctrica en el tiempo a intervalos espaciados uniformemente. El objetivo de la identificación de la información histórica es determinar un patrón básico en el comportamiento del consumo de electricidad que permita la proyección futura de la demanda de energía eléctrica.

Para examinar a la serie de tiempo, se grafican sus valores, lo que permite realizar un análisis completo de las misma. Una vez graficados los datos, es posible detectar algunas irregularidades, e incluso valores atípicos, en caso de que estén presentes; dentro de los que se destaca la aparición de un nivel, cambios periódicos y efectos estacionales. Los cambios o discontinuidades dentro de la serie de tiempo, pueden ser fundamentales para el análisis de los datos por intervalos. Dentro del estudio de las series de tiempo, es primordial analizar sus componentes y de ser necesario realizar transformaciones para eliminarlas o modificarlas. Con esto se obtienen series de tiempo estacionarias, siendo posible un análisis más preciso.

3.1.1 Componentes de una serie de tiempo.


3.1.1.1 Tendencia. Es la componente que recoge el comportamiento de la serie a largo plazo, para detectarse se requiere que la serie conste de un elevado número de observaciones, de esta forma apreciar un movimiento creciente o decreciente o estacionalidad. En el caso de la demanda de energía eléctrica la tendencia se puede tomar en periodos semanales, mensuales o anuales y son movimientos lineales o exponenciales relacionado con el constante crecimiento de los usuarios. [4], [16], [18].

Figura 12. Característica de componente de tendencia de una serie temporal




3.1.1.2 Fluctuaciones cíclicas. El efecto cíclico se define como la fluctuación en forma de onda alrededor de la tendencia, son curvas de largo período asociadas con grandes ciclos económicos de las fases expansivas y recesivas de la economía, estos patrones cíclicos tienden a repetirse en los datos cada dos, tres o más períodos. La forma de estos ciclos no son simples de aislar y en ciertas ocasiones la teoría económica no se encuentra suficientemente desarrollada como para permitir una cuantificación confiable. [4], [16], [18].

Figura 13. Característica de componente de ciclicidad de una serie temporal



3.1.1.3 Fluctuaciones estacionarias. Son movimientos ascendentes y descendentes de la serie que se repiten periódicamente. Al tiempo entre dos picos consecutivos se le denomina periodo estacional, y puede ser diario, semanal, mensual, anual, etc.; estos periodos se pueden determinar con la aplicación de la transformada rápida de Fourier (FFT), o bien por medio de la función de auto correlación. [4], [16], [18].

Figura 14. Característica de componente de estacionalidad de una serie temporal



Una serie es estacionaria si la media y la variabilidad se mantienen constantes a lo largo del tiempo.

Si al diferenciar una vez una serie, su media y varianza se vuelven constantes, se dice que es integrada de orden uno i (1).

3.1.1.4 Fluctuaciones aleatorias. Estas variaciones no responden a ningún patrón de comportamiento, más bien son consecuencia de la presencia de factores aleatorios que inciden de manera aislada y no permanente en la serie; una característica principal es que su correlación es cero. [4], [16], [18].

Figura 15. Característica de componente de aleatoriedad de una serie temporal



Según estas definiciones, una serie temporal $Y(t)$, puede admitir una descomposición del tipo:

$$Y(t) = T(t) + C(t) + E(t) + A(t) \text{ Esquema Aditivo} \quad (3.1)$$

$$Y(t) = T(t) * C(t) * E(t) * A(t) \text{ Esquema Multiplicativo} \quad (3.2)$$

$$Y(t) = T(t) * C(t) * E(t) + A(t) \text{ Esquema Mixto} \quad (3.3)$$

Donde:

T(t)=Tendencia

C(t)= Ciclicidad

E(t)= Estacionalidad

A(t)= Aleatoriedad

Cabe decir que este tipo de descomposición en ocasiones no es posible en su totalidad, debido a la naturaleza y periodicidad de los datos (series anuales, trimestrales, mensuales, diarias, etc.) alguno o la totalidad de los componentes pueden no existir. Así mismo hay que señalar que dado que los componentes no son observables directamente no existe una total unanimidad en la definición de los mismos, por lo que existe la posibilidad que utilizando diversos métodos y definiciones obtengamos estimaciones de los componentes totalmente diferentes.

3.1.2 Método de descomposición. Esta técnica supone que la serie histórica de una variable puede ser desagregada en cuatro patrones fundamentales: tendencia, ciclo, estacionalidad y un componente aleatorio, los cuales una vez aislados pueden extrapolarse individualmente hacia el futuro. Constituye uno de los enfoques más antiguos y comúnmente empleado en el mundo de los negocios, existiendo diversos procedimientos para descomponer la serie de tiempo. [4], [16], [18].

3.2 ANÁLISIS DE SERIES TEMPORALES BASADOS EN PROMEDIOS

3.2.1 Promedio Simple. Este método utiliza datos recientes de la demanda para hacer pronósticos y se da igual ponderación a todos los datos, se obtiene encontrando la media de todos los valores pertinentes y usando después esta media para pronosticar el siguiente periodo. Es recomendable utilizarlo cuando las demandas son estables y no presentan ni tendencia, ni estacionalidad, detallado en las referencias [1], [4], [18]. La fórmula para el promedio móvil simple es:

$$PS = \frac{\sum_{t=1}^n Y_t}{n} \quad (3.4)$$

Donde:

n = Número de períodos a promediar

Y_t= Demanda en el período i

La variable n determina el grado de suavización del pronóstico. A mayor n hay más suavización y por lo tanto es recomendable para datos poco aleatorios, ya que la proyección resultante es constante y reacciona más lento a los cambios en la demanda.

3.2.2 Promedios Móviles. Este método es una variación del Promedio Simple, en el cual se propone un número fijo de elementos que se moverán por todos los datos históricos que se están analizando, reemplazando los elementos más antiguos de la serie y aceptando los elementos nuevos que se van presentando. La cantidad fija de elementos lo establecerá el analista que los está estudiando, pero teniendo muy en cuenta que una vez establecidos no se pueden modificar; además, sigue en vigencia la colocación del mismo peso para cada elemento considerado [1],[4], [18].El modelo está expresado de la manera siguiente :

$$\hat{Y}_{t+1} = \frac{\sum_{t=1}^n Y_{t-n+1}}{n} = \frac{Y_t + Y_{t-1} + Y_{t-2} + Y_{t-n+1}}{n} \quad (3.5)$$

Donde:

\hat{Y}_{t+1} = Valor pronosticado para el siguiente período

Y_t = Valor real u observado en el periodo t

n = número de términos en el promedio móvil

Los promedios móviles son útiles si se asume que las demandas del mercado serán más o menos constantes durante un determinado período de tiempo. Para obtener el promedio móvil basta con dividir la demanda de los periodos previos entre la cantidad de periodos.

3.2.3 Promedio móvil doble. Una forma de pronosticar series de tiempo que tienen una tendencia lineal, consiste en utilizar la técnica del promedio móvil doble. El método hace lo que su nombre implica: se calcula un conjunto de promedios móviles y después se calcula un segundo conjunto como promedio móvil del primero. [1], [4], [18]

El primer promedio móvil se calcula con la siguiente expresión:

$$\hat{Y}_{t+1} = \frac{Y_t + Y_{t-1} + Y_{t-2} + Y_{t-n+1}}{n} \quad (3.6)$$

$$M_t = \hat{Y}_{t+1} \quad (3.7)$$

El segundo promedio móvil se calcula así:

$$M'_t = \frac{M_t + M_{t-1} + M_{t-2} + \dots + M_{t-n+1}}{n} \quad (3.8)$$

La diferencia entre los promedios móviles así:

$$a_t = 2M_t - M'_t \quad (3.9)$$

También se calcula b_t que es un factor de ajuste adicional, similar a la medición de una pendiente que cambia a través de la serie

$$b_t = \frac{2}{n-1} (M_t - M'_t) \quad (3.10)$$

El pronóstico para m periodos en el futuro se describe en la siguiente expresión:

$$\hat{Y}_{t+p} = a_t + b_t p \quad (3.11)$$

Donde:

Y_t = Valor real de la serie en el periodo t

p = Número de periodos a pronosticar hacia el futuro

n = Número de periodos en el promedio móvil

3.2.4 Promedios Móviles Ponderados. Es un tipo de pronóstico interesante, que resulta de la combinación de los dos tipos de pronósticos indicados anteriormente, pues representa un promedio de elementos que se mueve por la mayoría de los datos históricos observados. Posee una característica que lo diferencia de los anteriores: da pesos diferentes a cada uno de los elementos que se estén considerando y los pesos que se le ponderen a cada elemento en ningún momento pueden ser mayores a la unidad. En otras palabras, la sumatoria de los pesos asignados a cada elemento tiene que ser igual a la unidad, de esta manera, el analista tendrá la oportunidad de darle un toque de subjetividad al pronóstico de acuerdo con el comportamiento histórico observado en la demanda [1], [4], [18]. Matemáticamente, la relación de este pronóstico vendría dado de la siguiente manera:

$$PM = W_1 Y_1 + W_2 Y_2 + \dots + W_n Y_n = \sum_{t=1}^n W_t Y_t \quad (3.12)$$

$$0 \leq W_t \leq 1 \quad y \quad \sum_{t=1}^n W_t = 1.0 \quad (3.13)$$

Donde:

Y_t = Demanda del período t

W_t = Peso asignado al período i , entre 0 y 100%

Este método se usa cuando existe una tendencia o un patrón, por lo general se le da énfasis o mayor ponderación a los periodos más recientes, para así ser más sensible a los cambios. Decidir la importancia de cada dato o conjunto de datos dentro del periodo calculado es cuestión de intuición y de suerte. Para obtener el pronóstico basta con elegir la cantidad de datos que serán tomados en cuenta para estimar un periodo.

3.3 ANÁLISIS DE SERIES TEMPORALES BASADOS SUAVIZACIÓN EXPONENCIAL.

3.3.1 Suavización Exponencial. Este es uno de los métodos más populares y frecuentemente usados para pronosticar ya que requiere pocos datos. Por ser exponencial, da mayor importancia a los últimos datos, es por esto que solo trabaja con el último dato real y el último pronosticado. A demás, este método reacciona mejor a cambios fuertes en la demanda.[1], [4], [16], [18]

La suavización exponencial requiere el uso de la siguiente fórmula:

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) \hat{Y}_t \quad (3.14)$$

Donde:

\hat{Y}_{t+1} = Nuevo valor atenuado o valor de pronóstico para el siguiente período t

α = Constante de atenuación ($0 < \alpha < 1$)

Y_t = Nueva observación o valor real de la serie en el período t

\hat{Y}_t = Valor atenuado anterior período o experiencia promedio de la serie atenuada al periodo ($t - 1$).

$$\hat{Y}_{t+1} = \hat{Y}_t + \alpha(Y_t - \hat{Y}_t) \quad (3.15)$$

La atenuación exponencial es simplemente el pronóstico anterior \hat{Y}_t mas α veces el error $(Y_t - \hat{Y}_t)$ en el pronóstico anterior.

La atenuación exponencial es un procedimiento para revisar constantemente un pronóstico a la luz de la experiencia más reciente.

La constante de atenuación α sirve como el factor para ponderar. El valor real de α determina el grado hasta el cual la observación más reciente puede influir en el valor del pronóstico. Cuando α es cercana a 1, el nuevo pronóstico incluirá un ajuste sustancial de cualquier error ocurrido en el pronóstico anterior. Inversamente, cuando α está cercana a 0, el pronóstico es similar al anterior.

Los valores de α cercanos a 1 generan una menor suavización en el pronóstico, por lo tanto hay una mayor reacción a los cambios en la demanda. Se usa para demandas que presentan tendencia.

3.3.2 Atenuación exponencial ajustada a la tendencia: Método de Holt. Otra técnica que se usa con frecuencia para manejar una tendencia lineal se denomina Método de dos parámetros de Holt. La técnica de Holt atenúa en forma directa la tendencia y la pendiente empleando diferentes constantes de atenuación para cada una de ellas. En el enfoque de Brown, solo se usaba una constante de atenuación y los valores estimados de la tendencia serán muy sensibles a variaciones aleatorias. La técnica de Holt proporciona mayor flexibilidad al seleccionar las proporciones a las que se rastrearán la tendencia y la pendiente [4], [16], [18]. Las tres ecuaciones que se utilizan en esta técnica son:

1. Serie exponencialmente atenuada

$$A_t = \alpha Y_t + (1 - \alpha)(A_{t-1} + T_{t-1}) \quad (3.16)$$

Esta ecuación es muy similar a la ecuación original de atenuación exponencial simple, con excepción de que se incorpora un nuevo término (T_t) para la tendencia. La estimación de la tendencia se calcula tomando la diferencia entre los valores sucesivos de atenuación exponencial ($A_t - A_{t-1}$). Ya que los valores sucesivos se atenuaron con fines de aleatoriedad, su diferencia constituye una estimación de la tendencia en los datos.

2. La estimación de la tendencia

$$T_t = \beta(A_t - A_{t-1}) + (1 - \beta)T_{t-1} \quad (3.17)$$

Para atenuar la estimación de la tendencia se utiliza una segunda constante de atenuación β . En esta ecuación la atenuación se realiza para la tendencia en vez de los datos reales, como resultado se tiene una tendencia atenuada excluyendo aleatoriedad.

3. El pronóstico de p periodos en el futuro

$$\hat{Y}_{t+p} = A_t + pT_t \quad (3.18)$$

En donde

A_t = Nuevo valor atenuado

α = Constante de atenuación de los datos ($0 \leq \alpha \leq 1$)

Y_t = Nueva observación o valor real de la serie, en el período t

β = Constante de atenuación de la estimación de la tendencia ($0 \leq \beta \leq 1$)

T_t = Estimación de la tendencia

p = Periodos a pronosticar en el futuro

\hat{Y}_{t+p} = Pronóstico de p periodos en el futuro

En la ecuación numero 3, se muestra el pronóstico de p a futuro. Se multiplica la estimación de la tendencia T_t por el numero de periodos en pronostico p y el producto se suma al nivel actual de los datos A_t para eliminar aleatoriedad.

3.3.3 Atenuación exponencial ajustada a la tendencia y a la variación estacional: Modelo Winter. El modelo de atenuación exponencial lineal y estacional de tres parámetros de Winter, que es una extensión del modelo de Holt, pudiera reducir el error de pronóstico. Se utiliza una ecuación adicional para determinar la estacionalidad. Esta estimación está dada por un Índice estacional y se calcula con la ecuación del numeral (3), la cual muestra que la estimación del índice estacional (Y_t/A_t) se multiplica por γ , se suma después a la estimación estacional anterior S_{t-L} multiplicada por $(1 - \gamma)$. La razón Y_t se divide entre A_t para expresar el valor en forma de índice en vez de hacerlo en términos absolutos de modo que pueda promediarse con el índice estacional atenuado al periodo $(t - L)$. [4], [16], [18]

Las cuatro ecuaciones que emplea el modelo de Winter son:

1. La serie exponencial atenuada

$$A_t = \alpha \frac{Y_t}{S_{t-L}} + (1 - \alpha)(A_{t-1} + T_{t-1}) \quad (3.19)$$

2. La estimación de la tendencia

$$T_t = \beta(A_t - A_{t-1}) + (1 - \beta)T_{t-1} \quad (3.20)$$

3. La estimación de la estacionalidad

$$S_t = \gamma \frac{Y_t}{A_t} + (1 - \gamma)S_{t-L} \quad (3.21)$$

4. El pronóstico de p períodos en el futuro

$$\hat{Y}_{t+p} = (\alpha + \beta T_t) S_{t-L+p} \quad (3.22)$$

Donde:

α = Nuevo valor atenuado

α = Constante de atenuación ($0 < \alpha < 1$)

Y_t = Nueva observación o valor real de la serie en el periodo t

β = Constante de atenuación de la estimación de la tendencia ($0 < \beta < 1$)

T_t = Estimación de la tendencia

γ = Constante de atenuación de la estimación de la estacionalidad ($0 < \gamma < 1$)

S_t = Estimación de la estacionalidad

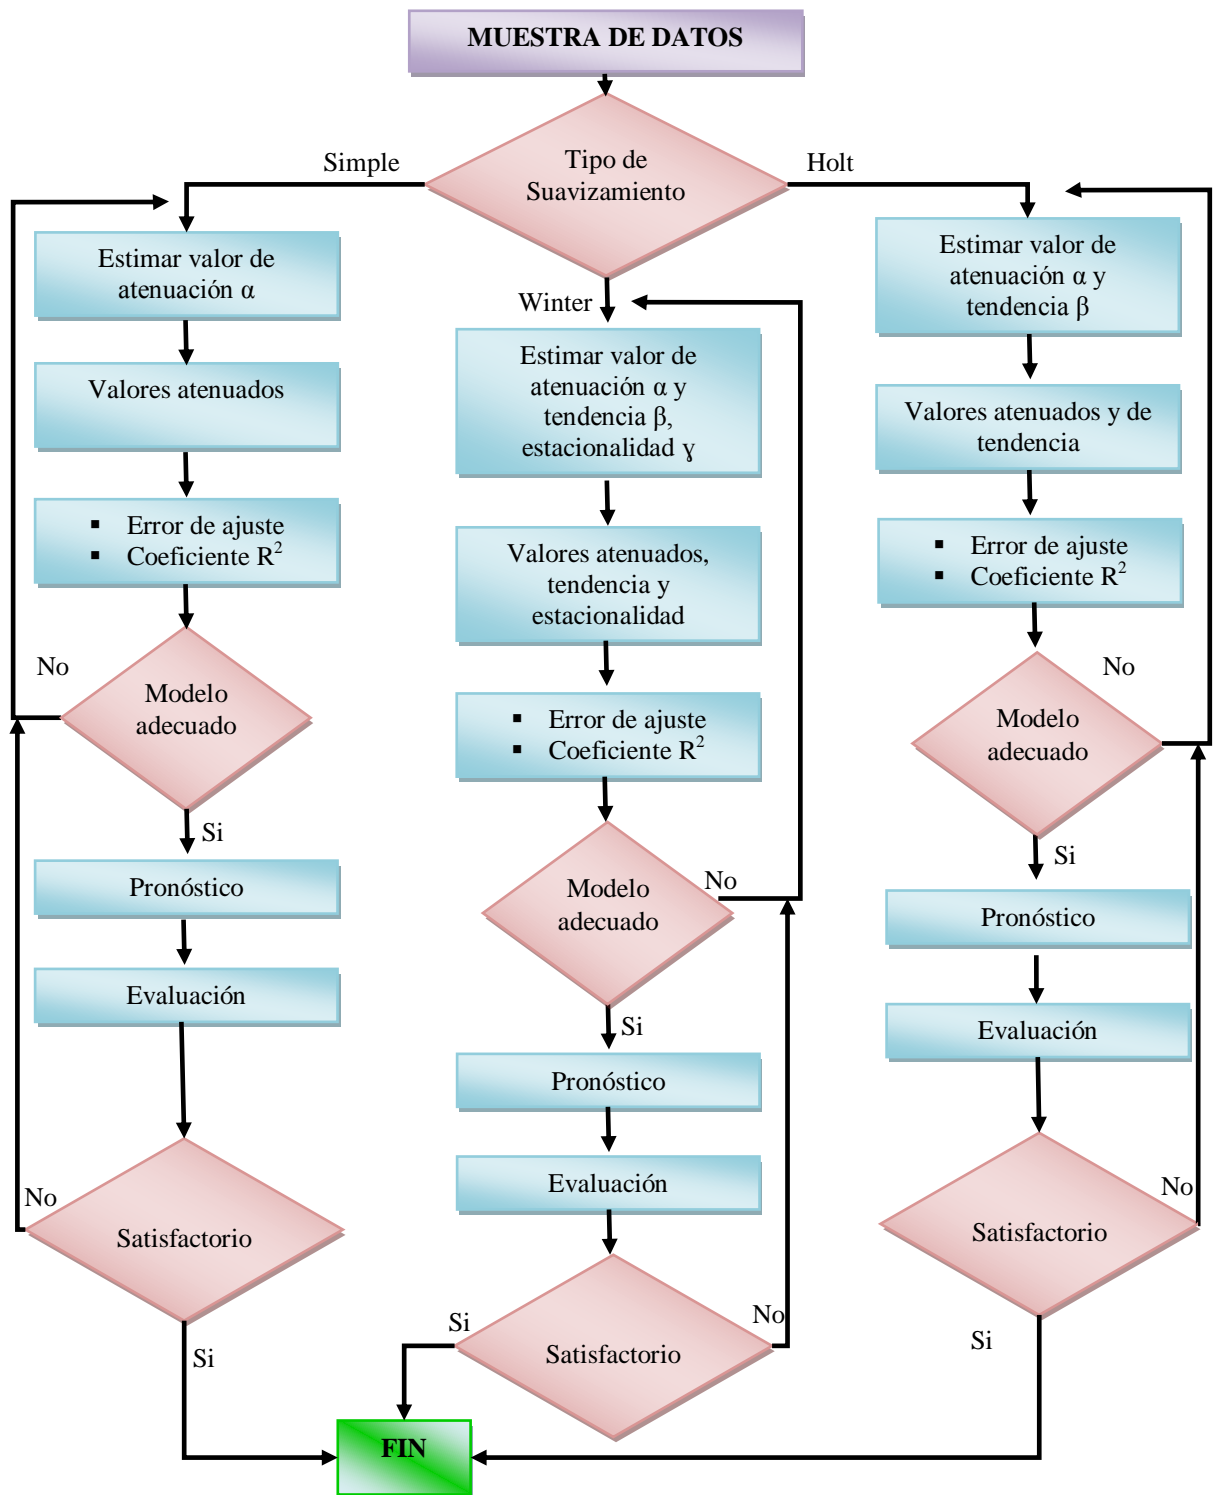
p = Períodos a estimar en el futuro

L = Longitud de la estacionalidad

\hat{Y}_{t+p} = Pronóstico de p periodos a futuro

La técnica de Winter resulta mejor que los modelos anteriores si se considera el minimizar el EMC (Error medio cuadrático).

Figura 16. Metodología para Modelos de Suavizamiento Exponencial



3.4 ELABORACIÓN DE LOS MODELOS AR, MA Y ARMA PARA SERIES DE TIEMPO

3.4.1 Proceso autorregresivo (AR). Los procesos autorregresivos forman una familia de procesos tales que una observación depende de las observaciones anteriores. Sea Y_t la demanda de energía eléctrica en el período t . si se modela Y_t como:

$$(Y_t - \delta) = \alpha_1(Y_{t-1} - \delta) + u_t \quad (3.23)$$

Donde δ es la media de Y y u_t , es un término de error aleatorio no correlacionado con media cero y varianza constante σ^2 (es decir, ruido blanco), entonces se dice que Y_t sigue un proceso estocástico **autorregresivo de primer orden o AR (1)**. [4], [16]

El valor de Y_t en el tiempo t depende de su valor en el periodo anterior y de un término aleatorio; los valores de Y están expresados como desviaciones de su valor medio. Este modelo dice que el valor del pronóstico de Y en el periodo t es simplemente alguna proporción α_1 de su valor en el periodo $(t - 1)$ mas una perturbación en el tiempo t ; nuevamente los valores de Y están expresados alrededor de su media.

El valor de Y en el tiempo depende de sus valores en los periodos anteriores, los valores de Y expresados alrededor de media δ . En general se tiene:

$$(Y_t - \delta) = \alpha_1(Y_{t-1} - \delta) + \alpha_2(Y_{t-2} - \delta) + \dots + \alpha_p(Y_{t-p} - \delta) + u_t \quad (3.24)$$

En cuyo caso Y_t es un **proceso autorregresivo de orden p o AR (p)**.

3.4.2 Proceso de media móvil (MA). Es una combinación lineal de términos de error con ruido blanco. En forma general sigue la siguiente expresión:

$$Y_t = \mu + \beta_0 u_t + \beta_1 u_{t-1} + \beta_2 u_{t-2} + \dots + \beta_q u_{t-q} \quad (3.25)$$

Donde μ es una constante y u es el término de error estocástico con ruido blanco. En este caso Y en el periodo t es igual a una constante más un promedio móvil de los términos de error presente y pasados. [4], [16]

3.4.3 Proceso autorregresivo y de media móvil (ARMA). En este caso la característica de Y es una combinación de AR y de MA, así Y_t sigue un proceso **ARMA (1, 1)**, donde hay un término autorregresivo y uno de media móvil, se expresa de la siguiente forma:

$$Y_t = \theta + \alpha_1 Y_{t-1} + \beta_0 u_t + \beta_1 u_{t-1} \quad (3.26)$$

En general en un proceso **ARMA** (p, q) habrá p términos autorregresivos y q términos de media móvil. [4], [16]

3.4.4 Proceso autorregresivo integrado de media móvil (ARIMA). Los modelos de series analizados suponen que la series de tiempo consideradas son débilmente estacionarias, es decir, que la media y la varianza de la serie de tiempo son constantes y su covarianza es invariante en el tiempo. Pero muchas de las series de tiempo son no estacionarias, es decir, integradas, pero si una serie de tiempo es integrada de orden 1, es decir, si es $I(1)$, sus primeras diferencias son $I(0)$, es decir, son estacionarias. De forma similar si una serie de tiempo es $I(2)$, su segunda diferencia es $I(0)$. En general si una serie de tiempo es $I(d)$, después de diferenciarla d veces se obtiene una serie $I(0)$. Por consiguiente, si se debe diferenciar una serie de tiempo d veces para hacerla estacionaria y luego aplicar a ésta el modelo ARMA (p, q), se dice que la serie de tiempo original es **ARIMA** (p, d, q), es decir, es una serie de tiempo **autorregresiva integrada de media móvil**, donde p denota el numero de términos autorregresivos, d el número de veces que la serie debe ser diferenciada para hacerse estacionaria y q el numero de términos de media móvil. [4], [16]

Por ejemplo si se tiene una serie de tiempo **ARIMA** ($2, 1, 2$), tiene que ser diferenciada una vez ($d = 1$) antes que se haga estacionaria, y la serie de tiempo estacionaria (en primera diferencia) puede ser modelada como un proceso **ARMA** ($2, 2$), es decir, que tiene dos términos **AR** y dos términos **MA**. Por supuesto si ($d = 0$), es decir, la serie es estacionaria entonces **ARIMA** ($p, d = 0, q$) = **ARMA** (p, q).

Si se tiene un proceso **ARIMA** ($p, 0, 0$), significa que es un proceso estacionario **AR** (p) puro; en caso de un **ARIMA** ($0, 0, q$) es un proceso estacionario **MA** (q) puro. Dados los valores de p, d y q puede decirse de cuál proceso se está haciendo el modelo. Cuando se tiene **ARIMA** ($0, 0, 0$) se refiere a ruido blanco.

3.4.5 Propiedades de las series integradas. Sea X_t, Y_t, Z_t tres series de tiempo. [16]

1. Si $X_t \sim I(0)$ y $Y_t \sim I(1)$, entonces $Z_t = (X_t + Y_t) \sim I(1)$; es decir, una combinación lineal de sumas de series de tiempo estacionarias y no estacionarias, es no estacionaria.
2. Si $X_t \sim I(d)$, entonces $Z_t = (a + bX_t) \sim I(d)$, donde a y b son constantes. Es decir, una combinación lineal de una serie $I(d)$ es también $I(d)$. Por tanto si $X_t \sim I(0)$, entonces $Z_t = (a + bX_t) \sim I(0)$.
3. Si $X_t \sim I(d_1)$ y $Y_t \sim I(d_2)$, entonces $Z_t = (aX_t + bY_t) \sim I(d_2)$, donde $d_1 < d_2$.
4. Si $X_t \sim I(d)$ y $Y_t \sim I(d)$, entonces $Z_t = (aX_t + bY_t) \sim I(d^*)$; d^* es por lo general igual a d , pero en algunos casos $d^* < d$. (**Cointegración**).

Se nota que debe ponerse especial atención al combinar dos o más series de tiempo que tienen diferente orden de integración.

Para utilizar la metodología de Box-Jenkins, se debe tener en cuenta que la serie sea estacionaria o que luego de una o dos diferenciaciones la serie de tiempo sea estacionaria. Los modelos de Box-Jenkins tienden a obtener mejores resultados que los modelos de suavización exponencial para series de tiempo más largas y estables no son buenos para datos con ruido y alta volatilidad.

Este enfoque se basa en el hecho que la serie temporal que se trata de predecir es generada por un proceso estocástico, cuya naturaleza puede ser caracterizada mediante un modelo. Para ello, se necesita una serie con un elevado número de observaciones.

Tabla 3. Patrones teóricos de FAC y FACP

PATRONES TEÓRICOS DE FAC Y FACP		
TIPO DE MODELO	PATRÓN TÍPICO FAC	PATRÓN TÍPICO FACP
AR (p)	Disminuye exponencialmente o con un patrón sinusoidal decreciente o ambos	Picos grandes a lo largo de los p rezagos, se anula para retardos superiores a p.
MA (q)	Picos grandes a lo largo de los q rezagos, se anula para retardos superiores a q.	Decrece exponencialmente sin llegar anularse
ARMA (p,q)	Decrece exponencialmente sin llegar anularse	Decrece exponencialmente sin llegar anularse

Fuente: GUJARATI, Damodar.Econometria. McGraw-Hill, edición 4, 2003.

3.4.6 Caracterización Series de tiempo $I(0)$ e $I(1)$.

Tabla 4. Caracterización series de tiempo

SERIE $I(0)$	SERIE $I(1)$
Presentan varianza finita e independiente del tiempo.	Su varianza depende del tiempo y tiende a finito a medida que el tiempo tiende a infinito
Tienen memoria limitada.	Cualquier innovación afecta permanentemente a sus procesos.
Tienden a fluctuar alrededor de la media (que puede incluir una tendencia determinista).	Oscilan ampliamente.
Presentan autocorrelaciones que tienden a disminuir rápidamente a medida que el retardo se incrementa.	Su autocorrelación tiende a uno (en valor absoluto) para cualquier orden del retardo.

Fuente: Basado en GUJARATI, Damodar.Econometria. McGraw-Hill, edición 4, 2003.

3.4.7 Modelos estacionales ARIMA. Dentro de estos modelos se encuentran los modelos estacionales ARIMA que se denotan anteponiéndoles la letra S y el orden de sus parámetros se escribe con mayúscula, así:

- Modelos Autorregresivos Estacionales SAR(P)
- Promedios Móviles Estacionales SMA(Q)
- Modelo Autorregresivo y de Promedios Móviles Estacionales SARMA (P, Q).

Los modelos SARMA son análogos al proceso ARMA pero considerando los retardos del ruido blanco y del proceso de s en s . Sin embargo estos modelos SARMA no son capaces de explicar todos los movimientos estacionales, pues si estos crecieran de año en año, los SARMA serían incapaces de recoger esta evolución pues al igual que los ARMA son estacionarios. Esta dificultad se resuelve a través de los modelos autorregresivos de promedios móviles integrados estacionales **SARIMA (P, D, Q)**. [4], [16]

La unión de modelos estacionales con modelos no estacionales conduce a un modelo de gran capacidad de adaptación que puede reflejar tanto la tendencia como la estacionalidad de una serie (enfoque de Box y Jenkins). La combinación de estos modelos se logra a través de la multiplicación de los operadores polinomiales que caracterizan a cada modelo obteniendo los modelos conocidos como **ARIMA(p, d, q) * SARIMA(P, D, Q)**. Por lo general los parámetros que no se consideran son de orden cero, como se describe a continuación:

- p : orden de un modelo autorregresivo AR
- d : orden de diferenciación en la parte regular o no estacionaria de la serie
- q : orden de un modelo promedio móvil MA
- P : orden de un modelo autorregresivo estacional SAR
- D : orden de diferenciación en la parte estacional de la serie
- Q : orden de un modelo promedio móvil estacional SMA

3.4.8 Pruebas de estacionariedad. Los modelos clásicos de Box-Jenkins describen series temporales estacionarias. Por lo tanto es necesario primero determinar si la serie temporal es estacionaria; Si no es así, se debe transformar la serie. [4], [16]

1. Propiedades estadísticas

De manera intuitiva una serie es estacionaria si la media y varianza son esencialmente constantes a través del tiempo, es decir, que sus n valores fluctúan con variación constante respecto de la media.

2. Prueba gráfica

Es aconsejable graficar la serie de tiempo bajo estudio, para observar su comportamiento y tendencia.

3. Función de autocorrelación y correlograma

La función de autocorrelación al rezago k denotada por ρ_k se define como:

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\text{Covarianza al rezago k}}{\text{varianza}} \quad (3.27)$$

La varianza y covarianza están medidas en las mismas unidades por lo que ρ_k es un número sin unidad de medida y se encuentra entre -1 y +1, igual que el coeficiente de correlación. Si se grafica ρ_k frente a k la grafica obtenida se conoce como **correlograma poblacional**.

En la práctica solo se tiene una realización de un proceso estocástico, es decir, la muestra, solamente se puede calcular la **función de autocorrelación muestral**, $\hat{\rho}_k$. Por consiguiente se debe calcular primero la **covarianza muestral** al rezago k, $\hat{\gamma}_k$ y la varianza muestral $\hat{\gamma}_0$ que están definidas como:

$$\hat{\gamma}_k = \frac{\sum (Y_t - \bar{Y})(Y_{t+k} - \bar{Y})}{n} \quad (3.28)$$

$$\hat{\gamma}_0 = \frac{\sum (Y_t - \bar{Y})^2}{n} \quad (3.29)$$

Donde n es el tamaño de la muestra y \bar{Y} es la media muestral. La función de autocorrelación muestral al rezago k corresponde a la razón entre la covarianza y varianzas muestrales así:

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} \quad (3.30)$$

La grafica de $\hat{\rho}_k$ frente a rezago k se le conoce como **correlograma muestral**.

Una regla práctica consiste en calcular la FAC hasta un tercio o una cuarta parte de la longitud de la serie de tiempo.

Una forma de saber si la serie tiene Tendencia, Estacionalidad, es una serie Aleatoria o una serie Estacionaria es mediante la observación del Correlograma.

- **Correlograma:** Gráfica que muestra los coeficientes de autocorrelación de la serie.

$$r_k = \frac{\sum_{t=1}^{n-k} (Y_t - \bar{Y})(Y_{t+k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad (3.31)$$

Donde:

r_k = Coeficiente de Autorreclación para un desfase de k periodos

Y_t = Dato observado en el período t

\bar{Y} = Media de los valores de la serie

Y_{t-k} = Observación en k periodos anteriores o en el periodo ($t - k$)

El correlograma es una herramienta gráfica que se emplea para exhibir las autocorrelaciones para varios desfases en una serie de tiempo.

3.4.9 Criterios de validez modelos ARIMA.

3.2.9.1 Estadístico AIC (*Akaike Information Criterion*). El estadístico AIC propuesto por Akaike está basado en la teoría de la información y se expresa de la siguiente forma:

$$AIC = -\frac{2L}{T} + \frac{2(p + d + q)}{T} \quad (3.32)$$

Donde

p, Número de parámetros autorregresivos

q, Número de medias móviles

d, Número de diferencias para hacer la serie estacionaria

T, Numero de instantes considerados en la serie

L, Valor de logaritmo de la función de verosimilitud.

Este criterio se aplica en general a muchos modelos autorregresivos. [1]

3.2.9.2 Estadístico SBC (*Schwartz Bayesian Criterion*). Este estadístico al igual que AIC permiten determinar el orden del modelo. Los parámetros denominados AIC y SBC son medidas de ajuste del modelo. Este parámetro se aplica de manera general a diferencia del AIC que suele emplearse en modelos autorregresivos. Cuanto más pequeño sea el valor del criterio de información AIC y SBC, mejor será el modelo. [1]

3.4.10 Descripción de la metodología Box-Jenkins

1. Identificación

Encontrar los valores apropiados de p, d, q, con la ayuda del correlograma y correlograma parcial.

Las herramientas principales en la identificación son la **función de autocorrelación (FAC)**, la **función de autocorrelación parcial (FACP)** y los **correlogramas** resultantes, que son simplemente los gráficos de FAC y FACP respecto a la longitud del rezago [16]

2. Estimación

Una vez identificados los valores de p y q , lo siguiente será estimar los parámetros de los términos autorregresivos y de media móvil incluidos en el modelo. Este cálculo puede hacerse por medio de mínimos cuadrados simples, pero en otros casos se deberá aplicar estimación no lineal (en parámetros), esta estimación puede realizarse mediante paquetes estadísticos. [16]

3. Validación

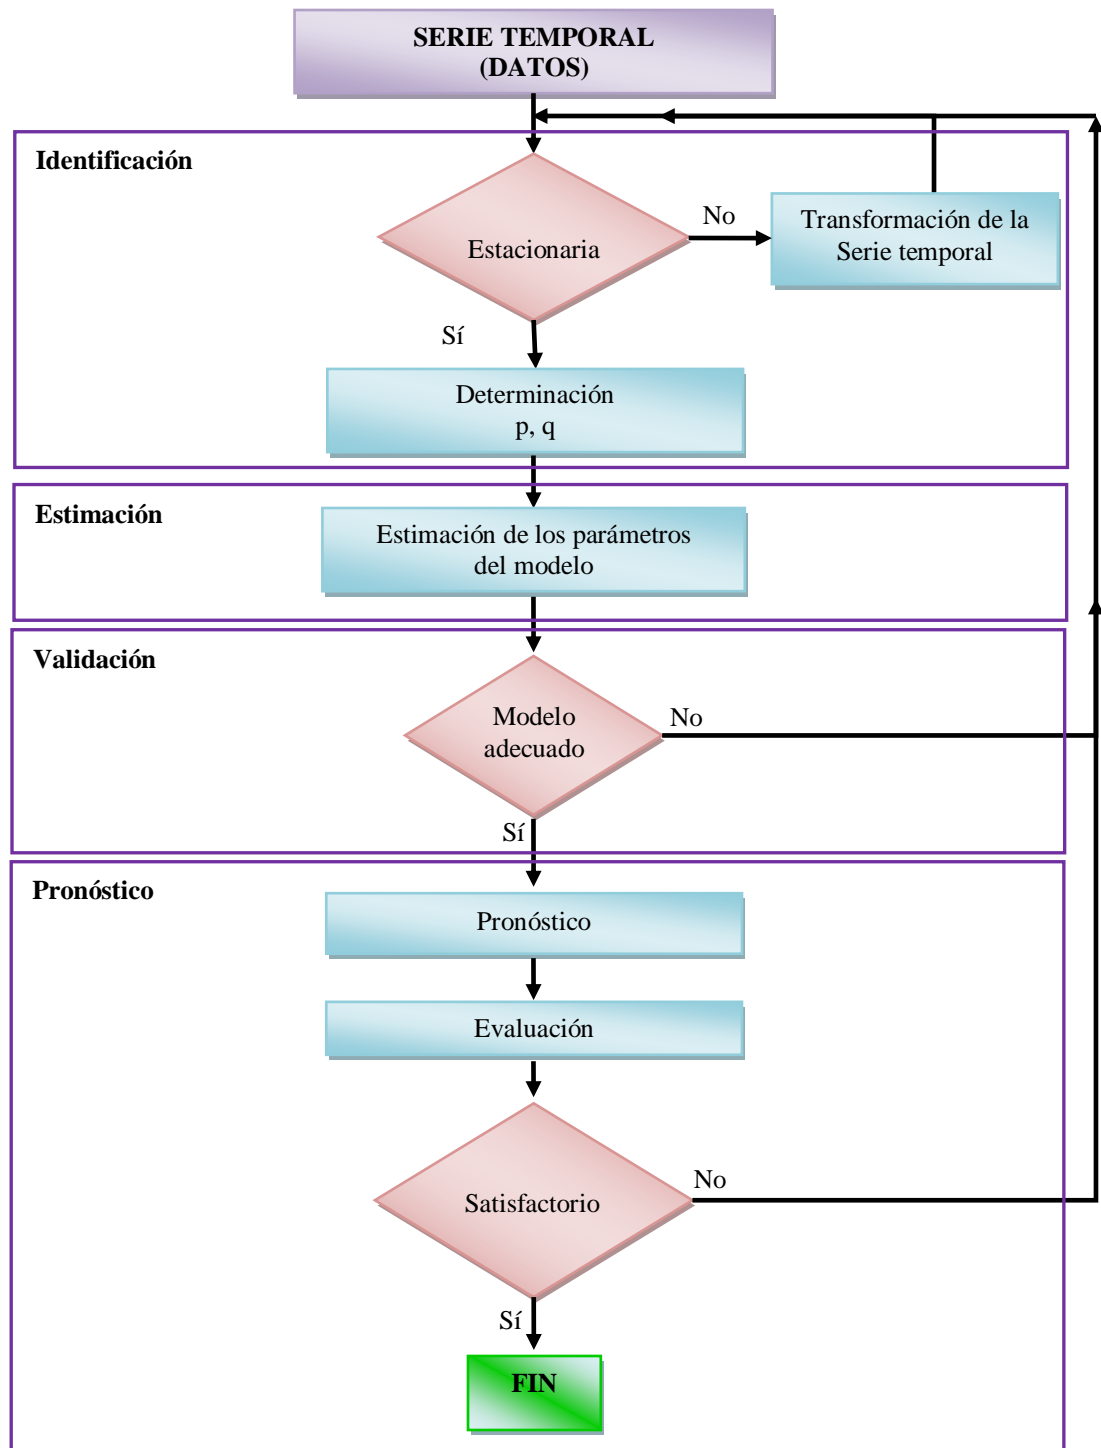
Después de seleccionar un modelo ARIMA particular y de estimar sus parámetros, se verifica que el modelo seleccionado se ajuste a los datos de manera razonable puesto que es posible que otro modelo ARIMA también lo haga [16]. Existen varias pruebas de diagnóstico, pero se utilizarán las más reconocidas universalmente, que se indican a continuación:

- Se comprueba que todos los parámetros estimados son estadísticamente significativos.
- Verificar que la serie temporal formada por los residuos del modelo, es decir, las diferencias entre los valores reales pasados de la serie y las previsiones obtenidas por el modelo, tiene un comportamiento similar a un ruido blanco, para lo cual se analiza su FAC. Es posible que varios de los modelos alternativos estimados pasen las pruebas de diagnóstico, lo que quiere decir que todos ellos son válidos para realizar previsiones. Sin embargo, lo más lógico con uno de ellos; para ello se comparan los errores estándar de los residuos (RSE) de todos, quedándose con el que presente el menor valor.
- La selección del modelo depende de la habilidad del usuario, este es un proceso iterativo.

4. Pronóstico

En esta última fase, se realizan previsiones con el modelo seleccionado al final de la etapa anterior. Para ello, vuelve a ser necesario el uso del ordenador, indicando al programa el número de previsiones que se quieren obtener y el período a partir del cual tiene que calcularlas. [16]

Figura 17. Diagrama de flujo Metodología Box-Jenkins



Fuente: Basado en GUJARATI, Damodar. Econometria. McGraw-Hill, edición 4, 2003.

CAPITULO IV

PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO DISTRIBUCIONES DE PROBABILIDAD

4.1 DISTRIBUCIÓN DE PROBABILIDAD

El modelo de pronóstico de demanda de energía eléctrica basados en distribución de probabilidad se construye ajustando los datos de cada subperiodo a una función de distribución de probabilidad continua con la cual se puede calcular la probabilidad de que la variable aleatoria sea menor igual a un valor dado. Como antes se ha mencionado la demanda de energía eléctrica es una variable aleatoria puesto que sus valores no pueden predecirse en forma exacta ya que dichos valores se ven influenciados por diversos factores descritos en el capítulo 1, por lo cual, la ocurrencia de ciertos valores solo puede expresarse en términos de probabilidad.[32], [33]

Este método asume que los datos de la muestra son independientes entre sí, condición que debe verificarse antes de aplicar el procedimiento de ajuste a una distribución.

Si la muestra global de los datos se ajusta a una distribución de probabilidad se pierde la secuencia cronológica en que ocurren los valores de la variable aleatoria. Una alternativa para conservar la secuencia cronológica de los valores de la variable aleatoria bajo estudio es ajustar a una distribución de probabilidad a los datos de cada subperiodo.

- **Eventos independientes:** Dos eventos son independientes si la ocurrencia de uno, no afecta la probabilidad de ocurrencia del otro.

4.1.1 Método de momentos (MOM). Este método consiste en obtener aproximaciones de los parámetros poblacionales desconocidos a partir de la igualación de momentos muestrales y momentos poblacionales que serán función de dichos parámetros, es decir, se igualarán tantos momentos como parámetros poblacionales tengamos que estimar, como se resultado se tendrá un sistema de n ecuaciones con n incógnitas que son los parámetros a estimar, el sistema tendrá una única solución que serán los valores de los estimadores.

Este método condiciona su validez a que los valores muestrales sean independientes; los momentos muestrales tendrán un valor numérico concreto, calculado a partir de los datos de la muestra; y los momentos poblacionales los conoceremos por el tipo de distribución que sigue o de la función de probabilidad que le corresponda. [1]

Al obligar que los momentos correspondientes sean iguales se cumplirá que no son los momentos centrales de primer orden (las medias) y los momentos mediales de segundo orden (las varianzas) con lo que se cumplen las principales propiedades de los estimadores, es decir, centrados y eficientes.

Sea $\mathbf{X}_1, \mathbf{X}_2, \mathbf{X}_3 \dots \mathbf{X}_n$ una muestra aleatoria de una población con una función de probabilidad $\mathbf{f}(\mathbf{x})$ con $\mathbf{k} = 1, 2, 3 \dots$ se tiene que:

El k-ésimo de la población o el k-ésimo de la distribución $\mathbf{f}(\mathbf{x})$ es $\mathbf{E}(\mathbf{X}^k)$.

El k-ésimo momento muestral es $\left(\frac{1}{n}\right) \sum_{i=1}^n \mathbf{X}_i^k$.

Por consiguiente el primer momento de la población $\mathbf{E}(\mathbf{X}) = \mu$ y el primer momento muestral es $\frac{\sum \mathbf{X}_i}{n} = \bar{\mathbf{X}}$. Los segundos momentos de la población y muestral son $\mathbf{E}(\mathbf{X}^2)$ y $\frac{\sum_{i=1}^n \mathbf{X}_i^2}{n}$ respectivamente.

4.1.2 Método estimación de máxima verosimilitud (MLE). La función de verosimilitud dice que tan probable es que la muestra observada sea una función de los valores de parámetro. Al incrementarse al máximo la probabilidad se obtienen los valores de parámetro con los que la muestra observada es más probable que haya sido generada, es decir, los valores de parámetro que mas concuerdan con los datos observados. Estas estimaciones pueden coincidir con las obtenidas por el método de los momentos. [1]

Se denomina **función de verosimilitud** o función de densidad muestral, al a función formada por el producto de las funciones de probabilidad particularizada para los valores muestrales. Si la población tiene por función de probabilidad $\mathbf{f}(\mathbf{x}, \mathbf{a}, \mathbf{b})$ donde \mathbf{x} es la variable del suceso favorable y \mathbf{a}, \mathbf{b} , los parámetros poblacionales que se quiere estimar (generalmente uno o máximo dos) y sea la muestra $\mathbf{X}_1, \mathbf{X}_2, \mathbf{X}_3 \dots \mathbf{X}_n$ con frecuencias $\mathbf{f}_1, \mathbf{f}_2, \mathbf{f}_3 \dots \mathbf{f}_n$; entonces la función de verosimilitud \mathbf{V} es:

$$\mathbf{V} = [\mathbf{f}(\mathbf{x}_1, \mathbf{a}, \mathbf{b})]^{\mathbf{f}_1} [\mathbf{f}(\mathbf{x}_2, \mathbf{a}, \mathbf{b})]^{\mathbf{f}_2} [\mathbf{f}(\mathbf{x}_3, \mathbf{a}, \mathbf{b})]^{\mathbf{f}_3} \dots [\mathbf{f}(\mathbf{x}_n, \mathbf{a}, \mathbf{b})]^{\mathbf{f}_n} \quad (4.1)$$

El método de Máxima Verosimilitud consiste en hacer máxima esta función, con respecto a los parámetros a estimar, por los procedimientos matemáticos conocidos. Dado a la forma de la función \mathbf{V} , se puede hacer uso de la propiedad que el máximo de una función coincide con el máximo del logaritmo de la misma función, el cálculo del estimador Máxima Verosimilitud se facilita al resolver el sistema:


$$\begin{bmatrix} \frac{\partial(\ln V)}{\partial a} = 0 \\ \frac{\partial(\ln V)}{\partial b} = 0 \end{bmatrix} \quad (4.2)$$

Toda solución de este sistema será el estimador Máxima Verosimilitud del parámetro poblacional.

4.1.3 Criterios de validación o ajuste.

4.1.3.1 Test de Chi cuadrado χ^2 . Esta prueba se utiliza tanto para distribuciones discretas como continuas. [1], [26]

Figura 18. Distribución Chi cuadrado



H_0 : La variable se modela mediante la distribución de probabilidad $f(x)$.

H_a : La variable no se modela mediante la distribución de probabilidad $f(x)$.

- **Grados de libertad:** Se calculan así:

$$\text{gdl} = (r - 1)(c - 1) \quad (4.3)$$

Donde:

r , Número de filas en la tabla de frecuencias observadas

c , Número de columnas


La hipótesis nula de la prueba Chi-cuadrado postula una distribución de probabilidad totalmente especificada como el modelo matemático de la población que ha generado la muestra.

Este contraste se realiza mediante una tabla de frecuencias. Para cada valor o intervalo de valores se indica la frecuencia absoluta observada o empírica O_i . Se supone que la hipótesis nula es cierta y con ello se calcula para cada valor o intervalo de valores la frecuencia absoluta que cabría esperar o frecuencia esperada $E_i = n \cdot p_i$; donde n es el tamaño de la muestra y p_i la probabilidad del i-ésimo valor o intervalo de valores según la hipótesis nula.

La prueba se basa en las diferencias entre la O_i y E_i y se define como:

$$\chi^2 = \sum_{i=1}^k \frac{(\text{Observada} - \text{Teórica})^2}{\text{Teórica}} = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \quad (4.4)$$

Figura 19. Región de aceptación test Chi Cuadrado



Si las frecuencias observadas coinciden o se aproximan mucho a las esperadas, el valor estadístico de χ^2 tiende a cero. Por el contrario si las frecuencias observadas difieren significativamente de las esperadas el valor estadístico de χ^2 será positivo y tan grande cuanto mayor sean las diferencias entre las frecuencias, por tanto aumentará la probabilidad de rechazar la hipótesis de nulidad.

No se puede usar la prueba χ^2 cuando el valor esperado es menor que 5, es decir $E_i \geq 5$, debe tenerse en cuenta que el tamaño muestral n sea grande $n > 30$.

El nivel de significancia es fijado por el analista, generalmente se fija en un nivel de 5% ($\alpha = 0,05$) ó de 1% ($\alpha = 0,01$), el criterio de rechazo de la hipótesis nula debe establecerse previamente al análisis de datos y no subordinarlo a resultados de la investigación.

4.1.3.2 Test de Kolmogorov–Smirnov. Se emplea solo para distribuciones continuas. La ventaja de este método respecto al Chi-cuadrado es que trabaja directamente con la función de distribución empírica encontrada a partir de los valores de la muestra y como consecuencia no requiere la agrupación de los valores en intervalos, este test es válido si todos los parámetros de la distribución son conocidos, es decir, los parámetros no pueden ser estimados a partir de la muestra, en la práctica se emplea aunque los parámetros hayan sido estimados. [1], [26]

H₀ : La distribución observada se ajusta a la distribución teórica.

H_a: La distribución observada no se ajusta a la distribución teórica.

Se construye una función de distribución acumulativa empírica **S(x)**, a partir de los valores de la muestra, también se formula una hipótesis sobre la función de distribución acumulativa teórica **F(x)**, que mejor pueda representar el valor de la muestra, se descompone en intervalos los valores de la muestra se calcula el valor de D según esta expresión:

$$D = \max_i [F(x_i) - S(x_i)] \quad (4.5)$$

Se escoge el valor de **α**, y se rechaza la hipótesis si **D > D_{n,α}** donde **D_{n,α}** es el valor critico.

D, es la distancia máxima entre las dos funciones, por tanto se tiene:

$$D^+ = \max \left[\frac{i}{n} - F(x_i) \right]_{1 \leq i \leq n} \quad D^- = \max \left[F(x_i) - \frac{i-1}{n} \right]_{1 \leq i \leq n} \quad (4.6)$$

La toma de decisión puede llevarse a cabo mediante el empleo del p-valor asociado al D observado. El p-valor se define como:

$$p - \text{valor} = P(D > D_{\text{abs}} / H_0 \text{ es cierta}) \quad (4.7)$$

$$\begin{aligned} \text{Sí } p - \text{valor} &\geq \alpha \text{ Aceptar } H_0 \\ \text{Sí } p - \text{valor} &< \alpha \text{ Rechazar } H_0 \end{aligned} \quad (4.8)$$

Tabla 5. Distribución de probabilidad

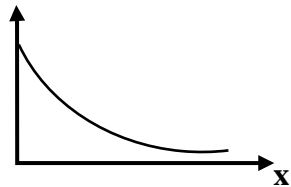
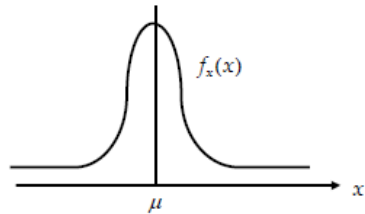
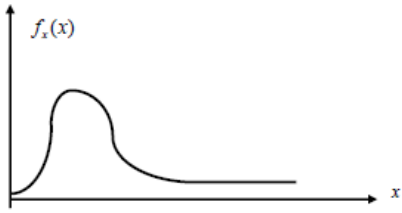
DISTRIBUCIÓN DE PROBABILIDAD	FUNCIÓN DE DENSIDAD	VALOR ESPERADO E(x)	VARIANZA VAR(X)
<p>EXPONENCIAL</p> 	$f(x) = \frac{1}{\mu} * e^{\frac{-x}{\mu}}$	$E(x) = \mu$	$VAR(x) = \mu^2$
<p>NORMAL O GAUSIANA</p> 	$f(x) = \frac{1}{\sigma\sqrt{2\pi}} * e^{\frac{-(x-\mu)^2}{2\sigma^2}}$	$E(x) = \mu$	$VAR(x) = \sigma^2$
<p>LOG NORMAL</p> 	$f(x) = \frac{1}{\sigma x\sqrt{2\pi}} * e^{\frac{-(\ln(x)-\mu)^2}{2\sigma^2}}$	$E(x) = e^{\left(\mu + \frac{\sigma^2}{2}\right)}$	$VAR(x) = e^{2\mu + \sigma^2} [e^{\sigma^2} - 1]$

Tabla 6. (Continuación)

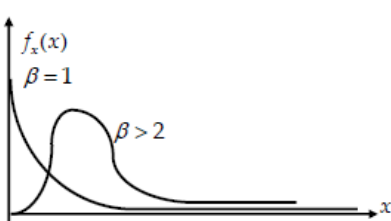
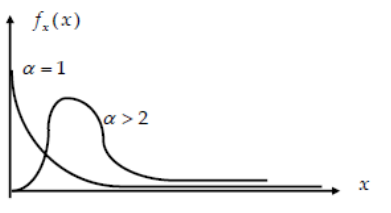
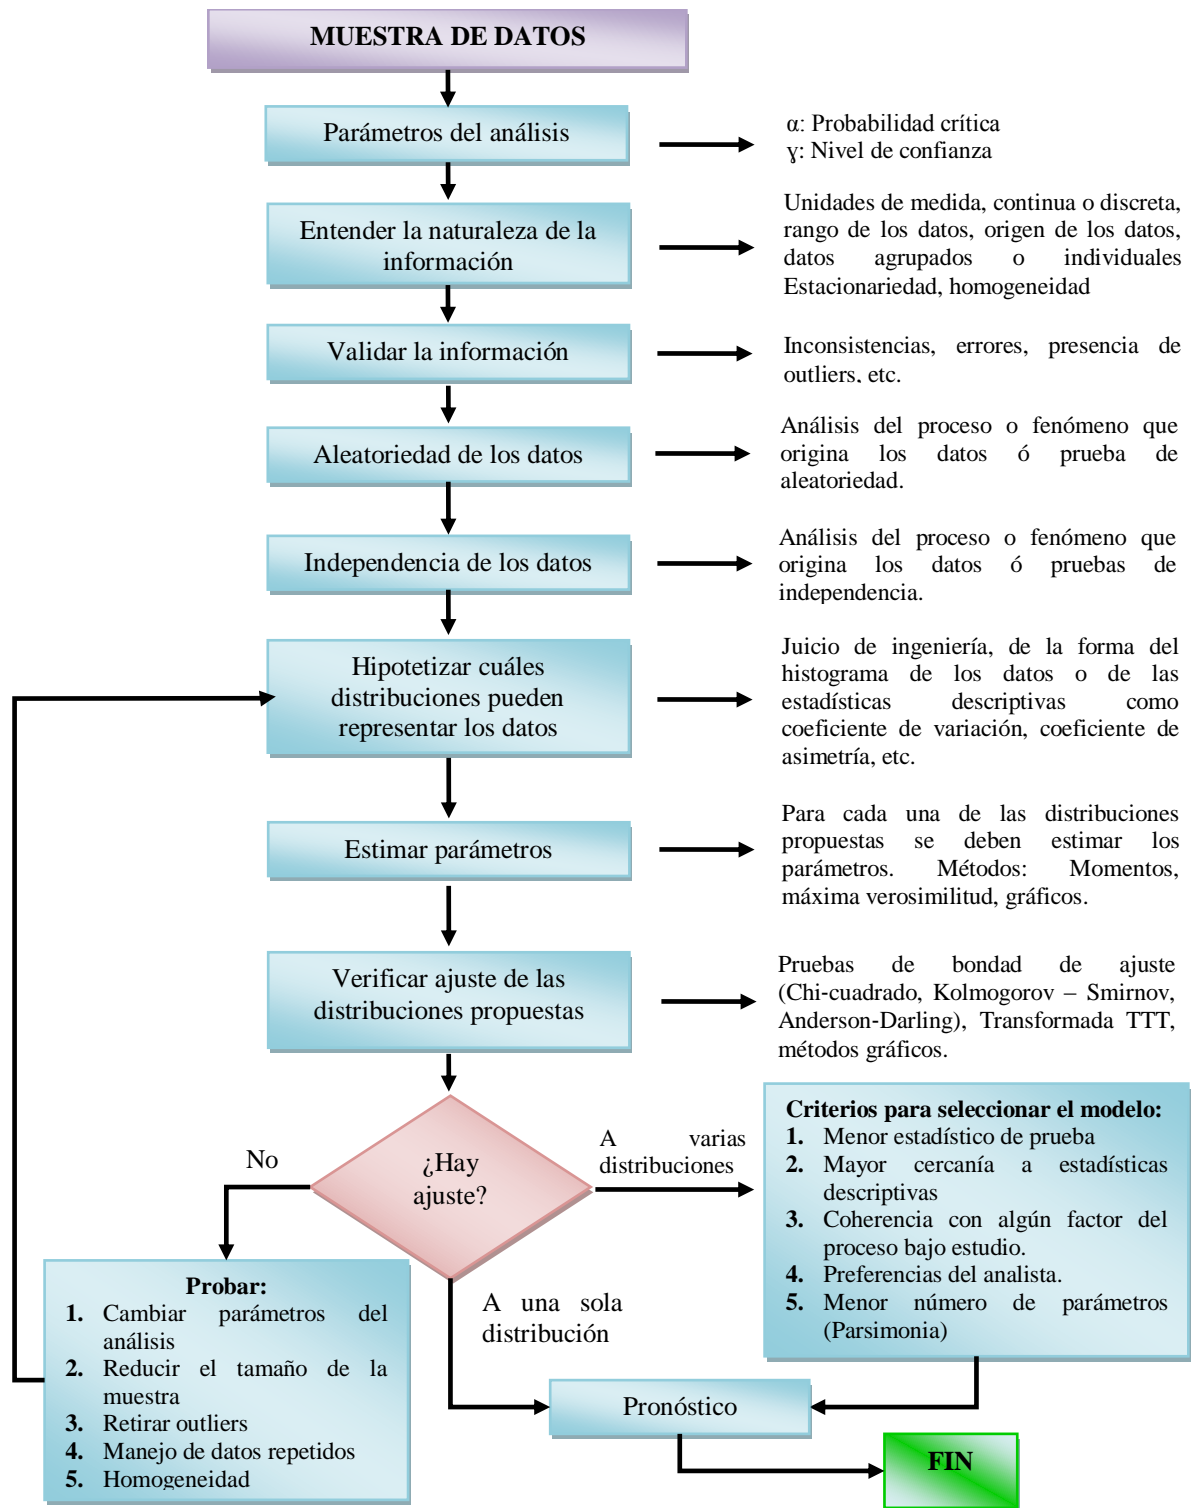
DISTRIBUCIÓN DE PROBABILIDAD	FUNCIÓN DE DENSIDAD	VALOR ESPERADO E(x)	VARIANZA VAR(X)
<p>WEIBULL</p> 	$f(x) = \alpha * \beta * x^{\beta-1} * e^{-\alpha x^\beta}$	$E(x) = \alpha^{\frac{-1}{\beta}} \Gamma(1 + \beta^{-1})$	$VAR(x) = \alpha^{\left(\frac{-2}{\beta}\right)} \left[\Gamma(1 + 2 * \beta^{-1}) - \left(\Gamma(1 + \beta^{-1}) \right)^2 \right]$
<p>GAMMA</p> 	$f(x) = \frac{\beta^{-\alpha} * x^{\alpha-1} * e^{\frac{-x}{\beta}}}{\Gamma(\alpha)}$ <p>Para $x > 0$</p>	$E(x) = \alpha * \beta$	$VAR(x) = \alpha * \beta^2$

Figura 20. Procedimiento para ajustar una distribución a un modelo probabilístico a partir de una muestra de datos



Fuente: ZAPATA, Carlos Julio. Ajuste de datos a una distribución. En: Análisis Probabilístico y Simulación. Pereira: Universidad Tecnológica de Pereira, 2010. p. 106.

CAPITULO V

PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO MICROÁREAS

5.1 MÉTODO DE MICRO ÁREAS

Este método propone que la zona de estudio sea dividida en varias zonas pequeñas llamadas microáreas y esta división debe realizarse tomando en cuenta el sistema eléctrico existente.

Los métodos de proyección de demanda eléctrica con base en microáreas tienen dos etapas de análisis:

1. Uso de tierra
2. Tendencia (Demanda de energía eléctrica)

5.1.1 Uso de tierra. La metodología planteada relaciona los datos de oferta y demanda del suelo y la transforma en información de demanda eléctrica, a través de curvas de carga características. La diferencia entre la demanda estimada y la demanda actual determinará la necesidad y ubicación de nuevas subestaciones de distribución, cuyas características dependerán del área geográfica de estudio, topología de la red y herramientas disponibles. Este procedimiento es de suma importancia, puesto que permite planificar el sistema de distribución a largo plazo, estableciendo las prioridades para su expansión ordenada y económica.

Los modelos de uso de la tierra se dividen en tres submodelos los cuales aportan la suficiente flexibilidad para lograr la obtención de diversos escenarios que definen la demanda de saturación [2], [11], [15], [17], [30]. Estos submodelos se denominan de la siguiente manera:

5.1.1.1 Submodelo de demanda de tierra. Determina la demanda de tierra por parte de los usuarios, pueden ser de tres tipos:


1. Control demanda por clase

Se establece un control total de demanda por clase, es decir, residencial, comercial e industrial; que a su vez pueden estar divididos en subclases. El control en este caso es la densidad de población expresada en habitantes por hectárea, de acuerdo a las disposiciones que dicta planeamiento municipal. [2], [11], [30]

2. Modelo espacial de polos urbanos

Este modelo se basa en la idea intuitiva de que la demanda se difunde desde áreas de alta hacia áreas de baja demanda. Una función de polo urbano modela la tendencia de la carga eléctrica hacia el incremento en el centro de la ciudad. Estas sencillas funciones son frecuentemente satisfactorias en el modelado de toda la distribución espacial de carga, y pueden redefinirse para más aplicaciones. [2], [11], [30]

Figura 21. Submodelo de demanda de suelo- Polos urbanos



3. Modelo urbano del transporte

Este sistema se fundamenta en el concepto de que cada individuo se ubicará en la ciudad tratando de optimizar su tiempo (costo de transporte), también se considera el impacto de las vías de comunicación. [2], [11], [30]


5.1.1.2 Submodelo de oferta de tierra. Determinan la cantidad de tierra disponible por clase de cliente [2], [11], [15]. Al igual que el anterior, dependiendo de la cantidad de datos con los que se cuente se pueden hacer de varias formas:

1. Utilizando valores de adecuación de la tierra para cada uso específico asignados manualmente, por criterio del analista o planificador.
2. Combinación de valores de adecuación con la zonificación existente. Se debe adecuar el uso de la tierra por criterio propio, tomando en cuenta la reglamentación preestablecida de zonificación.
3. Valores de adecuación obtenidos de factores espaciales, tales como proximidad y entorno. Este método considera que ciertas zonas de la ciudad son idóneas solamente para cierto tipo de uso de la tierra.

5.1.1.3 Definición de micro áreas. Para definir el área de interés se deben tener en cuenta varios aspectos entre ellos:

- Se pueden escoger microáreas de 0.25 km², 1 km², 5 km², 7 km², etc., dependiendo del grado de resolución que se desee obtener en el pronóstico de carga, las zonas también pueden dividirse según alimentadores/subestaciones, pero tiene la desventaja que con el paso del tiempo hay transferencia de carga de un alimentador/subestación a otro. Se recomienda utilizar áreas simétricas (500 metros x 500 metros) de este modo se eliminan inconvenientes.
- El uso de microáreas confronta otra dificultad como es la imposibilidad de aplicar tendencia en áreas sin historia, situación que se puede solventar utilizando el concepto de saturación del área o microárea la cual infiere que el crecimiento del área que no se tiene historia se comporta de la misma manera que la de su área de control. En microáreas pequeñas el porcentaje de crecimiento de la demanda es alto y la zona puede saturarse en cortos periodos de tiempo, en cambio si las microáreas son de mayor tamaño el porcentaje de crecimiento de la demanda es más bajo y eso es debido a que el crecimiento brusco de las microáreas ocurre en distintos momentos y si aumentamos el tamaño de las microáreas ese efecto se anula a nivel global.

Figura 22. Curva característica de crecimiento de carga (MWh/año)



- Un concepto importante dentro de la división de un área de servicio de una subestación, en microáreas es el de la ubicación del **centro de gravedad de la carga**, que está definido como un punto con momentos eléctricos iguales, para todas las cargas en el área considerada. [2], [11], [15], [30]

Para encontrar el centro de carga, se escogen arbitrariamente ejes de referencia al plano de micro áreas del área de servicio, entonces se calculan los momentos mediante las siguientes expresiones:

$$X = \frac{\sum_{i=1}^n (\text{Demanda en el eje X} * \text{distancia en X})}{\text{Demanda total}} \quad (5.1)$$

$$Y = \frac{\sum_{i=1}^n (\text{Demanda en el eje Y} * \text{distancia en Y})i}{\text{Demanda total}} \quad (5.2)$$

Se debe tener en cuenta que el centro de gravedad de la carga no es el mismo que el centro geométrico del área de servicio debido a que la carga no se encuentra idealmente distribuida, es decir que la carga se distribuye aleatoriamente en el área de servicio.

Es posible que en un sistema exista la posición de las subestaciones de distribución establecida, y se observa como diferencias del desarrollo relativo y en incremento de potencia en su área de servicio, se va desplazando a lo largo del tiempo el centro de gravedad, dejando la posición de la subestación alejada del mismo.

5.1.1.4 Determinación del factor de saturación por microárea. En el cálculo del factor de saturación, intervienen dos parámetros fundamentales: La población actual y plan de ordenamiento urbano de la zona en estudio; puesto que cada tipo de usuario (residencial, comercial e industrial) tendrá un área proyectada o por ocupar en el futuro, se describe mas detalladamente en las referencias [11], [15], [17], [30]. El factor de saturación se calcula mediante la siguiente expresión:

$$FS = \frac{\sum \text{Usuarios actuales}}{\sum \text{Usuarios futuros o proyectados}} \quad (5.3)$$

Para determinar el número de usuarios presentes o actuales, se toma el número real de usuarios por tipo (residencial, comercial e industrial), de cada modulo de área o microárea y se realiza la sumatoria, el total debe estar ajustado con el total de usuarios realmente servidos.

Luego, para determinar el número de usuarios futuros o proyectados de cada sector se pueden utilizar los siguientes métodos matemáticos detallados en [1], [4],[18], [30]:

1. Método aritmético

$$U_f = U_2 + \frac{U_2 - U_1}{t_2 - t_1} (t - t_2) \quad (5.4)$$

Donde:

U_f = Número de usuarios futuros o proyectados

U_1 = Número de usuarios en el periodo 1

U_2 = Número de usuarios en el periodo 2

t= Período futuro o de proyección

2. Método del porcentaje uniforme de crecimiento

$$U_f = U_{\text{actual}} * (1 + T_c)^n \quad (5.5)$$

Donde:

U_{actual}= Número de usuarios actuales

T_c= Tasa de crecimiento promedio

n= Número de años

3. Método geométrico

$$U_f = U_2 \left(\frac{U_2}{U_1} \right)^{\left(\frac{t-t_2}{t_2-t_1} \right)} \quad (5.6)$$

4. Método logístico o curva en S

$$U_f = \frac{S}{1 + Me^{bt}} \quad (5.7)$$

Donde:

$$S = \frac{2U_0U_1U_2 - U_1^2(U_0 + U_2)}{U_0U_2 - U_1^2} \quad (5.8)$$

$$M = \frac{S - U_0}{U_0} \quad (5.9)$$

$$b = \frac{1}{n} \left[\frac{U_0(S - U_1)}{U_1(S - U_0)} \right] \quad (5.10)$$

$$n = (t_2 - t_1) = (t_1 - t_0) \quad (5.11)$$

5.1.1.5 Demanda máxima por microárea. Por lo tanto para el pronóstico de la demanda máxima de una microárea se proponen dos formas detalladas en las referencias [2], [11], [15], [30].

▪ **Técnica 1**

$$L_k(t) = FS_k * L_{kcalc}(t) \quad (5. 12)$$

Donde:

$L_k(t)$ = Demanda máxima estimada para la microárea k en el año t.

FS_k = Factor de saturación en la microárea k en el año t.

$L_{kcalc}(t)$ = Demanda máxima proyectada matemáticamente para la microárea k en el año t.

▪ **Técnica 2**

Se calcula el índice de uso de área por tipo de usuario así:

$$I_{uso_i} = \frac{\text{Demanda}_i}{A_{uso_i} * F_{carga_i} * F_{p_i} * 8760} \quad (3. 33)$$

Donde:

I_{uso_i} = Índice de uso de área del usuario en la microárea i

Demanda = Consumo anual de energía eléctrica del usuario de la microárea i

A_{uso_i} = Área ocupada por el usuario en la microárea i

F_{carga_i} = Factor de carga del usuario de la microárea i

F_{p_i} = Factor de potencia del usuario de la microárea i

8760 = Horas que hay en un año

$$D_{max} = \sum_{i=1}^n I_{uso_i} * A_{f_i} \quad (3. 34)$$

Donde:

A_f = Área futura o a ocupar por el usuario en la microárea i

El área futura son proyectos de construcción o la estimación realizada en el plan de ordenamiento territorial.

5.1.2 Tendencia (Demanda de energía eléctrica). Estas técnicas se caracterizan por extrapolar la carga basada en la información histórica de la demanda de energía eléctrica y requieren un mínimo de datos por lo que su implementación resulta muy fácil. Entre los métodos de tendencia se encuentran [2], [30]:

5.1.2.1 Modelo de carga. Con este submodelo se logran obtener los índices de demanda que definen la magnitud de demanda en un área específica. Se utilizan tres tipos de técnicas:

1. Índices de demanda

El índice de demanda es un indicador de la demanda eléctrica según la cantidad y concentración de infraestructuras dentro de un área urbana determinada. Está dado en kVA/Ha (demanda sobre hectárea). [15], [17], [30]

$$I_k^c(t) = \frac{L_k^c(t)}{a_k^c(t)} \quad (5.13)$$

Donde:

$I_k^c(t)$ = Índice de demanda de la microárea k, en el año t, del sector c

c = Sectores de consumo (Residencial, Comercial, industrial)

$a_k^c(t)$ = Área ocupada por el sector c, en la microárea k en el año t

$L_k^c(t)$ = Demanda eléctrica por unidad de área del sector c en el año t

2. Curva de demanda diaria típica de cada clase

Esta técnica indica explícitamente el comportamiento de la carga eléctrica y ubicar los distintos picos diarios que ocurren. [15], [17], [30]

$$L_k(h) = \sum_{c=1}^c (a_k^c(t) * L_c(t, h)) \quad (5.14)$$

Donde:

$L_k(h)$ = Carga en la microárea k, en la hora h

$a^c_k(t)$ = Cantidad de uso de tierra del sector c, en la microárea k en el año t

$L_c(t, h)$ = Demanda eléctrica en una unidad de tierra del sector c, en el año t, en la hora h del día pico.

En este caso se consideran curvas de 24 horas en lugar de un valor único, al considerar dichas curvas por sector, se debe tener en cuenta que la demanda pico por cada clase no es coincidente en el tiempo.

3. Curva de demanda diaria típica por subclase de cada clase (análisis de usuario)

En este tipo se disgrega la carga eléctrica de cada clase en subclases; las cuales se constituyen por las distintas curvas de consumo de cada uno de los equipos eléctricos utilizados, es decir, en el caso residencial se genera subclases como iluminación, calefacción/aire acondicionado, cocción entre otras. Esta técnica permite al analista o planificador evaluar distinto escenarios donde cambie la utilización de dichos aparatos. [2], [15], [17], [30]

5.1.2.2 Ajuste de tendencia con curva polinómica. Predice el valor de demanda futura basada en la extrapolación de datos de demanda histórica. En general, el ajuste de la curva se aplica a los datos anuales de carga máxima debido a que la carga máxima anual es el valor más importante para la planificación y es el de más fácil obtención en subestaciones y alimentadores. [17], [30]

$$L_n(t) = a_n t^3 + b_n t^2 + c_n t + d_n \quad (5.15)$$

Donde:

$L_n(t)$ = Carga máxima para la subestación n para el año t

n = numero de área de la subestación 1...n

t = año de carga 1...t

a_n, b_n, c_n, d_n = Coeficientes del polinomio particular para la subestación n.

Esta técnica encuentra un conjunto único de coeficientes a_n, b_n, c_n, d_n para el historial de de demanda de una subestación en particular.

5.1.2.3 Regresión multivariable. Los métodos multivariantes de predicción espacial de carga, hacen uso no sólo los valores del pico de carga anual $L_k(t)$, sino que además utilizan otras variables adicionales relacionadas con factores demográficos, económicos, nivel de equipamiento entre otras sobre cada microárea. Estas variables forman un “vector de datos” para cada área llamado $V_k(t)$. [15], [17], [30]

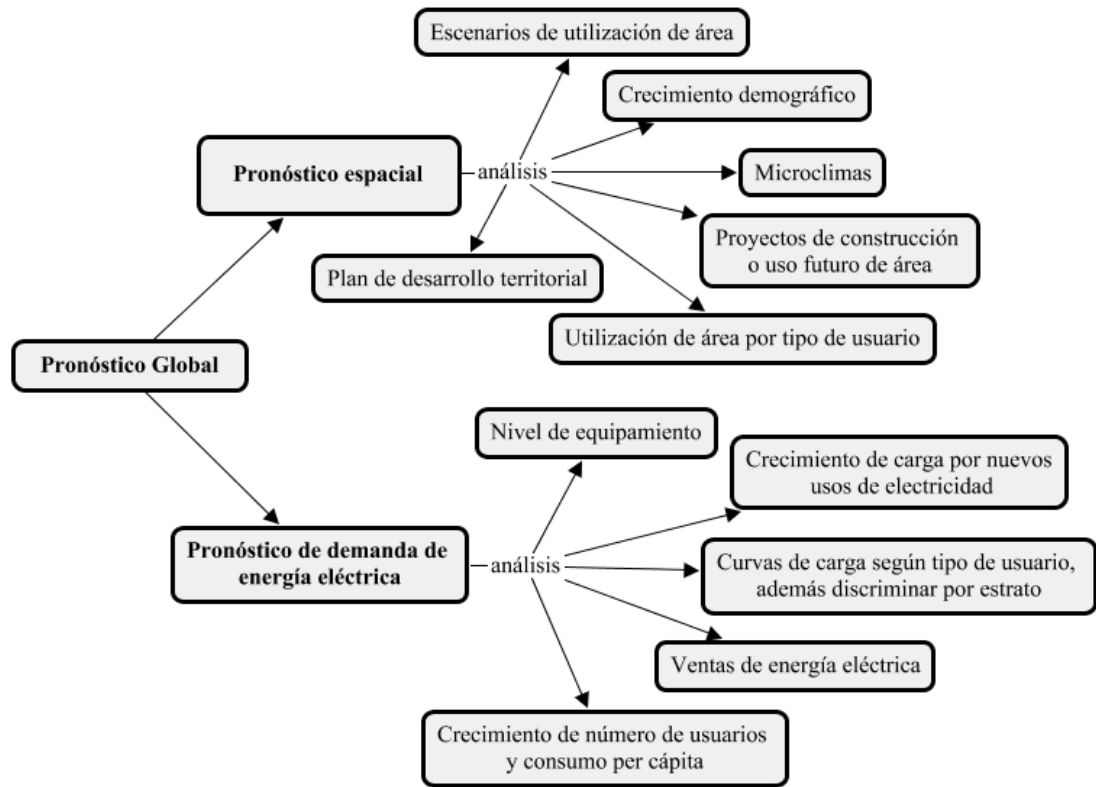
$$V_k(t) = (v_{1,k}(t), v_{2,k}(t), \dots, v_{i,k}(t)) \quad (5.16)$$

Donde $v_{i,k}(t)$ es la variable i en el año t , para la microárea k .

5.1.2.4 Técnica de inferencia de áreas vacías. Se utiliza para extender en forma automática las tendencias de crecimiento encontradas en aquellas áreas sin carga o vacías, dichas áreas no han tenido suministro de energía. Se puede inferir proyectando de una manera global toda la zona y se comprara con la suma de las tendencias individuales de cada microárea con historia dejando una microárea que será la vacía, la diferencia que resulte de estos dos valores será la correspondiente a la microárea vacía. [2], [11], [15], [17], [30]

5.1.2.5 Transferencia de carga. Este método utiliza la regresión múltiple ajustando una función polinómica a los datos de carga histórica (pico anual) de cada alimentador/subestación de cada microárea, dichas funciones se utilizan luego para extrapolar el crecimiento de carga futura de cada microárea. La ventaja de esta técnica es que reduce errores en el pronóstico debido a la transferencia de carga entre alimentadores/subestación. [2], [11], [15], [17], [30]

Figura 23. Esquema de pronóstico global (Espacial y Eléctrico)



5.2 METODOLOGÍA PARA EL PRONÓSTICO DE ENERGÍA ELÉCTRICA UTILIZANDO MICROÁREAS

La información necesaria para la aplicación del método es:

- Datos históricos número de usuarios por cuadrícula (Residencial, Industrial y Comercial)
- Área ocupada por cada tipo de usuario
- Datos históricos de demanda de energía por cada tipo de usuario y factor de potencia.
- Localización de subestaciones (Capacidad instalada, Demanda actual)
- Área por ocupar o proyectos por construir (residencial, comercial e industrial), estimada en el plan de ordenamiento territorial.

A continuación se enuncia el procedimiento a seguir:

1. Horizonte de pronóstico

El horizonte del pronóstico se establece dependiendo de la base de datos con la que se cuente y los objetivos trazados, como se menciona en el **numeral 1.5.1**.

2. Definir área de estudio

Delimitar la zona de estudio (dimensiones en Ha)

3. Establecer cuadrículas en el área de estudio (microáreas)

El tamaño de las cuadrículas es a criterio del analista pero se recomienda 500m x 500m para una buena resolución como se explica en el **numeral 5.1.1.3**. Es importante contar con esta información en formato digital pues en el mercado hay programas que permiten la simulación de predicción de carga a través de análisis de utilización de suelos como por ejemplo el **SLF-2 del paquete CADPAD® de Westinghouse**.

4. Localizar subestaciones en las cuadrículas

Se debe localizar las subestaciones en las cuadrículas con el objetivo establecer la necesidad de expansión, para ello debe calcularse centro de gravedad de la carga.

5. Establecer número y tipo de usuarios por cuadrícula

Para cada microárea se establecerá su tendencia de desarrollo en función de la utilización del suelo prevista, con los datos históricos y actuales se determinará la etapa de desarrollo actual y de esta manera definir la demanda que se esperaría para los próximos años.

6. Calcular índice de demanda por cada tipo de usuario (kVA/Ha)

Se estima la demanda eléctrica de cada tipo de usuario en relación con el área ocupada, como se describe en el **numeral 5.1.2.1**

7. Determinar crecimiento de suscriptores por tipo de usuario

Los usuarios residenciales crecen y se comportan de manera diferente respecto al comercial o industrial, por ende se debe determinar la tasa de crecimiento para cada uno de ellos y con esta información determinar el número de usuarios futuros; para realizar este análisis se grafica número de usuarios vs año, y se calcula por alguno de los métodos enunciados en el **numeral 5.1.1.4**

8. Calcular factor de saturación por cuadrícula (microárea)

Una vez estimados los usuarios futuros o proyectados por medio de las técnicas mencionadas en el **numeral 5.1.1.4**, se procede hacer la relación entre consumidores actuales y proyectados.

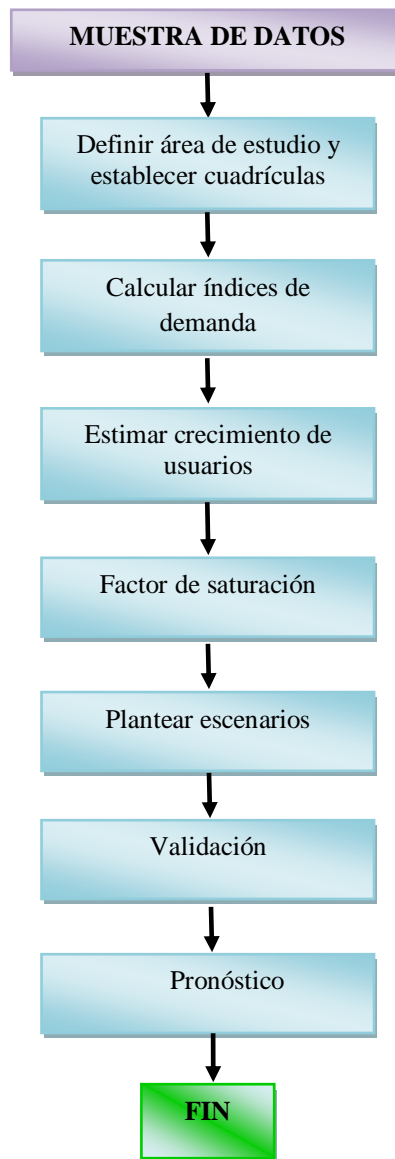
9. Plantear diversos escenarios de utilización de terrenos

Establecer escenarios optimistas, medio y pesimista, es decir un escenario donde la demanda de saturación sea la máxima; uno medio donde los parámetros tomados en cuenta para establecer la demanda de saturación no consideran todos los crecimientos posibles en la zona y finalmente un escenario pesimista cuya magnitud de demanda es la mínima y suele utilizar parámetros de crecimientos mínimos en el área de estudio.

10. Calcular demanda máxima por microárea.

Se estima según la técnica 1 o 2 descrita en el **numeral 5.1.1.5**, esta demanda se estima dependiendo de los escenarios establecidos.

Figura 24. Procedimiento para pronósticos utilizando microáreas



CAPITULO VI

PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA EN SISTEMAS DE DISTRIBUCIÓN UTILIZANDO REDES NEURONALES ARTIFICIALES

6.1 MÉTODO REDES NEURONALES ARTIFICIALES


Están inspiradas en las redes neuronales biológicas del cerebro humano, las cuales intentan interactuar con objetos del mundo real del mismo modo que lo hace el sistema biológico. Una red neuronal artificial es una estructura compuesta de un número de unidades interconectadas (neuronas artificiales). Cada unidad posee una característica de entrada/salida e implementa una computación local o función. La salida de cualquier unidad está determinada por su característica de entrada/salida, su interconexión con otras unidades, y (posiblemente) de sus entradas externas.

Las redes neuronales, permiten aproximar funciones no lineales, esto permite modelar fenómenos complejos donde las variables no están correlacionadas. Así con aplicaciones de RNA se han obtenido atractivos resultados en medicina, economía, comunicaciones y otras áreas del conocimiento, siendo una de sus características la eliminación de hipótesis de reducción de linealidad que ha dominado el análisis de diferentes problemas a lo largo del tiempo. Si bien, la hipótesis de simplificación, permite desarrollar formulaciones de modelos matemáticos para explicar fenómenos de diversa naturaleza; no es posible desechar el modelo lineal básico, que se sustenta justamente en la linealidad de sus ecuaciones. [13], [20]

6.1.1 Elementos de una red neuronal.

6.1.1.1 Neurona artificial. Son elementos simples de cálculo que a partir de un vector de entrada procedente del mundo exterior, y/o a partir del estímulo recibido de otras neuronas proporcionan una respuesta única (salida).

Figura 25. Relación entre una neurona biológica y artificial



6.1.1.2 Unidad de proceso. La distribución de neuronas dentro de la red se realiza formando niveles o capas, con un número determinado de dichas neuronas en cada una de ellas [13], [20]. A partir de su ubicación dentro de la red, se pueden distinguir tres tipos de capas:

1. Capa de entrada

Es la capa que recibe directamente la información proveniente de las fuentes externas de la red.

2. Capa Ocultas

Son internas a la red y no tienen contacto directo con el entorno exterior. El número de niveles ocultos puede estar entre cero y un número elevado. Las neuronas de las capas ocultas pueden estar interconectadas de distintas maneras, lo que determina, junto con su número, las distintas topologías de redes neuronales.

3. Capa de salida

En esta capa se transfiere la información de la red hacia el exterior.

6.1.1.3 Estado de activación. Todas las neuronas de la red presentan cierto estado inicial, de reposo o excitación que depende de su valor de activación. Este valor puede ser continuo (**generalmente** $[0, 1]$ o $[-1, 1]$) o discreto ($\{0, 1\}, \{-1, 1\}$), es decir, suelen tomar un conjunto discreto de valores binarios, así un estado activo se indicaría con el número uno (1) y un estado pasivo estaría representado por el número cero (0); pueden ser limitado o ilimitado, según la entrada total recibida y el umbral de la propia neurona. [13], [20]

Si se designa como $\mathbf{a}_i(t)$ la activación de la i -ésima unidad \mathbf{U}_i respecto al momento de tiempo t , resulta posible definir el vector:

$$\mathbf{A}(t) = [\mathbf{a}_1(t), \dots \mathbf{a}_i(t), \dots \mathbf{a}_n(t)] \quad (6.1)$$

Que representa el estado de activación total de todas las neuronas de la red (de entrada, ocultas y de salida).

Desde el punto formal se interpreta como el producto escalar de los vectores de entrada y los pesos de la red así:

$$\text{Net}_j(t) = \sum_i^N \mathbf{w}_{ij} \cdot \mathbf{x}_i(t) = \mathbf{w}_j^T \cdot \mathbf{x}_i \quad (6.2)$$

Donde \mathbf{w}_j^T , vector transpuesto representativo de los N pesos de entrada que llegan a la j -ésima neurona, siendo $\mathbf{w}_j^T = (\mathbf{w}_{1j}, \dots, \mathbf{w}_{ij}, \dots \mathbf{w}_{iN})$, y \mathbf{x}_i la i -ésima entrada a la j -ésima neurona. Otra regla de tipo no lineal de uso más limitado que implica una interacción de tipo multiplicativo entre las entradas de la neurona es:

$$\text{Net}_j(t) = \sum_{i_1 i_2 \dots i_N} \mathbf{w}_{i_1 i_2 \dots i_N, j} \mathbf{x}_{i_1} \mathbf{x}_{i_2} \dots \mathbf{x}_{i_N} \quad (6.3)$$

6.1.1.4 Conexiones y pesos sinápticos. Las conexiones que unen a las neuronas que forman una RNA tiene asociado un peso, que es el que hace que la red adquiera conocimiento. Se considera que el efecto de cada señal es aditivo, de tal forma que la entrada neta que recibe una neurona (potencial postsináptico) net_j es la suma del producto de cada señal individual por el valor de la sinapsis que conecta ambas neuronas y es lo que se conoce como regla de propagación. [13], [20]

$$\text{Net}_j = \sum_i^n \mathbf{w}_{ji} \cdot \mathbf{y}_i \quad (6.4)$$

Se utiliza una matriz \mathbf{W} con todos los pesos \mathbf{w}_{ji} , si \mathbf{w}_{ji} es positivo indica que la relación entre las neuronas es excitadora, es decir, siempre que la neurona i esté activada, la neurona j recibirá una señal que tenderá a activarla. Si por el contrario \mathbf{w}_{ji} es negativo, la sinapsis será inhibitoria. En este caso si i está activada, enviará una señal que desactivará a j . Finalmente si \mathbf{w}_{ji} es 0 se supone que no hay conexión entre ambas.

6.1.1.5 Función de activación. La función de activación combina la entrada total a la j -ésima neurona o potencial postsináptico (Net_j), obtenido a partir de estímulos y pesos recibidos, con el estado inicial de la neurona $[a_j(t-1)]$ para producir un nuevo estado de activación acorde con la nueva información recibida $[a_j(t)]$. [13], [20]

$$a_j(t) = f[a_j(t-1), \text{Net}_j(t)] \quad (6.5)$$

En muchos modelos de RNA se considera que el estado actual de la neurona no depende de su estado previo, por lo que la expresión anterior se simplifica así:

$$a_j(t) = f[\text{Net}_j(t)] = f\left[\sum_{i=0}^N w_{ij}(t) \cdot x_i(t)\right] \quad (6.6)$$


Por lo general la función de transferencia es determinista, en la mayoría de los modelos monótona creciente y continua respecto al nivel de excitación de la neurona, tal como se observa en los sistemas biológicos. Las funciones de transferencias típicas son:

1. Función de activación Escalón

Presenta salidas binarias, por lo general ($\{0, 1\}$ ó $\{-1, 1\}$). Si la activación de la neurona es inferior a determinado umbral, la salida se asocia con un determinado output y si es igual o superior se asocia con el otro output. Entre las redes que utilizan este tipo de función de transferencia está el Perceptrón simple, la red de Hopfield discreta, y la neurona clásica de McCulloch-Pitts. [13], [20]

$$y(x) = \begin{cases} 1 & \text{si } x \geq 0 \\ 0 & \text{si } x < 0 \end{cases} \quad (6.7)$$

Figura 26. Función de activación Escalón




2. Función de activación Identidad o Lineal

Este tipo de función devuelve directamente el valor de la activación de la neurona, se utiliza en redes de baja complejidad como el modelo Adaline (Widrow, 1987). [13], [20]

$$y(x) = x \quad (6.8)$$

Figura 27. Función de activación Identidad o Lineal




3. Función de activación Mixta o Lineal a tramos

Es una variante progresiva de la función escalón. Si la activación de la unidad es menor que un límite inferior preestablecido, la salida se asocia con determinado valor; si la activación es igual o superior que un límite superior la salida se asocia con otro valor. Si el nivel de activación se encuentra comprendido entre ambos límites se aplica la función de identidad o lineal. Esta alternativa puede considerarse como una función lineal saturada en sus extremos, siendo de gran sencillez computacional y resultando más plausible desde el punto de vista biológico. [13], [20]

$$y(x) = \begin{cases} -1, & x \leq -1 \\ x, & -1 < x < 1 \\ 1, & x \geq 1 \end{cases} \quad (6.9)$$

Figura 28. Función de activación Mixta




4. Función de activación Sigmoidal

Definida en un determinado intervalo monótonico con límites superiores e inferiores. Se caracterizan por presentar una derivada siempre positiva e igual a cero en sus límites asintóticos. [13], [20]

$$y(x) = \frac{1}{1 + e^{-x}} \quad (6.10)$$

Figura 29. Función de activación Sigmoidal




5. Función Tangente Hiperbólica

Es semejante a la función logística o Sigmoidal, pero su salida está entre -1 y 1 . Se utiliza con frecuencia en redes multicapas. En forma matemática se expresa como [13], [20]:

$$y(x) = \tanh x \quad (6.11)$$

Figura 30. Función de activación Tangente hiperbólica




6. Función Gaussiana

Su rango está entre 0 y 1. Se utiliza en redes neuronales de función de base radial, las cuales pueden aplicarse a problemas de predicción [13], [20]. Su expresión matemática es:

$$y(x) = Ae^{-Bx^2} \quad (6.12)$$

Figura 31. Función de activación Gaussiana



6.1.1.6 Función de salida o transferencia. Asociada con cada unidad hay una función de salida, que transforma el estado actual de activación en una señal de salida [13], [20]. Existen cuatro funciones de transferencia típicas que determinan distintos tipos de neuronas: Escalón, Lineal y Mixta, Sigmoidal, Gaussiana.

6.1.1.7 Regla de aprendizaje. El aprendizaje puede ser comprendido como la modificación de comportamiento inducido por la interacción con el entorno y como resultado de experiencias, que conduce al establecimiento de nuevos modelos de respuesta a estímulos externos. En el cerebro humano el conocimiento se encuentra en la sinapsis. [13], [20]

En el caso de las RNA el conocimiento se encuentra en los pesos de las conexiones entre neuronas. Todo proceso de aprendizaje implica cierto número de cambios en estas conexiones. En realidad, puede decirse que se aprende modificando los valores de los pesos de la red.


6.1.2 Topología de redes neuronales. La topología o arquitectura de las RNA's hace referencia a la organización y disposición de las neuronas en la red formando capas de procesadores interconectados entre sí a través de sinapsis unidireccionales la arquitectura de una red neuronal artificial depende de cuatro parámetros principales: Número de capas del sistema, número de neuronas por capa, grado de conectividad entre las neuronas y el tipo de conexiones neuronales. Por su parte la conectividad entre los nodos de la red está relacionada con la forma de transmisión de las salidas de las distintas unidades y su transformación en inputs de otros procesadores [13], [20]. Las topologías neuronales pueden clasificarse atendiendo a distintos criterios:

6.1.2.1 Según la estructura en capas.

1. Redes monocapa

Compuestas por una única capa de neuronas, entre las que se establecen conexiones laterales y en ocasiones autorrecurrentes. Este tipo de redes suele utilizarse en problemas de auto asociación. [13], [20]

Figura 32. Red Monocapa



Donde:

(c) = Conexiones laterales

(d) = Conexiones autorrecurrentes

2. Redes multicapa

Las neuronas están dispuestas en varias capas (entrada, oculta(s), salida). La capa a la que pertenece la neurona puede distinguirse mediante la observación del origen de las señales que recibe y el destino de las señales que genera.

El número de elementos de procesamiento puede variar en unas capas respecto a otras. Las funciones (tanto de activación como de salida) de los elementos de procesamiento pueden ser diferentes. En general, cuanto mayor sea la diferencia entre los elementos de entrada y los de salida, será necesario dotar a la estructura de más capas ocultas. Estas capas ocultas crean una representación interna de los patrones de entrada. La habilidad de la red para procesar información crece en proporción directa al número de capas ocultas.


Según, el número de interconexiones entre capas las redes se clasifican en: totalmente conectadas y localmente conectadas. En las redes totalmente conectadas la salida de un elemento de procesamiento de la capa i es entrada a todos los elementos de procesamiento de la capa $i+1$. Por el contrario, en las redes localmente conectadas, la salida de un elemento de procesamiento de la capa i es entrada a una región de elementos de procesamiento de la capa $i+1$. [13], [20]

6.1.2.2 Según el flujo de datos en la red

1. Redes unidireccionales o de propagación hacia adelante (feedforward)

Ninguna salida neuronal es entrada de unidades de la misma capa o de capas precedentes. La información circula en un único sentido desde las neuronas de entrada hacia las neuronas de salida de la red. [13], [20]

Figura 33. Red multicapa de propagación hacia adelante




Donde:

(a) = Conexiones hacia adelante

2. Redes de propagación hacia atrás (feedback)

Las salidas de las neuronas pueden servir de entrada a unidades del mismo nivel (conexiones laterales) o de niveles previos. Las redes de propagación hacia atrás que presentan lazos cerrados se denominan sistemas recurrentes. [13], [20]

Figura 34. Red multicapa de propagación hacia atrás (Feedback)



Donde:

(a) = Conexiones hacia adelante

(b) = Conexiones hacia atrás

(c) = Conexiones laterales

(d) = Conexiones autorrecurrentes

6.1.2.3 Según el tipo de respuesta de la red o asociación entrada y salida.

1. **Redes heteroasociativas.** Este tipo de red las neuronas están entrenadas para que ante la presentación de un determinado patrón A, el sistema responda con otro patrón diferente B. Estas redes precisan al menos de dos capas, una para captar y retener la información de entrada y otra para mantener la salida con la información asociada, estas a su vez pueden clasificarse según el objetivo de utilización distinguiéndose las destinadas a computar una función matemática a partir de las entradas que reciben, redes utilizadas para tareas de clasificación, redes para la asociación de patrones etc. [13], [20]
2. **Redes autoasociativas.** Entrenadas para que asocien un patrón consigo mismo, residiendo su interés en que ante la presentación de un patrón A' afectado por ruido su respuesta sea el patrón original A, actuando como un filtro. Estas redes pueden implementarse con una única capa de neuronas que comenzara reteniendo la información de entrada y terminara representando la información autoasociada, si se desea mantener la información de entrada y salida deberán añadirse capas adicionales. Estos modelos se utilizan en tareas de filtrado de información para analizar relaciones de vecindad entre los datos considerados y para resolver problemas de optimización. [13], [20]

6.1.3 Mecanismo de aprendizaje. El aprendizaje, es un proceso de adaptación al entorno; durante el se crean y manipulan representaciones que sean capaces de explicar dicho entorno. En una red neuronal el aprendizaje es el proceso por el cual una red neuronal modifica sus pesos en respuesta a una información de entrada. Los cambios que se producen durante el proceso de aprendizaje se reducen a la destrucción, modificación y creación de conexiones entre las neuronas, la creación de una nueva conexión implica que el peso de la misma pasa a tener un valor distinto de cero, una conexión se destruye cuando su peso pasa a ser cero. Se puede afirmar que el proceso de aprendizaje ha finalizado (la red ha aprendido) cuando los valores de los pesos permanecen estables. [13], [20]

$$\frac{dw_{ij}}{dt} = 0 \quad (6.13)$$

Existen tres formas de aprendizaje: Supervisado, No supervisado (o auto supervisado) y Reforzamiento (se puede considerar como un caso especial del aprendizaje supervisado).

Existen una gran cantidad variedad de algoritmos dentro de cada una de estas categorías.

6.1.3.1 Supervisado. El proceso de aprendizaje se realiza mediante un entrenamiento controlado por un agente externo (supervisor, maestro) que determina la respuesta que debería generar la red a partir de una entrada determinada. El supervisor comprueba la

salida de la red y en el caso de que ésta no coincida con la deseada, se procederá a modificar los pesos de las conexiones, con el fin de conseguir que la salida se aproxime a la deseada. Se consideran tres formas de llevar a cabo este tipo de aprendizaje [13], [20]:

1. Aprendizaje por corrección de error

Este tipo de entrenamiento consiste en presentar al sistema un conjunto de datos de entrada y la salida deseada para dicha entrada ajustando los pesos en función de la diferencia entre los valores deseados y los obtenidos como salida de la red. El objetivo, es minimizar el error entre la salida deseada y la salida que se obtiene. [13], [20]

2. Aprendizaje por refuerzo

Es más lento que el anterior. No se dispone de un ejemplo completo del comportamiento deseado pues no se conoce la salida deseada exacta para cada entrada sino que se conoce el comportamiento de manera general para diferentes entradas. La relación entrada-salida, se realiza a través de un proceso de éxito o fracaso, produciendo este una señal de refuerzo que mide el buen funcionamiento del sistema. La función del supervisor es más la de un crítico que la de un maestro. [13], [20]

3. Aprendizaje estocástico

Este tipo de aprendizaje consiste básicamente en realizar cambios aleatorios de los valores de los pesos y evaluar su efecto a partir del objetivo deseado y de distribuciones de probabilidad. [13], [20]

Tabla 7. Tipos de aprendizaje supervisado

TIPO DE APRENDIZAJE SUPERVISADO		MODELO DE RED
APRENDIZAJE POR CORRECCIÓN DE ERROR	OFF LINE	Perceptrón
		Adeline/Madeline
		Backpropagation
		Brain State in a Box
		Counterpropagation
APRENDIZAJE POR REFUERZO	ONLINE	Linear Reward Penalty
		Associative Reward Penalty
		Adaptative Heuristic Critic
APRENDIZAJE ESTOCÁSTICO	OFF LINE	Boltzmann Machine
		Cauchy Machine

Fuente: Basado en HILERA, José y MARTÍNEZ, Víctor. Redes Neuronales Artificiales: Fundamentos, Modelos y Aplicaciones. Addison Wesley Iberoamericana, Madrid.1995

6.1.3.2 No supervisado. Estas redes no requieren influencia externa para ajustar los pesos de las conexiones entre neuronas. La red no recibe ninguna información por parte del

entorno que le indique si la salida generada es o no correcta, así que existen varias posibilidades en cuanto a la interpretación de la salida de estas redes, [13], [20] tales como:

- **Familiaridad o Similitud:** Semejanzas entre la información actual y la información pasada.
- **Codificación:** En este se realiza una codificación de los datos de entrada, generando a la salida una versión codificada de la entrada, con menos bits, pero manteniendo la información relevante de los datos.
- **Mapeo:** Algunas redes con aprendizaje no supervisado realizan un mapeo de características, obteniéndose en las neuronas de salida una disposición geométrica que representa un mapa topográfico de las características de los datos de entrada, de tal forma que si se presentan a la red informaciones similares, siempre sean afectadas neuronas de salidas próximas entre sí, en la misma zona del mapa.
- **Clusterización o establecimiento de clases:** La red se encarga de encontrar las características propias de cada clase.

En general en el aprendizaje no supervisado se suelen considerar dos tipos:

1. Aprendizaje Hebbiano

Consiste básicamente en el ajuste de los pesos de las conexiones a partir de la correlación existente entre las salidas generadas por cada celda [13], [20]:

$$\Delta W_{ij} = y_i \cdot y_j \quad (6.14)$$

La regla de Hebb es de tipo no supervisado, pues la modificación de los pesos depende de los estados (salidas) de las neuronas obtenidas tras la presentación de un estímulo determinado, con independencia de que coincidan o no con las deseadas. De esta forma en el aprendizaje hebbiano múltiples neuronas de salida pueden activarse simultáneamente.

2. Aprendizaje Competitivo y Cooperativo

Las neuronas compiten (y cooperan) unas con otras con el fin de llevar a cabo una tarea dada. Con este tipo de aprendizaje se pretende que cuando se presente a la red cierta información de entrada, solo una de las neuronas de salida se active (alcance su valor de respuesta máximo). Por tanto las neuronas compiten por activarse, quedando finalmente una, o una por grupo, como neurona vencedora. El procedimiento de entrenamiento es muy simple: cuando se presenta un patrón de entrada se selecciona una única unidad de salida (la unidad ganadora) y se modifican los pesos de esa unidad. [13], [20]

Tabla 8. Tipos de aprendizaje no supervisados

TIPO DE APRENDIZAJE NO SUPERVISADO	MODELO DE RED	
APRENDIZAJE HEBBIANO	OFF LINE	ONLINE
	Hopfield	Additive grossberg
	Learning matrix	Shunting grossberg
	Temporal associative Memory	Bidirectional associative memory (BAM)
	Linear associative Memory (LAM)	Adaptative BAM
	Optima LAM	
	Drive reinforcement	
	Fuzzy associative Memory	
APRENDIZAJE COMPETITIVO/COOPERATIVO	Learning vector quantizer	Adaptative resonance theory
	Cognitron/Neocognitron	
	Topology Preserving map	

Fuente: Basado en HILERA, José y MARTÍNEZ, Víctor. Redes Neuronales Artificiales: Fundamentos, Modelos y Aplicaciones. Addison Wesley Iberoamericana, Madrid.1995

6.1.4 Representación de la información.

- **Datos de entrada y salida analógicos:** Las funciones de activación de las neuronas serán continuas, del tipo lineal o Sigmoidal.
- **Datos de entrada y salida discretos o digitales:** Valores discretos o binarios a la entrada y la salida de tipo binario. En este caso, las funciones de activación de las neuronas son de tipo escalón.
- **Red híbrida:** Cuya entrada obedece a valores continuos y salida de valores discretos y viceversa. [13], [20]

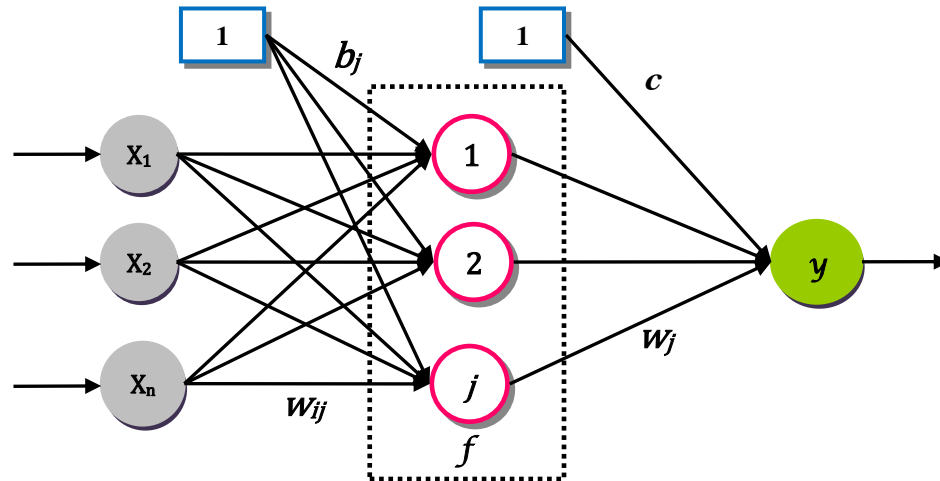
6.1.5 Evolución de redes neuronales artificiales. En la **tabla 9** se mencionan los aportes realizados en este campo del saber. [13], [20]

6.2 PERCEPTRÓN MULTICAPA

Dentro de los modelos de RNA existen diversos tipos de estructuras dependiendo de la disposición de los enlaces que conectan las neuronas o si existen bucles dentro de la red. Una estructura ampliamente utilizada en el pronóstico de series de tiempo es el Perceptrón Multicapa (PM), el cual presenta las siguientes características:

- No existen bucles ni conexiones entre las neuronas de una misma capa
- Las funciones de activación son iguales para cada neurona de una misma capa
- Tiene una sola neurona en la capa de salida.

Figura 35. Esquema general de un Perceptrón Multicapa



La representación matemática de la **figura 35**, se indica en la ecuación

$$y = \sum_{j=1}^m w_j \cdot f_j \left(\sum_{i=1}^n a_{ij} x_i + b_j \right) + c \quad (6.15)$$

Donde:

y = Variable pronosticada

x_i = Variables de entrada

w_j = Pesos que conectan la j -ésima salida de la capa oculta a la capa de salida

w_{ij} = Pesos que conectan la i -ésima entrada al modelo con la j -ésima neurona de la capa oculta

b_j = Sesgos (bias) o intercepto de las j -ésima neurona oculta c es el sesgo (bias) o intercepto de la neurona y de salida.

w_j, a_{ij}, b_j y c son los parámetros del modelo que deben ser ajustadas mediante el algoritmo de entrenamiento. En total son $(n + 1)(m + 1)$ parámetros a ajustar, donde n es el número de entradas al modelo y m es el número de neuronas en la capa oculta de la red. Interpretando esta ecuación, el modelo resulta ser una regresión caracterizada por la

función f , la cual puede ser lineal o no lineal y determina la forma en que se relacionan las entradas al modelo con la salida. [13], [20]

6.3 PASOS PARA LA IMPLEMENTACIÓN DE REDES NEURONALES EN EL PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA

Tabla 9. Metodología Kaastra-Boyd para pronóstico utilizando Redes Neuronales Artificiales

METODOLOGÍA KAASTRA-BOYD PARA PRONÓSTICO UTILIZANDO REDES NEURONALES ARTIFICIALES	
1.	Selección de la Variable
2.	Recolección de Datos
3.	Procesamiento de Datos.
4.	Definir conjunto de Entrenamiento, Validación y Prueba
5.	Selección topología de la red neuronal
	a. Número de Neuronas de Entrada.
	b. Número de Capas Ocultas.
	c. Número de Neuronas Ocultas.
	d. Número de Neuronas de Salida.
	e. Función de Transferencia.
6.	Criterios de evaluación
7.	Entrenamiento de la red
	a. Número de Iteraciones
	b. Tasa de Aprendizaje y Momento
8.	Implementación del Modelo de Redes Neuronales Artificiales

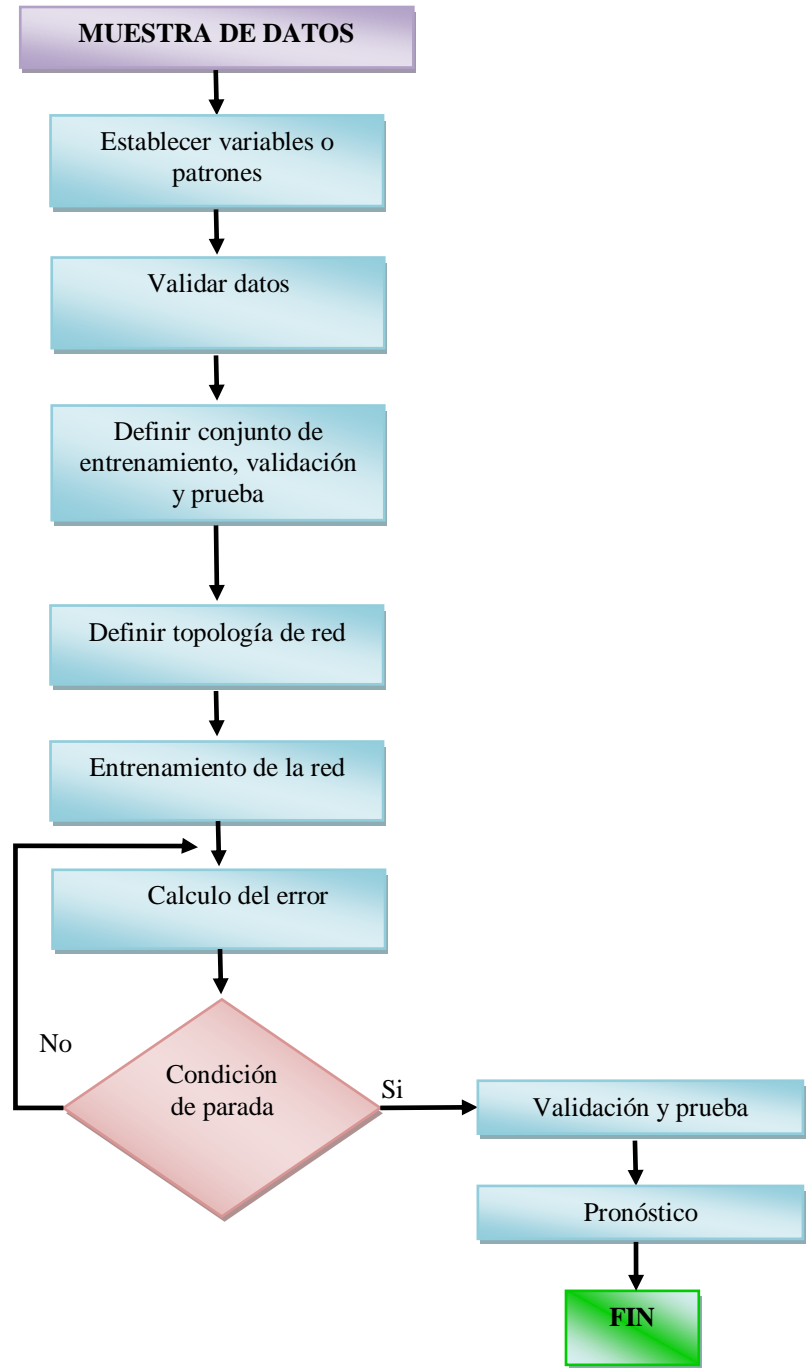
Fuente: KAASTRA, Iebling y BOYD, Milton. Designing Network for Forecasting financial and economic time series. En: Neurocomputing.1996, p. 215-236.

En el **numeral 7.1.5** se hace una descripción más detallada de la metodología y como se implementó en el caso de la empresa ABC. En la **figura 37**, se describe la metodología de modo grafico.

Tabla 10. Evolución de Redes Neuronales Artificiales (RNA)

EVOLUCIÓN DE REDES NEURONALES ARTIFICIALES		
FECHA	DISEÑADOR (ES)	APORTE / RED
1936	Alan Turing	Primero en estudiar el cerebro como una forma de ver el mundo de la computación
1943	Warren McCulloch y Walter Pitts	Modelaron una red neuronal simple mediante circuitos eléctricos.
1949	Donald Hebb	Explica los procesos del aprendizaje (que es el elemento básico de la inteligencia humana) desde un punto de vista psicológico, desarrollando una regla de como el aprendizaje ocurría
1950	Karl Lashley	Encontró que la información no era almacenada en forma centralizada en el cerebro sino que era distribuida encima de él.
1956	Congreso de Dartmouth	Este Congreso frecuentemente se menciona para indicar el nacimiento de la inteligencia artificial.
1957	Frank Rosenblatt.	Comenzó el desarrollo del Perceptrón. Esta es la red neuronal más antigua; utilizándose hoy en día para aplicación como identificador de patrones.
1960	Bernard Widroff/Marcian Hoff	Desarrollaron el modelo ADALINE (ADaptative LINear Elements). Esta fue la primera red neuronal aplicada a un problema real (filtros adaptativos para eliminar ecos en las líneas telefónicas) que se ha utilizado comercialmente durante varias décadas.
1961	Karl Steinbeck	Red neuronal para simples realizaciones técnicas (memoria asociativa).
1969	Marvin Minsky/Seymour Papert	Probaron (matemáticamente) que el Perceptrons no era capaz de resolver problemas relativamente fáciles, tales como el aprendizaje de una función no-lineal. Esto demostró que el Perceptrón era muy débil, dado que las funciones no-lineales son extensamente empleadas en computación y en los problemas del mundo real.
1974	Paul Werbos	Desarrolló la idea básica del algoritmo de aprendizaje de propagación hacia atrás (BACKPROPAGATION); cuyo significado quedó definitivamente aclarado en 1985.
1977	Stephen Grossberg	Teoría de Resonancia Adaptada (TRA). La Teoría de Resonancia Adaptada es una arquitectura de red que se diferencia de todas las demás previamente inventadas. La misma simula otras habilidades del cerebro: memoria a largo y corto plazo.
1985	John Hopfield	Provocó el renacimiento de las redes neuronales con su libro: "Computación neuronal de decisiones en problemas de optimización.
1986	David Rumelhart/G. Hinton	Redescubrieron el algoritmo de aprendizaje de propagación hacia atrás (backpropagation).
1987-1990	Carpenter y Grossberg	Teoría de la Resonancia Adaptativa (Adaptative Resonance Theory, ART), versión ART 1, ART 2, ART 3
1991	Carpenter, Grossberg y Rosen	Fuzzy ART
1992	Kosko	Differential Competitive Learning (DCL) y Differential hebbian

Figura 36. Metodología para pronóstico utilizando Rede Neuronales Artificiales



CAPITULO VII

EJEMPLO DE APLICACIÓN Y ANÁLISIS DE RESULTADOS

7.1 BASE DE DATOS

Para la implementación de los métodos se hizo uso de una serie de tiempo de demanda de energía eléctrica de un operador de red de Colombia y por razones de confidencialidad en este trabajo se le llamara **Empresa ABC**.

Tabla 11. Demanda de energía eléctrica periodo 200801 a 201104 en una zona de Colombia

PERIODO	DEMANDA GW-h	PERIODO	DEMANDA GW-h
200801	62,623	200909	61,611
200802	62,978	200910	61,510
200803	61,655	200911	60,855
200804	59,479	200912	61,135
200805	60,538	201001	62,451
200806	59,705	201002	62,877
200807	60,987	201003	62,287
200808	59,171	201004	60,233
200809	59,986	201005	60,555
200810	60,707	201006	61,205
200811	60,649	201007	61,309
200812	61,955	201008	61,314
200901	62,223	201009	63,158
200902	62,792	201010	62,729
200903	61,379	201011	61,814
200904	58,436	201012	62,831
200905	59,291	201101	64,186
200906	59,889	201102	63,597
200907	59,812	201103	62,278
200908	59,301	201104	60,246

Fuente: Demanda de energía eléctrica suministrado por empresa ABC para el período 200801-201104.


Tabla 12. Análisis estadístico de los datos de demanda periodo 200801 a 201104

ESTADÍSTICA DESCRIPTIVA	
No. de observaciones	40
Media	0,954
Desviación típica	0,021
Varianza	0
Coefficiente de variación	0,022
Asimetría Pearson	-0,021
Asimetría Fisher	-0,022
Asimetría Bowley	-0,025
Error estándar de la media	0,003
Desviación absoluta de media	0,017
Media geométrica	0,955
Desviación típica geométrica	1,023

En primera instancia se debe conocer el comportamiento de esta serie, hacer una estimación de la técnica que se va a emplear y luego el pronóstico de los siguientes periodos; cabe anotar que esto es con fines académicos, pues la base de datos que se tiene es una muestra pequeña, como antes se ha mencionado el tamaño de la muestra es importante en la precisión del pronóstico, debido a que la demanda es variable se debe considerar un análisis espaciado de tiempo para estimar su comportamiento.


En la práctica los analistas utilizan datos históricos de más de veinte años, con esto se puede establecer patrones discriminantes por mes, vacaciones, invierno, verano entre otras y con ello proyectarlo a horizontes de uno a quince años obteniendo así un pronóstico confiable sobre el comportamiento mensual de la demanda. En caso de contar con el comportamiento hora a hora de la demanda los perfiles de consumo se discriminan por hora del día, día de la semana, fin de semana, festivos, y las mencionadas anteriormente.

Figura 37. Curva anual de demanda de energía eléctrica 200801 a 201104



Se puede observar que el mes de Abril es el de menor consumo para el periodo analizado, los meses de Diciembre y Enero son los de mayor consumo.

Figura 38. Demanda de energía eléctrica periodo 200801 al 201104



7.1.1 Métodos de Tendencia simple. Inicialmente se hace la regresión de la serie de todos los datos. En la **figura 33** se muestra el comportamiento de la demanda de la zona donde opera la empresa ABC, para el periodo comprendido entre 2008 al mes de abril de 2011 (40 meses). Gráficamente se muestra que la serie no tiene una tendencia marcada de crecimiento o decrecimiento, a simple vista no se puede determinar su comportamiento por lo que se recurre a la regresión simple y a partir del coeficiente de determinación R^2 , conoceremos qué función es semejante al comportamiento de la serie ($R^2 \geq 0,8$) mencionado en el numeral , en este caso se hará uso de Excel.

También se tomara en cuenta el criterio de errores señalado en el numeral **1.5** validación del método entre valor estimado y valor real de la serie, para ello se utilizara el software Minitab 15, luego se realiza una comparación de los resultados obtenidos y se determina el modelo de tendencia que mejor se ajusta a la serie de datos.

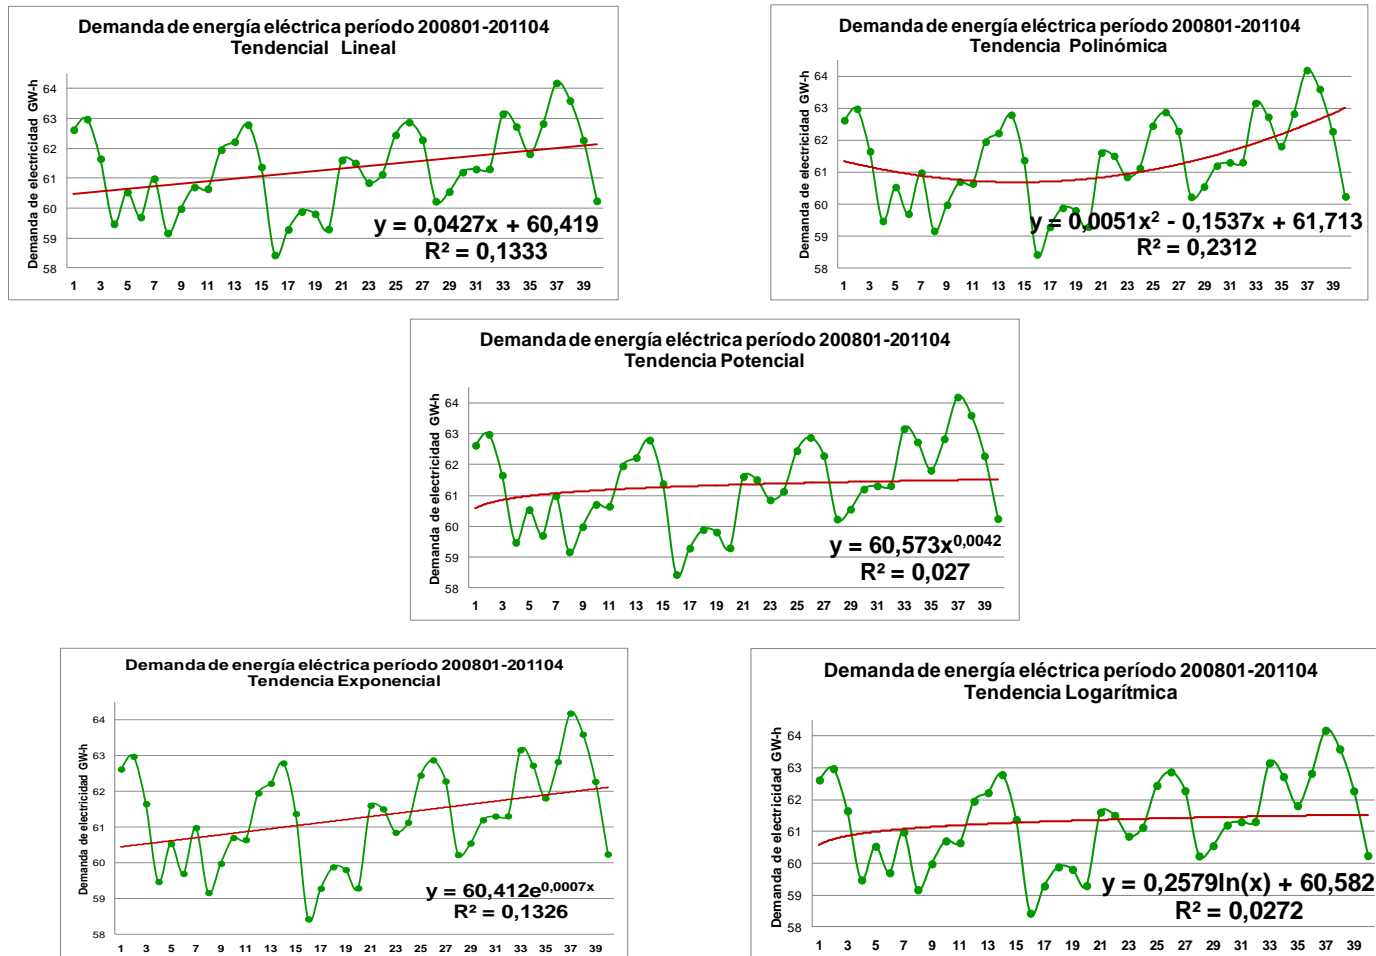
En la **figura 34** se realiza un esquema comparativo de los modelos de tendencia obtenidos a través de Excel, se nota que la tendencia polinómica (Cuadrática) es la que presenta mayor ajuste con $R^2 = 0,2312$, en este caso no se puede afirmar que su comportamiento obedece a una función cuadrática pues el coeficiente de correlación no es igual ni mayor a 0,8. En la **tabla 13** se presentan los resultados obtenidos.

Tabla 13. Coeficiente de correlación según el tipo de regresión para la serie de demanda

Tendencia	Lineal	Polinómica	Exponencial	Logarítmico	Potencial
Criterio R^2	0,1333	0,2312	0,1326	0,0272	0,0270

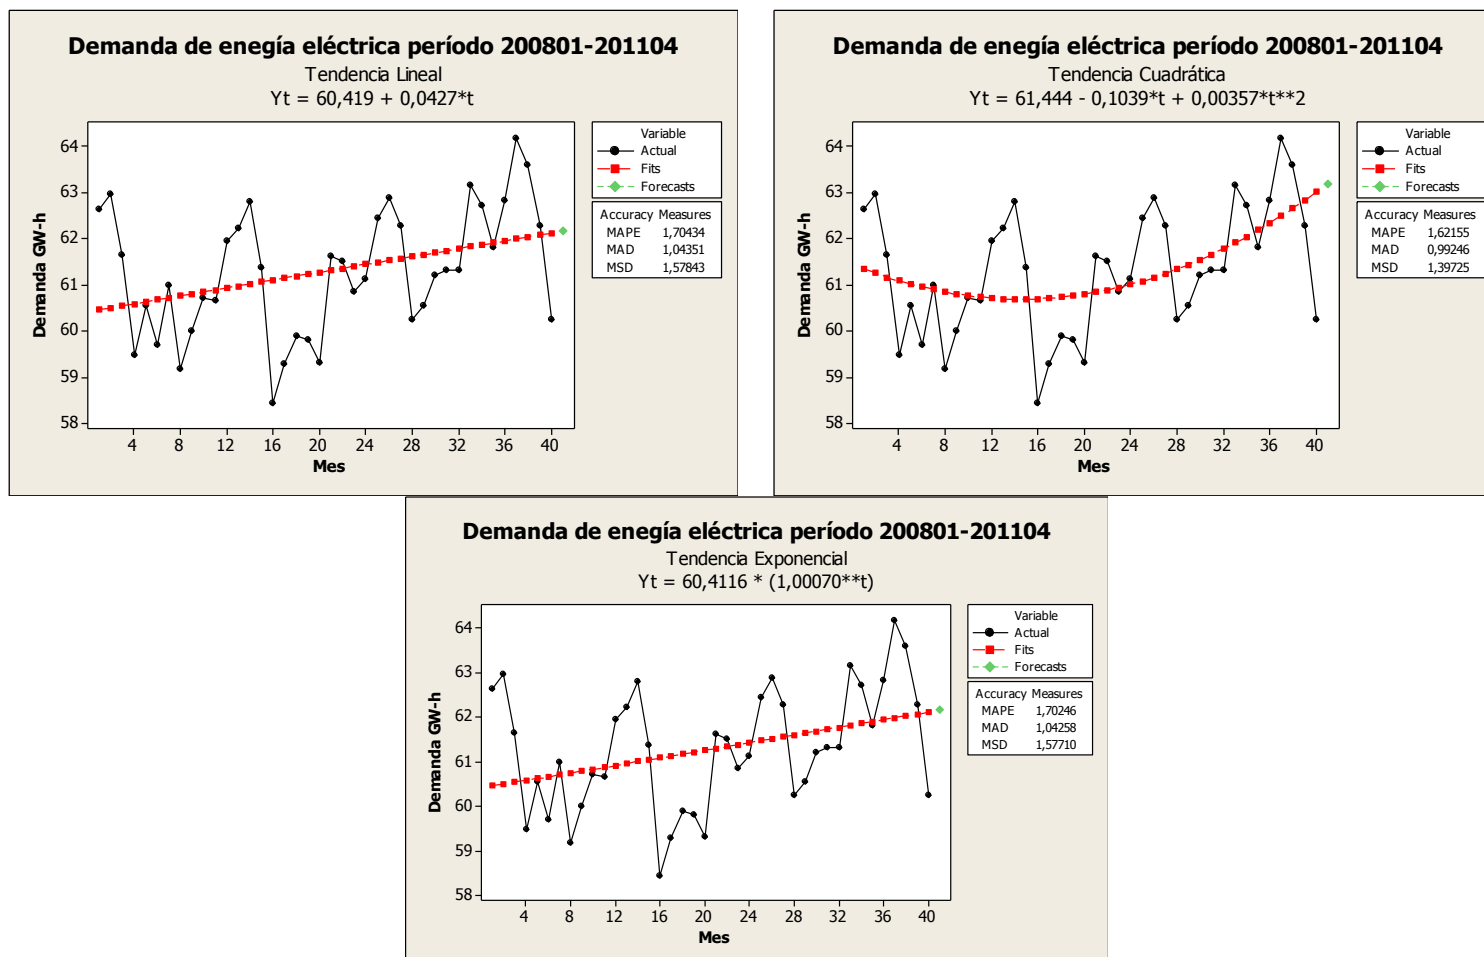
Por otra parte en la **figura 35** se muestran los resultados arrojados por el software Minitab que son semejantes a las regresiones de Excel, en este último se comparan la función de ajuste con los datos reales mediante el error MAPE y MAD, se nota que para la tendencia cuadrática estos errores presentan el menor valor entre las 3 tendencias graficadas con el software. Tomando los siguientes valores: **MAPE = 1,62155** , **MAD = 0,99246**. En la **tabla 14** se encuentran tabulados los resultados obtenidos por el software.

Figura 39. Modelos de tendencia utilizando Excel (Criterio R^2)



Fuente: Resultados de regresión en Excel para la serie de tiempo de demanda de energía eléctrica de la empresa ABC para el período 200801-201104.

Figura 40. Modelos de tendencia utilizando Minitab 15 (Criterio MAD, MAPE)



Fuente: Resultados de tendencia obtenidos a través del software Minitab 15 para la serie de tiempo de demanda de energía eléctrica de la Empresa ABC para el período 200801-201104.

Con ayuda del software Minitab 15 se hace un análisis de componentes de la serie. La primera grafica es la representación de los valores de demanda de energía eléctrica en los 40 meses, la siguiente grafica corresponde a los datos que no muestran tendencia de incremento o disminución de la demanda en el tiempo.

Figura 41. Análisis de componentes de la serie




Figura 42. Modelo de descomposición para la serie de demanda de energía





Figura 43. Modelo de Media Móvil a dos períodos para la serie de demanda

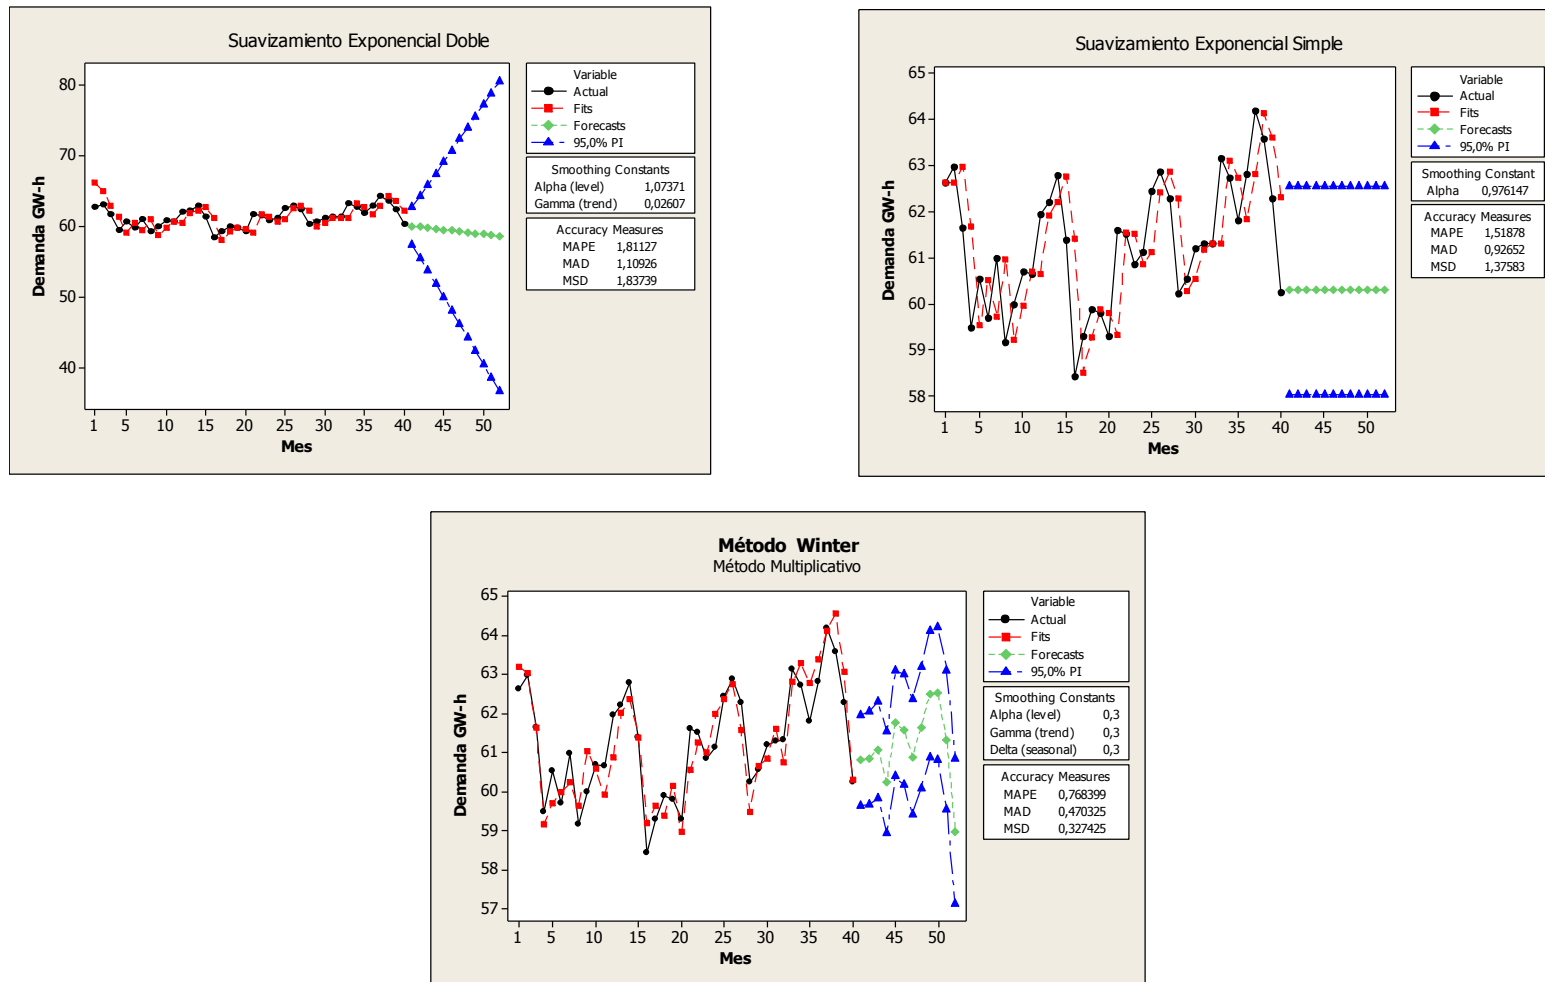


7.1.2 Método de Suavizamiento exponencial y promedios móviles. De los métodos implementados en el software Minitab 15 el que presenta mejor ajuste para la serie de datos es el Método Winter, este método presenta el menor error de ajuste entre el modelo y la serie de datos, tal como se muestra en la tabla 14.

Con el software SPSS 20 se hace un análisis de la serie para los métodos que no dispone el Minitab 15, como lo es Brown, Holt y Simple estacional, dichos resultados se muestran en la **figura 40** y **tabla 15**.

El modelo de ajuste del método Holt y Brown no se ajustan al comportamiento de la serie mientras que el modelo simple estacional genera un comportamiento similar a la serie de datos, no obstante el Modelo Winter Aditivo es quien posee el mayor coeficiente de correlación entre los modelos ajustados $R^2 = 0,877$, en este caso se puede afirmar el comportamiento de la serie de demanda de energía eléctrica obedece al Modelo Winter Aditivo pues el coeficiente de correlación es ni mayor a 0,8 y es el más cercano a 1.

Figura 44. Modelos de Suavizamiento Exponencial (Simple, Doble, Winter)



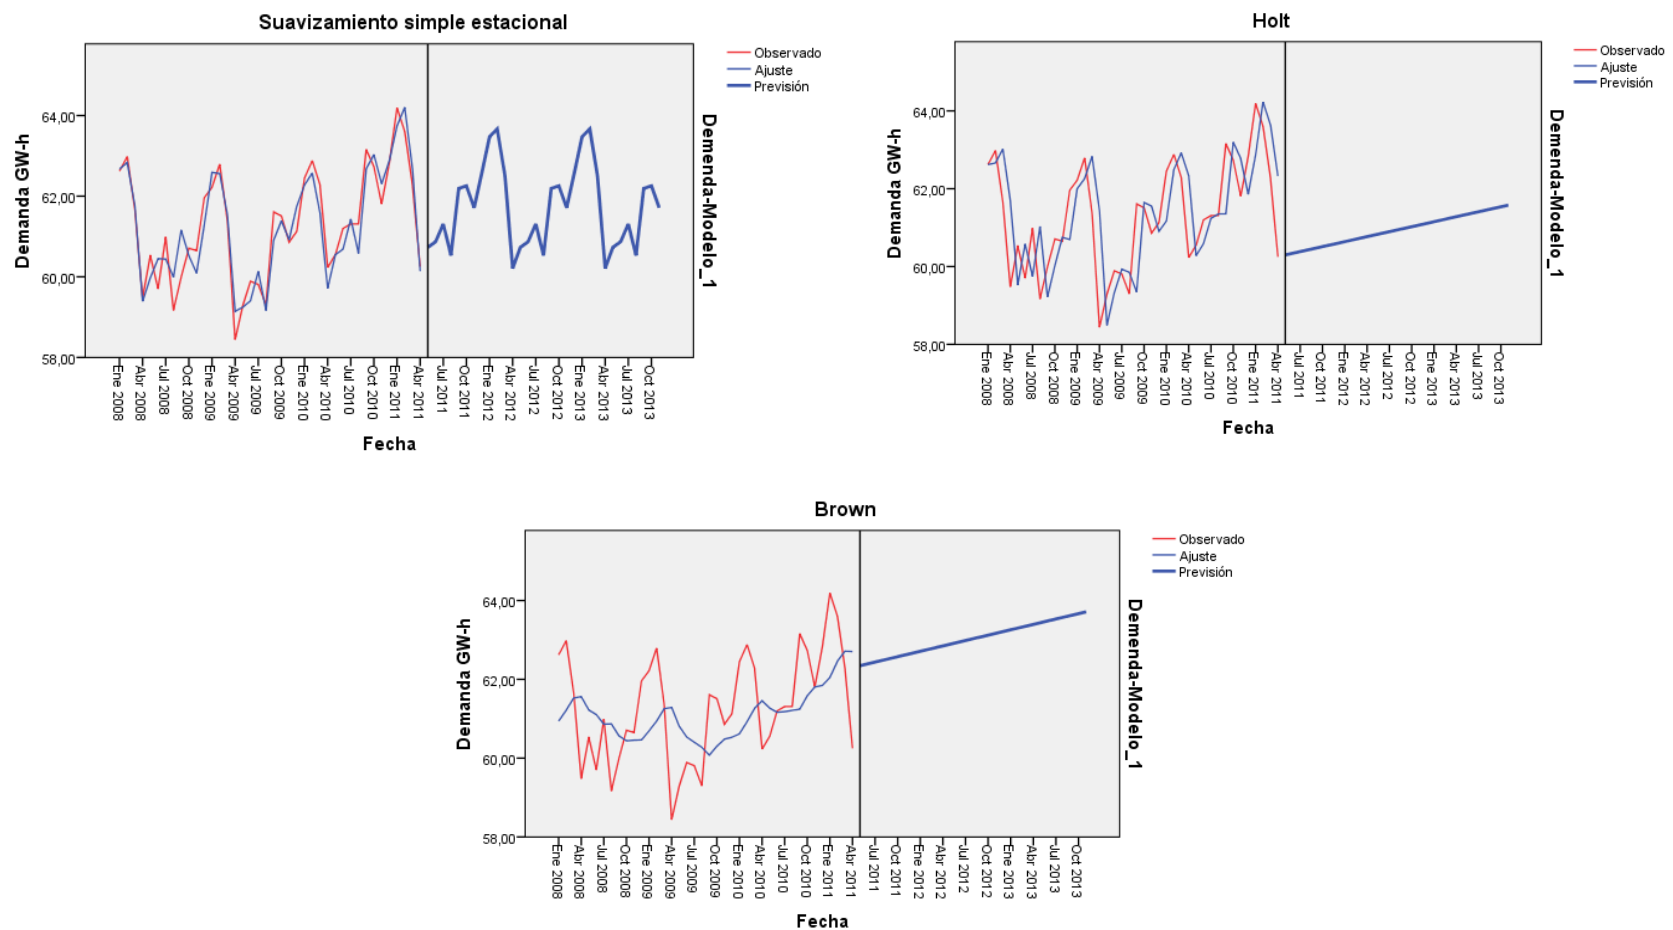
Fuente: Resultados obtenidos a través del software Minitab 15 para la serie de tiempo de demanda de energía eléctrica de la empresa ABC para el período 200801-201104.

Tabla 14. Error estimado según método utilizado para la serie temporal

Error	Descomposición Multiplicativo	Lineal	Cuadrático	Exponencial	Promedio móvil		Suavizamiento exponencial simple $\alpha = 0,97615$	Suavizamiento exponencial Doble $\alpha = 1,07371$ $\gamma = 0,02607$	Método Winter		
					n = 2	n = 3			$\alpha = 0,1$ $\gamma = 0,1$ $\delta = 0,1$	$\alpha = 0,2$ $\gamma = 0,2$ $\delta = 0,2$	$\alpha = 0,3$ $\gamma = 0,3$ $\delta = 0,3$
MAPE	0,81885	1,70434	1,62155	1,70246	1,69880	1,80540	1,51878	1,81127	1,15010	0,79851	0,76839
MAD	0,50033	1,04351	0,99246	1,04258	1,03654	1,10069	0,92652	1,10926	0,70706	0,49030	0,47033
MSD	0,36262	1,57843	1,39725	1,57710	1,76326	1,94246	1,37583	1,83739	0,70089	0,34471	0,32743


Fuente: Resultados obtenidos a través del software Minitab 15 para la serie de tiempo de demanda de energía eléctrica de la empresa ABC para el período 200801-201104.

Figura 45. Modelos Suavizamiento Exponencial (Simple estacional, Brown, Holt)



Fuente: Resultados obtenidos a través del software SPSS 20 para la serie de tiempo de demanda de energía eléctrica de la empresa ABC para el período 200801-201104.

Figura 46. Modelo Winter (Aditivo y Multiplicativo) para la serie temporal



Fuente: Resultados obtenidos a través del software SPSS 20 para la serie de tiempo de demanda de energía eléctrica de la empresa ABC para el período 200801-201104.

Tabla 15. Análisis de los Modelos Winter, Holt y Brown

NO ESTACIONAL	Sin transformación			Raíz cuadrada			Log natural		
	Simple	Holt	Brown	Simple	Holt	Brown	Simple	Holt	Brown
Criterio R²	0,244	0,240	0,055	0,243	0,239	0,056	0,242	0,238	0,057
MAPE	1,518	1,527	1,759	1,514	1,527	1,758	1,512	1,527	1,756
MAE	0,926	0,931	1,079	0,924	0,931	1,078	0,922	0,931	1,076
Alfa (nivel)	0,972	0,997	NA	0,962	0,996	NA	0,958	0,995	NA
Gamma (Tendencia)	NA	2,115 E-6	NA	NA	9,351E-7	NA	NA	1,449E-6	NA
Alfa nivel y tendencia	NA	NA	0,086	NA	NA	0,086	NA	NA	0,085

ESTACIONAL	Sin transformación			Raíz cuadrada			Log natural		
	Simple	Aditivo Winter	Multiplicativo Winter	Simple	Aditivo Winter	Multiplicativo Winter	Simple	Aditivo Winter	Multiplicativo Winter
Criterio R²	0,876	0,877	0,806	0,876	0,877	0,806	0,876	0,877	0,806
MAPE	0,636	0,628	0,746	0,637	0,629	0,747	0,639	0,630	0,747
MAE	0,389	0,383	0,455	0,390	0,384	0,456	0,390	0,385	0,456
Alfa (nivel)	0,600	0,557	0,276	0,600	0,558	0,280	0,600	0,560	0,282
Delta (Estación)	1,093E-7	0,001	0,634	1,394E-5	0,001	0,630	3,923E-6	0,001	0,626
Gamma (Tendencia)	NA	0,001	0,007	NA	0,000	0,006	NA	0,000	0,006

Fuente: Resultados obtenidos a través del software SPSS 20 para la serie de tiempo de demanda de energía eléctrica de la empresa ABC para el período 200801-201104.

7.1.3 Método ARIMA. En el **Capítulo III** se hizo la descripción de la metodología Box-Jenkins para modelos ARIMA, la explicación de cada una de las etapas; a continuación se hará uso de la metodología para la serie de datos de la empresa ABC para determinar el modelo que mejor se ajusta al comportamiento de la serie de datos.

1. Identificación

Se utiliza FAC y FACP para estimar los valores de p , d , q , la longitud del rezago es criterio del analista y tamaño de la muestra, algunos autores recomiendan que la longitud del rezago sea un tercio de la muestra, en este caso se tienen 40 datos así que se realizara con 10 rezagos.

Una vez obtenidos los correlogramas se procede a analizar su comportamiento y si es necesaria la diferenciación de la serie para transformarla en una serie estacionaria.

Figura 47. Función de Autocorrelación de la serie temporal





Figura 48. Función de Autocorrelación Parcial de la serie temporal



Fuente: Resultado obtenido a través del software Minitab 15 para la serie de tiempo de demanda de energía eléctrica de la empresa ABC para el período 200801-201104.

Las líneas punteadas rojas en el gráfico representan el intervalo de confianza dentro del cual se supone que la autocorrelación se puede asumir nula y fuera del cual la autocorrelación es significativa. Se debe tomar los retardos o rezagos más influyentes de entre todos los significativos.

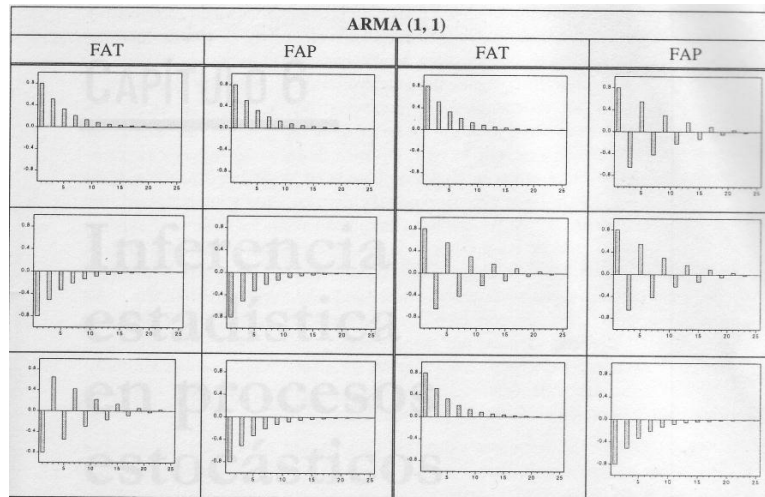
En la grafica de autocorrelación FAC se puede observar que la serie de demanda presenta el comportamiento típico de una serie estacionaria, puesto que los primeros valores de la función no son muy elevados ni tampoco presentan un decrecimiento lento a cero, en el cuarto rezago el valor cambia al plano negativo. Solo hay un valor influyente y significativo en esta serie, en este caso no es necesario diferenciar la serie para convertirla en estacionaria.

2. Estimación

Cuando se tiene la FAC y FACP de la serie estacionaria se procede a estimar los valores p , d , q ; recordemos que d es las veces que se diferencia la serie para transformarla en una serie estacionaria. Una vez cumple esta condición los correlogramas resultantes se comparan con funciones FAC y FACP teóricas, para estimar el modelo.

Al observar la FAC y la FACP de la serie de demanda se puede concluir que la serie se ajusta a un modelo **AR (1)** y **MA (1)**, ya que el primer valor de la FACP es significativo; es decir, presenta un valor significativo que sale de los intervalos de confianza, y el resto de valores presentan un comportamiento sinusoidal; además, los primeros valores de la FAC presentan un decrecimiento exponencial, seguidos de un comportamiento sinusoidal para los siguientes valores.

Figura 49. FAC y FACP teóricas para ARMA (1,1)



3. Validación

Después de seleccionar un modelo ARIMA particular y de estimar sus parámetros, se verifica que el modelo seleccionado se ajuste a los datos de manera razonable puesto que es posible que otro modelo ARIMA también lo haga.

Para este caso se hará uso del software Minitab 15 en la estimación de los modelos y su validación se hará teniendo en cuenta el test t de nulidad, valor p y por ultimo mínimo error cuadrado medio del modelo. Los resultados obtenidos se tabulan ajustando los parámetros (p, d, q) (P, D, Q).

Tabla 16. Estimación de Modelos ARIMA para la serie de datos

VALIDACIÓN DE MODELOS ARIMA						
MODELO ARIMA	PARÁMETRO	ESTIMACIÓN	ERROR ESTÁNDAR	t	P-valor <0,05	RESULTADO
(1,0,1)(0,0,0)	AR	0,4600	0,2237	2,06	0,047	SI
	MA	-0,2911	0,2421	-1,20	0,237	NO
(1,0,0)(0,0,0)	AR	0,6272	0,1278	4,91	0,000	SI
(0,1,0)(1,0,0)	SAR	0,9797	0,0873	11,22	0,000	SI
(0,1,0)(1,1,0)	SAR	-0,7756	0,1534	-5,05	0,000	SI
(0,1,0)(0,1,1)	SMA	0,7895	0,1722	4,58	0,000	SI
(0,1,1)(0,0,0)	MA	0,0254	0,1711	0,15	0,883	NO
(0,0,1)(0,0,0)	MA	-0,5730	0,1353	-4,24	0,000	SI
(0,0,1)(0,1,0)	MA	-0,8927	0,1120	-7,97	0,000	SI
(1,1,0)(0,0,0)	AR	-0,0137	0,1707	-0,08	0,936	NO
(1,0,0)(0,1,0)	AR	0,6903	0,1434	4,81	0,000	SI
(1,0,0)(1,0,0)	AR	0,7540	0,1164	6,48	0,000	SI
	SAR	0,9794	0,0919	10,65	0,000	SI
(1,0,0)(0,0,1)	AR	0,6537	0,1215	5,38	0,000	SI
	SMA	-0,7699	0,2021	-3,81	0,001	SI
(1,0,0)(1,1,0)	AR	0,6308	0,1572	4,01	0,000	SI
	SAR	-0,4690	0,1832	-2,56	0,017	SI
(1,0,0)(1,1,1)	AR	0,4376	0,1889	2,32	0,029	SI
	SAR	-0,8789	0,1600	-5,49	0,000	SI
	SMA	0,7036	0,2328	3,02	0,006	SI
(1,0,0)(1,0,1)	AR	0,7383	0,1190	6,20	0,000	SI
	SAR	0,8629	0,1409	6,12	0,000	SI
	SMA	-0,5534	0,2504	-2,21	0,034	SI
(0,1,1)(1,0,1)	SAR	0,9980	0,0192	51,91	0,000	SI
	MA	0,4654	0,1519	3,06	0,004	SI
	SMA	0,7880	0,1841	4,28	0,000	SI
(0,1,1)(1,1,1)	SAR	-0,8953	0,1734	-5,16	0,000	SI
	MA	0,6408	0,1620	3,95	0,001	SI
	SMA	0,6905	0,2505	2,76	0,011	SI

Tabla 17. (Continuación)

VALIDACIÓN DE MODELOS ARIMA						
MODELO ARIMA	PARÁMETRO	ESTIMACIÓN	ERROR ESTÁNDAR	t	P-valor <0,05	RESULTADO
(1,0,0)(0,1,1)	AR	0,6396	0,1505	4,25	0,000	SI
	SMA	0,7528	0,1979	3,80	0,001	SI
(0,0,1)(0,0,1)	MA	-0,6050	0,1364	-4,44	0,000	SI
	SMA	-0,7931	0,1912	-4,15	0,000	SI
(0,1,1)(1,1,0)	SAR	-0,9672	0,1499	-6,45	0,000	SI
	MA	0,7494	0,1493	5,02	0,000	SI
(1,1,1)(0,0,0)	AR	0,5729	0,1934	2,96	0,005	SI
	MA	0,9467	0,1366	6,93	0,000	SI
(1,1,1)(1,0,0)	AR	0,7064	0,1458	4,85	0,000	SI
	SAR	0,9881	0,0961	10,28	0,000	SI
	MA	0,9884	0,0235	42,13	0,000	SI
(1,1,1)(0,1,0)	AR	0,5364	0,2374	2,26	0,033	SI
	MA	0,9493	0,1608	5,90	0,000	SI
(1,1,1)(1,0,1)	AR	0,5585	0,2156	2,59	0,014	SI
	SAR	0,9992	0,0241	41,42	0,000	SI
	MA	0,9060	0,1164	7,78	0,000	SI
	SMA	0,7614	0,2056	3,70	0,001	SI

Adicionalmente se compara el nivel de significancia del valor P generado en la prueba Box –Pierce calculado por el software Minitab 15, para cada una de los modelos estimados, luego se procede a elegir el modelo que presente el mínimo error **MSE**.

Tabla 18. Validación de Modelos ARIMA utilizando criterio MSE

MODELO ARIMA	MSE	PRIORIDAD	RESULTADO
(1,0,0)(0,1,1)	0,24115	1	APROBADO
(0,1,0)(0,1,1)	0,24906	2	RECHAZADO
(1,0,0)(1,1,1)	0,27413	3	RECHAZADO
(0,1,1)(1,1,1)	0,31210	4	DESCARTADO
(1,1,1)(1,0,1)	0,32520	5	DESCARTADO
(0,1,1)(1,0,1)	0,32580	6	DESCARTADO
(1,0,0)(1,0,0)	0,37780	7	DESCARTADO
(1,0,0)(1,0,1)	0,37790	8	DESCARTADO
(1,1,1)(1,0,0)	0,39790	9	DESCARTADO
(0,1,0)(1,0,0)	0,43090	10	DESCARTADO

4. Pronóstico

Una vez escogido el modelo en este caso es (1, 0,0) (0, 1,1), se procede a realizar el pronóstico al periodo deseado, para ello se ejecuta la aplicación y se ingresa el numero de periodos.

7.1.4 Método distribución de probabilidad. Se hizo escalamiento de los datos debido a que la distribución de probabilidad son datos entre 0 y 1. Para la implementación del método se utiliza el software MATLAB y el software XLSTAT. Método de los momentos (MOM) y Método de verosimilitud (MLE)

Tabla 19. Modelos de Distribución de probabilidad para la serie temporal (MATLAB)

Distribución	Parámetro 1	Parámetro 2	E[X]	STD[X]	D KOLSMI	Estimación de método
Normal	0.9556	0.0211	0.9556	0.0211	0.0708	MLE
Normal	0.9556	0.0211	0.9556	0.0211	0.0708	MOM
Gamma	2.0588e+003	4.6416e-004	0.9556	0.0211	0.0722	MOM
Gamma	2.1102e+003	4.5286e-004	0.9556	0.0208	0.0747	MLE
Log normal	-0.0456	0.0221	0.9556	0.0211	0.0726	MLE
Log normal	-0.0456	0.0220	0.9556	0.0211	0.0730	MOM
Uniforme	0.9191	0.9921	0.9556	0.0211	0.0751	MOM
Uniforme	0.9100	1	0.9550	0.0260	0.1342	MLE
Pearson VI	4.1233e+003	4.3158e+003	0.9556	0.0208	0.0753	MLE
Pearson V	2.1071e+003	2.0126e+003	0.9556	0.0208	0.0759	MLE
Weibull	0.9657	49.5886	0.9549	0.0243	0.0843	MLE
Weibull	0.9650	57.4768	0.9556	0.0211	0.0968	MOM
Logística	0.9556	0.0116	0.9556	0.0211	0.0933	MOM
Log logística	82.2452	0.9554	0.9556	0.0211	0.0954	MOM
Gumbel	0.9461	0.0164	0.9556	0.0211	0.1133	MOM

Figura 50. Distribución Normal datos teóricos y reales





Figura 51. Curva de Distribución Normal vs Serie de demanda



De lo anterior se puede concluir que la distribución de probabilidad que mejor se ajusta al comportamiento de la serie de demanda eléctrica es la Distribución Normal con el mayor porcentaje de aceptación de las pruebas Kolmogorov –Smirnov y Chi cuadrado como se muestra en la **tabla 20**.

Tabla 20. Modelos de Distribución de probabilidad para la serie temporal (XLSTAT)

Distribución de Probabilidad	Parámetros	Prueba Kolmogorov -Smirnov				Prueba Chi-cuadrado (X^2)					
		D	p-valor	alfa	% Acept.	X^2 Ajustado (Valor observado)	X^2 Ajustado (Valor crítico)	p-valor	Grados de libertad	alfa	% Acept.
Normal	$\mu = 0,954, \sigma = 0,021$	0,067	0,993	0,02	99,28	5,144	19,679	0,822	9	0,02	82,16
Normal estándar	NA	0,819	0,000	0,02	0,01	2049,275	22,618	0,000	11	0,02	0,01
Gamma (1)	$k=0,954$	0,618	0,000	0,02	0,01	1357,052	21,161	0,000	10	0,02	0,01
Gamma (2)	$k=2007,551, \beta=0$	0,068	0,991	0,02	99,11	5,165	19,679	0,820	9	0,02	81,97
Gamma (3)	$K=1, \beta=1, \mu=0$	0,598	0,000	0,02	0,01	1320,340	18,168	0,000	8	0,02	0,01
Log normal	$\mu=1, \sigma=1$	0,841	0,000	0,02	0,01	2147,481	19,679	0,000	9	0,02	0,01
Uniforme	$a=0, b=1$	0,910	0,000	0,02	0,01	463,640	19,679	0,000	9	0,02	0,01
Weibull (1)	$\beta=1$	NA	NA	NA	NA	1320,340	21,161	0,000	10	0,02	0,01
Weibull (2)	$\beta=1, \gamma=1$	NA	NA	NA	NA	1320,340	19,679	0,000	9	0,02	0,01
Weibull (3)	$\beta=1, \gamma=1, \mu=0$	NA	NA	NA	NA	1320,340	18,168	0,000	8	0,02	0,01
Gumbel	NA	NA	NA	NA	NA	1975,673	22,618	0,000	11	0,02	0,01
Exponencial	$\alpha=1$	NA	NA	NA	NA	1320,340	21,161	0,000	10	0,02	0,01

7.1.5 Método Redes Neuronales Artificiales. En esta sección se hará uso de los conceptos expuestos en el método para construir, entrenar y probar una red neuronal para predecir valores futuros de la serie de tiempo, basada únicamente en sus valores pasados detallado en el **Capítulo VI**.

Se hace la implementación de la metodología de Kaastra-Boyd descrita en la **tabla 10**, y se hace de MATLAB Neural Network Toolbox V2012b.

1. Selección de la Variable

- **Variable a Predecir:** Demanda mensual de energía eléctrica de una zona del país.
- **Tipo de Variable:** Cuantitativa
- **Unidad:** GWh

En caso de contar con una muestra más amplia y detallada de demanda de electricidad se podrían establecer perfiles de consumo según hora del día, día de la semana y mes del año. Además de la posibilidad de adición de otras variables que influyan en el comportamiento de la demanda como la temperatura, precio, PIB entre otras.

2. Recolección de Datos

Los datos utilizados para el presente trabajo fueron obtenidos por parte de la Empresa ABC y consisten en mediciones de la cantidad mensual demandada de energía eléctrica de la zona, los datos corresponden al periodo comprendido 200801 al 201104 detallados mensualmente, para un total de 40 meses.

Para introducir la serie de tiempo a la red neuronal es necesario que los datos sean de fácil manipulación para el software, para ello la base de datos se convierte en una matriz 1X40, con el fin de manipulación de los mismos en forma vectorial, dicho distribución se encuentra en una hoja de cálculo Excel.

3. Procesamiento de Datos

Se realiza un análisis y transformación de las variables de entrada y salida para minimizar el ruido, detectar tendencias y establecer perfiles para ayudar a la red neuronal en el aprendizaje de patrones relevantes, debido a que las redes neuronales son buscadores de patrones, la representación de los datos es crítica en el diseño de una red exitosa. Las variables de entrada son raramente ingresadas a la red en su forma original.

Nuestra base de datos no contiene datos atípicos ni nulos o con formato inconsistente, sin embargo el software ofrece funciones de pre-procesamiento y post-procesamiento implícitas en las funciones de entrenamiento haciendo innecesario el uso individual de éstas.

4. Definir conjunto de Entrenamiento, Validación y Prueba

- a. **Conjunto de Entrenamiento:** Es el conjunto de datos que utiliza la red neuronal para aprender los patrones presentes en los datos. Por lo general los datos utilizados

para el entrenamiento de la red neuronal corresponden al 80 % de los datos de la serie, en este caso son 32 datos, dichos datos se seleccionan en forma consecutiva y ordenada.

- b. Conjunto de Validación:** Conjunto de datos utilizados para verificar el aprendizaje de la red donde los datos empleados son los más recientes consecuentemente al último valor de la muestra.

Durante el proceso de entrenamiento de la red puede ocurrir un problema llamado *overfitting* (se da cuando la red tan solo aprende puntos individuales en vez de generales), para evitarlo; es necesario incluir un conjunto de validación durante el proceso de aprendizaje de la red.

En este caso este conjunto se obviará, debido a que se está utilizando un componente de retardo y por lo tanto el conjunto de entrenamiento se va generando en el tiempo, impidiendo de esta manera que exista un conjunto de validación priori.

- c. Conjunto de Prueba:** Es el conjunto de datos encargados de evaluar la capacidad de predicción y precisión de la red, corresponden al 20% de datos de la serie, en nuestro caso son 8 datos de demanda de energía eléctrica, estos son los datos restantes una vez seleccionados los patrones de entrenamiento.

5. Selección topología de la red neuronal

- a. Número de Neuronas de Entrada:** Corresponde a las mediciones de demanda de energía eléctrica de un año. Por tanto la cantidad de neuronas de entrada son 12.
- b. Número de Capas Ocultas:** Son las encargadas de brindarle a la red la capacidad de generalizar por lo general se usan una o dos capas, el incremento en número de capas incrementa el tiempo de procesamiento y la dificultad sobre el ajuste lo que conduce a un pobre desempeño en la predicción fuera de la muestra.


En nuestro caso se opta por una sola capa oculta la cual es suficiente para asegurar la capacidad de generalización de nuestra red dada la cantidad de datos con los que contamos.

- c. Número de Neuronas Ocultas:** El número de neuronas de nuestra capa oculta será de un 75% del total de entradas, es decir, dado que el número de entradas de nuestra red es igual al número de meses que contiene un año (12 meses), el número de neuronas de nuestra capa oculta sería de 9 neuronas.
- d. Número de Neuronas de Salida:** Las redes neuronales con múltiples salidas, especialmente si éstas salidas están ampliamente espaciadas, producirán resultados inferiores en comparación con una red con una única salida. Lo recomendable es tener una red especializada para cada una de las salidas deseadas en cada pronóstico.

El número de neuronas de la capa de salida de nuestra red es una, porque tan solo intentamos predecir el valor de la variable seleccionada para un mes y no para un conjunto de meses lo cual disminuiría la precisión de la red.

- e. **Función de Transferencia:** El propósito de esta función es prevenir a las salidas de alcanzar valores muy elevados que puedan paralizar la red y detener el entrenamiento de la misma. Como función de transferencia se utiliza la función Sigmoidal (rango de salida entre -1 y +1).

Figura 52. Esquema de red neuronal implementada



6. Criterios de evaluación

Para medir la eficiencia de la red, se ha considerado utilizar el Error Cuadrático Medio (EMC). El Error Medio Cuadrático calculado como la diferencia entre la salida de la red y la respuesta deseada. El cual se usa como factor de culminación del entrenamiento. Para esta fase se fijó un parámetro en 10 épocas y el factor de terminación empleado del EMC teniendo como umbral un valor de 0.02.

7. Entrenamiento de la red

Entrenar una red neuronal para aprender patrones involucra el presentarle ejemplos de manera iterativa de las respuestas correctas.

El entrenamiento de la red utiliza la técnica del gradiente descendente inmerso en el algoritmo de propagación hacia adelante. El entrenamiento se detendrá básicamente cuando suceda uno de estos 3 motivos:

- El número de iteraciones excede el número de épocas establecidas.
- La función de evaluación (EMC) toma un valor por debajo de la meta establecida.
- El error medio de la función de evaluación se incrementa para un número específico de iteraciones (este último caso requiere de la existencia del conjunto de validación).

- a. **Número de Iteraciones:** A mayor número de iteraciones en el entrenamiento producirá un menor error en el entrenamiento pero éste a su vez no garantiza que se obtendrá el menor error con el conjunto de prueba. En nuestro caso el número máximo es 10 suficiente para conseguir un nivel de error aceptable.

8. Implementación del Modelo de Redes Neuronales Artificiales

Se hace uso de la técnica y se realiza la implementación de la red neuronal para el pronóstico de energía eléctrica a continuación se presenta tabulada la información de la red:

Tabla 21. Información de la red neuronal implementada para el pronóstico de energía eléctrica

INFORMACIÓN DE LA RED NEURONAL	
Tipo de Red	Perceptrón multicapa
Dirección de la información	Hacia adelante
Tipo de aprendizaje	Supervisado
Tipo de asociación entrada y salida	Heteroasociativas
Mecanismo de aprendizaje	Refuerzo
No. de Entradas	1 con 12 neuronas
No. de Capas Ocultas	1 con 9 neuronas
No. de Salidas	1
No. de Datos de entrenamiento	32 (80%)
No. de Datos de validación	8 (20%)
Función de activación de los nodos de la Capa Oculta	Sigmoidal
Función de activación de la salida	Sigmoidal
Método de estimación de error	Suma de error medio cuadrático
Dato de Salida	Predicción de demanda para 12 periodos

Se toman 12 valores de los 32 de entrenamiento para comprobar el aprendizaje de la red, la red debe arrojar datos muy parecidos a los datos de la demanda. Los datos arrojados de esta simulación se tabulan a continuación.

Tabla 22. Simulación de entrenamiento

SIMULACIÓN DEMANDA (GWh/mes)			
62.2425	58.3737	60.0764	61.4057
62.8806	60.3031	61.0938	59.9110
61.2427	61.1275	61.6709	61.9548

Luego realizamos una prueba de pronóstico con los 8 datos restantes de la base.

Tabla 23. Resultados de prueba de la red neuronal

PERIODO	VALOR REAL GWh	PRONOSTICO GWh	ERROR RESIDUAL
201009	63,158	62,201	0,957
201010	62,729	63,269	-0,54
201011	61,814	61,435	0,379
201012	62,831	58,103	4,728
201101	64,186	60,308	3,878
201102	63,597	61,362	2,235
201103	62,278	59,763	2,515
201104	60,246	59,737	0,509

Figura 53. Resultado de entrenamiento de la red

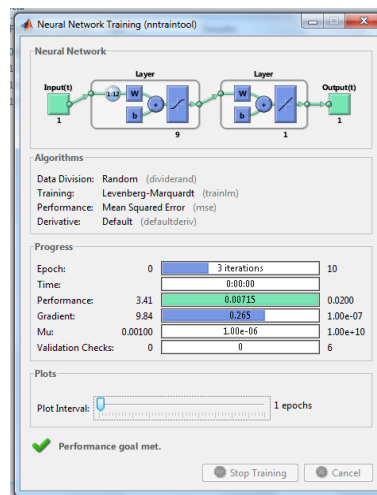
```

Training with TRAINLM.
Epoch 0/10, Time 0.052, Performance 3.4147/0.02, Gradient 9.8383/1e-07, Mu 0.001/10000000000, Validation Checks 0/6
Epoch 1/10, Time 0.112, Performance 0.91562/0.02, Gradient 2.9039/1e-07, Mu 0.0001/10000000000, Validation Checks 0/6
Epoch 2/10, Time 0.151, Performance 0.10757/0.02, Gradient 0.92261/1e-07, Mu 1e-05/10000000000, Validation Checks 0/6
Epoch 3/10, Time 0.183, Performance 0.007149/0.02, Gradient 0.2649/1e-07, Mu 1e-06/10000000000, Validation Checks 0/6
Training with TRAINLM completed: Performance goal met.

```


En la figura 48 se nota la disminución del error al paso de cada iteración hasta tomar un valor por debajo de 0.02.

Figura 54. Resultados de entrenamiento (Modo grafico)




Se aprecia la finalización del entrenamiento una vez el EMC o el performance toma un valor menor o igual a 0.02, en este caso es 0.007149 mucho menor que la meta fijada, que constituía una de las condiciones de parada. Seguidamente se guarda la red ya entrenada para utilizarla en el Cálculo del Nivel de Error, y finalmente, ya para concluir con la implementación del modelo, presentamos las gráficas que miden la eficiencia del mismo:

Figura 55. Performance de entrenamiento



Esta grafica muestra cómo va disminuyendo el error a través del tiempo (épocas) hasta alcanzar su mínimo durante el entrenamiento.

Figura 56. Correlación del Modelo RNA



El coeficiente de correlación del modelo es $R^2 = 0,9985$, cumple la condición de aceptación ($R^2 \geq 0,8$) y presenta un muy buen ajuste.

Tabla 24. Resultados finales

COMPARACIÓN DE MODELOS				
Modelo	Tendencia cuadrática	Winter Aditivo	ARIMA	RNA
Criterio R^2	0.2312	0.8770	0.5331	0,9985

CAPITULO VIII

VENTAJAS Y DESVENTAJAS DE LOS MÉTODOS DE PRONÓSTICO DE DEMANDA DE ENERGÍA ELÉCTRICA

Tabla 25. Métodos de pronóstico de demanda ventajas y desventajas

MÉTODO	VENTAJAS	DESVENTAJAS	HORIZONTE
REGRESIÓN	Modelamiento sencillo.	Sobre extrapolación, es decir, predecir mayor demanda de la que puede existir en términos reales en una zona.	Corto, Mediano y Largo plazo
	La función obtenida permite hallar valores por dentro (interpolación) y por fuera (extrapolación) del rango de datos de la muestra y se conserva la secuencia cronológica en que se producen los datos de la muestra.		
	Permite incluir las variables que influyen en la demanda de energía eléctrica a través de la regresión múltiple.		
PROMEDIOS	Es de fácil construcción y conserva la secuencia cronológica en que se producen los datos, es decir, el patrón de comportamiento de la variable.	No considera la tendencia, estacionalidad o patrones sistemáticos, por tal motivo sus resultados son poco confiables.	Corto, Mediano y Largo plazo
	Su costo es bajo y su aplicación sencilla.		
HOLT Y WINTER	Su actualización es sencilla y adaptable a las necesidades del pronóstico que se requiere, con o sin variaciones estacionales.	No considera los factores cíclicos ni la presencia de variables externas en la predicción de los resultados.	Corto, Mediano y Largo plazo

Tabla 25. (Continuación)

MÉTODO	VENTAJAS	DESVENTAJAS	HORIZONTE
AR, MA, ARMA	El ajuste de datos estimados se acerca mucho al comportamiento de la curva de demanda con un margen de error mínimo.	Operacionalmente son deficientes en el corto plazo debido a la estimación y validación de varios modelos para una misma variable o perfil.	Corto, Mediano y Largo plazo
	Elimina los efectos de la estacionalidad, proporcionando resultados más confiables.	No considera el efecto de variables externas.	
DISTRIBUCIÓN DE PROBABILIDAD	La función obtenida permite hallar valores por dentro (interpolación) y por fuera (extrapolación) del rango de datos de la muestra.	Generalmente solo utiliza una variable, excluyendo los factores que influyen en la demanda de electricidad.	Corto, Mediano y Largo plazo
		No conserva la secuencia cronológica en que se producen los datos, es decir, el patrón de comportamiento de la variable.	
MICROÁREAS	Relaciona el crecimiento de la demanda eléctrica, con crecimiento de la población y comercio a través del uso del suelo.	Traslado de carga de una subestación a otra.	Mediano y Largo plazo
	Determina la ubicación idónea para la nueva subestación eléctrica	El pronóstico es válido es tanto la información de uso futuro de tierra o usuarios proyectados sea verídica.	
	Estima el tipo de consumo dentro de una pequeña área.	No establece pronóstico en corto plazo	
	Permite calcular otros parámetros eléctricos que competen al alimentador y a la subestación, es posible recalcular porcentajes de cargabilidad, pérdidas y caídas de voltaje del primario en el área de servicio.		
	La relación demanda eléctrica y uso de tierras se puede realizar a través de regresión múltiple brindando la oportunidad de adicionar variables que influyan en el comportamiento de la demanda.		

Tabla 25. (Continuación)

MÉTODO	VENTAJAS	DESVENTAJAS	HORIZONTE
RNA	Mejor redimiendo en el trato con las funciones no-lineales, su fortaleza estriba en que no requieren formulaciones matemáticas complejas o de correlación cuantitativa entre entradas y salidas.	Los paquetes computacionales en el mercado son limitados en su adaptación al problema, algunos tienen restricción en tamaño de la muestra.	Corto, Mediano y Largo plazo
	Modelos sencillos y permiten obtener bajos errores en el pronóstico tanto dentro como fuera de la muestra	Programación de la red es un tanto tediosa pero muy acertada en sus resultados.	
	El analista tiene mayor libertad en cuanto al manejo de parámetros para ajustar el modelo a la serie de datos.		
	El software ofrece funciones de pre-procesamiento y post-procesamiento de datos implícitas en las funciones de entrenamiento haciendo innecesario el uso individual de éstas		
	Reducción de costos operacionales y económicos debido a la disminución del error del pronóstico.		
	Son una solución sencilla, eficaz y confiable para la predicción de demanda de energía eléctrica con una precisión superior al 95%.		

VI. CONCLUSIONES

- A partir de los datos de demanda de electricidad de la empresa ABC del periodo 200801 a 201104 que corresponden a 40 meses se establecieron los modelos que mejor se ajustan a la serie de datos por cada método expuesto. Se puede afirmar que el modelo generado a partir del método de redes neuronales artificiales es el que presenta el mayor ajuste al comportamiento de la serie de datos con un coeficiente de correlación de **0,9985**, puesto que es mayor a 0.8 y el más cercano a 1, con este modelo se establece el pronóstico a 12 periodos.

Para esto se desarrollo un código en MATLAB V2012b que modela una red feedforward.

- De los modelos de regresión obtenidos a través de Excel, el modelo que presenta el mayor ajuste corresponde a un polinomio cuadrático con $R^2 = 0,2312$, en este caso no se puede afirmar que el comportamiento de la serie obedece a una función cuadrática pues el coeficiente de correlación no es igual ni mayor a 0,8.
- Los modelos generados a través del método Holt y Brown no se ajustan al comportamiento de la serie de datos mientras que el modelo de suavizamiento exponencial simple (estacional) genera un comportamiento similar a la serie de datos, no obstante el Modelo Winter Aditivo es quien posee el mayor coeficiente de correlación entre los modelos ajustados con $R^2 = 0,877$, con este resultado se puede afirmar que el comportamiento de la serie de demanda de energía eléctrica obedece al Modelo Winter Aditivo pues el coeficiente de correlación es mayor a 0,8 pero no el más cercano a 1.
- El modelo ARIMA (1, 0,0) (0, 1,1), se estimo teniendo en cuenta el test t de nulidad, valor p y por último el mínimo error cuadrado medio del modelo, este modelo presenta $R^2 = 0,5331$, no se puede afirmar que el comportamiento de la serie obedece a este modelo puesto que el coeficiente de correlación no es igual ni mayor a 0,8.
- De los modelos probabilísticos obtenidos para la serie de demanda de energía eléctrica el que mejor se ajusta es la distribución normal con el mayor porcentaje de aceptación de las pruebas Kolmogorov –Smirnov y Chi cuadrado seguido por la distribución gamma.

ANEXO

```
%-----%
% Universidad Tecnológica de Pereira
% Programa de Ingeniería Eléctrica
% Adriana Marcela Ariza Ramírez
% Código en MATLAB para implementar una red Neuronal de propagación hacia
% adelante para el pronóstico de demanda de energía eléctrica
% Perceptrón multicapa
% Predice periodos mensuales
%-----%

BaseDatos=xlsread('BaseDatos.xlsx');%Se llama la base de datos que
contiene los 40 registros del 200801 al 201104
EntrenaBaseDatos=con2seq(BaseDatos);%Se convierte la variable BaseDatos a
una secuencia de tiempo o arreglo de celdas
EntrenaBaseDatos=EntrenaBaseDatos(1:32);%Se filtran los primeros 32
registros que corresponden al 200801 hasta el 201008 para el
entrenamiento
red=newfftd(EntrenaBaseDatos,EntrenaBaseDatos,(1:12),9);%Red Feed-Forward
con una capa oculta y tiempo de retardo de 12 meses(1 año) y 9 neuronas
en la capa oculta
red.trainParam.epochs=10;%Numero de epocas o de iteraciones es de 10... se
puede modificar coloca las necesarias
red.trainParam.goal=0.02;%Meta de la funcion de evaluacion o bien el
error maximo permitido (Error Cuadratico Medio)es de 0.02 ,su valor al
ser alcanzado, detendra la red.
red.trainParam.show=1;%Muestra la salida en consola cada epoca o
iteracion
red.trainParam.showCommandLine=1;%Muestra la salida linea a linea
Entrada=EntrenaBaseDatos(13:end);%Conjunto de Entradas que inician en el
registro 13
Salida=EntrenaBaseDatos(13:end);%Conjunto de salidas y es igual al
conjunto de entradas ya que la prediccion de la variable se basa en sus
valores anteriores
ValorInicial=EntrenaBaseDatos(1:12);%Representa los 12 valores iniciales
que tendra el componente de retardo
[red,tr]=train(red,Entrada,Salida,ValorInicial);%Entrenamiento de la Red

%Grafica la eficiencia en el entrenamiento
plotperform(tr);
pronostico=sim(red,Entrada,ValorInicial);
reales=cell2mat(Entrada);
%disp('-----');
%disp('***Estos son los valores Reales para la demanda***');
%disp(reales);
%disp('-----');
pronostico=cell2mat(pronostico);
%disp('-----');
%disp('***Estos son los valores del Pronostico de la demanda***');
%disp(pronostico);
```

```

%Grafica de Regresion
pronostico=sim(red,Entrada,ValorInicial);
plotregression(Entrada(1,:),pronostico(1,:), '1');
%Guardamos los procesos matematicos
save redagua.mat

BaseDatos=xlsread('BaseDatos.xlsx');%Se llama la base de datos que
contiene los 40 registros del 200801 al 201104
load redagua.mat % Se leen los procesos ya realizados en la red
EntrenaBaseDatos=con2seq(BaseDatos);% Se convierte la variable BaseDatos
a una secuencia de tiempo o arreglo de celdas
EntrenaBaseDatos=EntrenaBaseDatos(28:40);%Se filtran los ultimos 12
registros que corresponden al 201005 hasta el 201104 para comprobar el
entrenamiento
Entrada=EntrenaBaseDatos(13:end);%Conjunto de Entradas que inician en el
registro 13
ValorInicial=EntrenaBaseDatos(1:12);%Conjunto de salidas con 12 valores
prediccion=sim(red,Entrada,ValorInicial);%Se obtiene la Demanda Futura
por medio de la simulacion de la red
reales=cell2mat(EntrenaBaseDatos(13:end));%Nuevos valores reales
disp('-----');
disp('***Se toma el ultimo valor real o de entrada para hallar el
error***');
disp(reales);
disp('-----');
prediccion=cell2mat(prediccion);
disp('-----');
disp('***Se toma el primer valor del Pronostico de la demanda para hallar
el error***');
disp(prediccion);
disp('-----');
error=abs(reales-prediccion);
disp('-----');
disp('***Resultado del Modelo de Redes Neuronales Artificiales***');
disp(['El Error de Pronostico Acumulativo es: ',num2str(sum(error))]);
disp('-----');
save redagua.mat %Se guardan los ultimos procesos
load redagua.mat% Se leen todos los procesos

%Simulacion Final de la red (Prueba de entrenamiento de la red)
BaseDatos=xlsread('BaseDatos.xlsx');% Se llama la base de datos que
contiene los 40 registros del 200801 al 201104
EntrenaBaseDatos=con2seq(BaseDatos);%Convertimos la variable BaseDatos a
una secuencia de tiempo o arreglo de celdas
Entrada=EntrenaBaseDatos(1:12);%Conjunto de entradas con 12 valores
ValorInicial=EntrenaBaseDatos(1:12);%Conjunto de salidas con 12 valores
prediccion=sim(red,Entrada,ValorInicial);
%disp('-----');
%disp('***Con la simulacion podemos comprobar que los valores para le
demanda futura***');
%disp('*****concuerdan con los valores del pronóstico de la
demanda*****');
%disp(prediccion);

```

BIBLIOGRAFÍA

- [1] ANDERSON, David; SWEENEY, Dennis y WILLIAMS, Thomas. Estadística para administración y economía. 10 ed. México: Cengage Learning Editores S.A.2008.
- [2] ARIAS, Luis Fernando. Programa digital para el pronóstico de carga eléctrica espacial. Trabajo de grado Ingeniero Eléctrico. Quito, Pichincha: Escuela Politécnica Nacional. Facultad de Ingeniería Eléctrica, 2000.
- [3] BANCO DE LA REPUBLICA. El fenómeno de El Niño y su posible impacto en Colombia. Investigación e información económica. Bogotá, D.C. Enero de 2007. Reportes del Emisor: Núm. 92.
- [4] BOWERMAN, Bruce; O'CONNELL, Richard y KOEHLER, Anne. Pronósticos, series de tiempo y regresión: Un enfoque aplicado. 4 ed. México: Internacional Thomson Editores, 2007.
- [5] COLOMBIA. CONGRESO DE LA REPUBLICA. Ley 51. (6, Diciembre, 1983). Por la cual se traslada el descanso remunerado de algunos días festivos. Diario Oficial. Bogotá, D.C., 1983. No. 36.428.
- [6] COLOMBIA. COMISIÓN DE REGULACIÓN DE ENERGÍA Y GAS. Resolución 097. (26, Septiembre, 2008). Por la cual se aprueban los principios generales y la metodología para el establecimiento de los cargos por uso de los Sistemas de Transmisión Regional y Distribución Local. Bogotá, D.C. 2008.p.1-135.
- [7] COLOMBIA. COMISIÓN DE REGULACIÓN DE ENERGÍA Y GAS. Resolución 183. (18, Diciembre, 2009). Por la cual se adoptan reglas relativas al cambio de usuarios entre el mercado no regulado y el mercado regulado y se adoptan otras disposiciones. Diario Oficial. Bogotá, D.C. 2009. No. 47.576.
- [8] DEL BARRIO, Tomás; CLAR, Miguel y Suriñach, Jordi. Modelo de regresión lineal múltiple: especificación, estimación y contraste. Barcelona: UOC Papers, 2002.
- [9] DEPARTAMENTO NACIONAL DE PLANEACIÓN, DIRECCIÓN DE ESTUDIOS ECONÓMICOS. Monografía del sector de electricidad y gas colombiano: Condiciones actuales y retos futuros. 5 de Noviembre, 2004. Documento: 272.
- [10] ENRÍQUEZ, Gilberto. El ABC Del Alumbrado y Las Instalaciones Eléctricas En Baja Tensión. 2 ed. México: Limusa, 2004.

- [11] ESPINA, José Rafael. Predicción espacial de la Demanda eléctrica en la ciudad de Maracaibo. Trabajo de grado Ingeniero Electricista. Maracaibo, Zulia: Universidad del Zulia. Facultad de Ingeniería. Escuela de Eléctrica, 1994.
- [12] FEINBERG, Eugene y GENETHLIOU, Dora. Load Forecasting En: Applied mathematics for Power Systems. Stony Brook: State University of New York. p. 269-285.
- [13] FLÓREZ, Raquel y FERNÁNDEZ José Miguel. Las Redes Neuronales Artificiales: Fundamentos teóricos y aplicaciones prácticas. España: Netbiblo, 2008.
- [14] GÖNEN, Turan. Electric Power Distribution System Engineering. McGraw-Hill, 1986.
- [15] GONZÁLEZ, Ayleen. Estudio de la demanda de saturación de energía eléctrica de la isla de margarita – Estado Nueva Esparta. Trabajo de grado Ingeniero Electricista. Barcelona, Anzoátegui: Universidad de Oriente. Escuela de Ingeniería y Ciencias Aplicadas. Departamento de Electricidad, 2009.
- [16] GUJARATI, Damodar. Econometria. 4 ed.: McGraw-Hill, 2003.
- [17] GUZMÁN, Jorge Luis. Fundamentos básicos para la proyección de la demanda de energía eléctrica. Trabajo de grado Ingeniero Electricista. Pereira, Risaralda: Universidad Tecnológica de Pereira. Facultad de Ingenierías. Programa de Ingeniería Eléctrica, 1990.
- [18] HANKE, John y REITSCH, Arthur. Pronósticos en los negocios. 5 ed. México: Pearson Educación (Traducción), 2000.
- [19] HERNÁNDEZ, Leonor. Predicción y optimización de emisiones y consumo mediante redes neuronales en motores diesel. España: Reverté, 2006.
- [20] HILERA, José y MARTÍNEZ, Víctor. Redes Neuronales Artificiales: Fundamentos, Modelos y Aplicaciones. Madrid: Alfa Omega-Rama, 2000.
- [21] KAASTRA, Iebling y BOYD, Milton. Designing Network for Forecasting financial and economic time series. En: Neurocomputing. 1996, p. 215-236.
- [22] LUZ DEL SUR S.A.A. Proyección de demanda de energía eléctrica 2007-2021. Perú. Septiembre 2006.
- [23] MALLO GONZÁLEZ, Carlos. Predicción de la demanda eléctrica horaria mediante redes neuronales artificiales. En: Universidad de Oviedo. Departamento de Economía Cuantitativa. p.5-28.

- [24] QUINTÍN, Martín; CABERO, María y DE PAZ, Yanira. Tratamiento estadístico de datos con SPSS: Prácticas resueltas y comentadas. España: Thomson Editores, 2008.
- [25] RAMÍREZ, Samuel. Redes de Distribución de Energía. 3 ed. Manizales: Universidad Nacional de Colombia, 2009.
- [26] ROSALES, Ramón y BONILLA, Jorge. Introducción a la Econometría. Bogotá D.C.: Universidad de los Andes, 2006.
- [27] UNIDAD DE PLANEACIÓN MINERO ENERGÉTICA. Proyección de demanda de energía eléctrica y potencia máxima. Informe Grupo de Demanda Energética. Bogotá D.C. Revisión 2011.
- [28] UNIDAD DE PLANEACIÓN MINERO ENERGÉTICA. Proyección de demanda de energía en Colombia. Informe Grupo de Demanda Energética. Bogotá D.C. Revisión Octubre de 2010.
- [29] VILLA, Andrés Felipe y HOLGUÍN, Juan Manuel. Aplicación de proyección de demanda y estudio de la cargabilidad en el sistema eléctrico de potencia en la ciudad de Pereira. Trabajo de grado Tecnólogos Electricistas. Pereira, Risaralda: Universidad Tecnológica de Pereira. Facultad de Tecnologías. Programa de Tecnología eléctrica, 2008.
- [30] WILLIS, H. Lee. Spatial electric Load forecasting. 2 ed. North Carolina: Marcel Dekker , 2002.
- [31] ZAPATA, Carlos Julio. Análisis Probabilístico y Simulación. Pereira: Universidad Tecnológica de Pereira, 2010.
- [32] ZAPATA, Carlos Julio; LÓPEZ, Julián y RENGIFO, Erickson. Efecto del modelamiento de la demanda en estudios de confiabilidad de largo plazo de sistemas eléctricos. En: Scientia et Technica. Diciembre de 2006, año XII, no. 32, p. 43-48.
- [33] ZAPATA, Carlos Julio; VAHOS, Mauricio y ROMERO, Carlos. Modelamiento de variables externas en estudios de confiabilidad de largo plazo de sistemas eléctricos. En: Mundo eléctrico. No. 70, p. 84-90.